数值分析

Analyse numérique élémentaire

教材信息

原书名： Analyse numérique élémentaire

适用专业：

适用年级： 本科三年级及以上

编译日期： 2026 年 1 月 31 日

数值分析教材中文翻译版

系统介绍数值计算的基本理论与方法

目录

前言 **i**

第一章 向量空间 **1**

1.1 向量空间 1

1.1.1 概述 1

1.1.2 向量子空间 2

1.1.3 线性无关族与生成族 2

1.1.4 向量空间的基 3

1.2 线性映射 4

1.2.1 线性映射的定义 4

1.2.2 线性映射的复合与逆映射 5

1.3 矩阵 6

1.3.1 矩阵的定义 6

1.3.2 矩阵的加法与乘法 7

1.3.3 矩阵的逆与转置 8

1.3.4 基底变换的定义 9

1.3.5 线性映射与矩阵的秩 10

1.4 行列式 11

1.4.1 递归定义行列式 11

1.4.2 行列式与列向量 12

1.4.3 行列式的基本性质 13

1.4.4 与秩相关的性质 14

1.5 线性方程组 15

1.5.1 方阵线性方程组 15

1.5.2 任意维度的线性方程组 16
1.6 特征值 17
1.6.1 特征值 18
1.6.2 特征值与相似矩阵 19
1.6.3 矩阵的对角化 19
1.6.4 特征值与正定矩阵 21

第二章 线性方程组的求解 23
2.1 研究背景 23
2.1.1 热传导方程 23
2.2 Guass 消元法 24
2.2.1 三角方程组的求解 24
2.2.2 *Gauss* 消元法的原理与第一步 25
2.2.3 第二步 26
2.2.4 一般步骤 27
2.2.5 *Gauss* 消元算法 27
2.2.6 *Gauss* 消元的矩阵表示 29
2.2.7 LU 分解的唯一性 30
2.3 直接计算分解 $A = LU$ 31
2.3.1 LU 分解的动机 31
2.3.2 直接计算 LU 分解的原理 31
2.3.3 Doolittle 算法 32
2.4 带主元搜索的 LU 分解 33
2.4.1 分解 $A = LU$ 的可行性 33
2.4.2 零主元-行置换 34
2.4.3 主元的选择。最大主元 35
2.4.4 分解 $PA = LU$ 36
2.4.5 分解 $PA = LU$ 的算法 38
2.4.6 应用于线性方程组的求解 38
2.4.7 完全主元法 39
2.5 对称矩阵的处理 40

2.5.1 分解 LDL^T 40
2.5.2 Cholesky 分解：存在性 40
2.5.3 Cholesky 算法 42

第三章 最小二乘问题的求解 45

3.1 最小二乘问题的一般表述 45
3.1.1 一个例子：平滑问题 45
3.1.2 矩阵形式 46
3.1.3 法方程 47
3.2 第三章文档 48
3.2.1 二次形式的梯度 48

第四章 迭代方法 51

4.1 线性方程组求解的迭代方法 51
4.1.1 一般原理 51
4.1.2 *Jacobi* 方法 52
4.1.3 *Gauss-Seidel* 方法 53
4.1.4 迭代方法的收敛性研究 53
4.2 单变量非线性方程的求解 55
4.2.1 二分法 55
4.2.2 不动点方法的原理 56
4.2.3 不动点方法的收敛性 56
4.2.4 *Newton* 方法求解方程 58
4.2.5 *Newton* 方法求解方程的收敛性 59
4.2.6 割线法 60
4.3 非线性方程组的求解 61
4.3.1 两个非线性方程的 *Newton* 方法 61
4.3.2 不动点方法 62
4.3.3 非线性方程组的 *Newton* 方法 63
4.4 第四章文档 64
4.4.1 非线性系统的不动点定理 64

第五章 插值 **67**

5.1 引言 67

5.1.1 函数的逼近 67

5.1.2 插值 68

5.2 多项式插值 68

5.2.1 *Lagrange* 基中的插值多项式 68

5.2.2 插值的计算 69

5.2.3 *Newton* 基中的插值多项式 70

5.2.4 差商 71

5.2.5 差商的实际计算 73

5.2.6 *Horner* 算法 74

5.2.7 插值多项式的收敛性 75

5.3 三次样条插值 75

5.3.1 问题的提出 75

5.3.2 三次样条插值的定义 76

5.4 第五章文档 76

5.4.1 插值多项式和 *Taylor* 多项式的表达式类比 76

第六章 积分 **79**

6.1 数值积分方法的动机和原理 79

6.2 使用插值多项式的方法 79

6.2.1 方法的原理 80

6.2.2 参考区间 80

6.2.3 求积误差的上界 - 阶数 81

6.2.4 *Newton-Cotes* 公式 82

6.2.5 复合数值积分 83

6.3 第六章文档 84

6.3.1 在什么意义下近似? 84

6.3.2 求积误差的先验和后验估计 85

第七章 微分方程 **87**

7.1 一般求解原理 87
7.1.1 引言 87
7.1.2 微分方程理论要素 88
7.1.3 数值方法的原理 90
7.2 单步格式 91
7.2.1 从数值积分出发的 *Euler* 格式 91
7.2.2 单步预测-校正格式 91
7.2.3 *Euler* 方法的初步研究 92
7.2.4 单步格式的阶和一致性 93
7.2.5 单步格式的稳定性和收敛性 94
7.2.6 *Runge-Kutta* 格式 96
7.3 多步格式 98
7.3.1 *Adams-Bashforth* 格式 98
7.3.2 *Adams-Bashforth* 格式的一些例子 99
7.3.3 *Adams-Moulton* 隐式格式 100
7.3.4 *Adams-Moulton* 格式的一些例子 101
7.4 第七章文档 101
7.4.1 Lipschitz 条件 101
7.4.2 *Runge-Kutta* 方法的定义 102
7.4.3 步长的自动适应 103

第八章 特征值和特征向量的确定 107

8.1 回顾和记号 107
8.2 幂迭代方法 - 陈述和假设 108
8.3 幂迭代方法 - 收敛性和备注 108
8.4 逆幂迭代方法 - 原理 110
8.5 逆幂迭代方法 111
8.6 收缩方法 111

前言

本文档是法国经典教材《Analyse numérique élémentaire》的中文翻译版本，面向本科生使用。本教材系统地介绍了数值分析的基本理论和方法，包括数值计算、误差分析、数值逼近、线性方程组求解、数值积分与微分等内容。

在翻译过程中，我们力求保持原著的学术严谨性和逻辑完整性，同时兼顾中文表达习惯，使内容更易于理解。本教材适合作《数值分析》课程的教材或参考书。

译者

2026 年 1 月 31 日

Chapter 1

向量空间

1.1　向量空间

1.1.1　概述

向量空间的精确定义已在所引用的文档中给出。由于你今后将遇到的主要应用只涉及 $\mathbb{R}^n$（或 $\mathbb{C}^n$）以及 P_n（次数小于或等于 n 的多项式空间）这两个常见的向量空间，我们将在这两个特殊情形下对该定义进行说明。

我们首先研究向量空间 $\mathbb{R}^3$。其中的向量 $\boldsymbol{x}$ 可以在一个正交规范坐标系中与几何向量 $\overrightarrow{OM}$ 等同。（见图 1.1.1）。

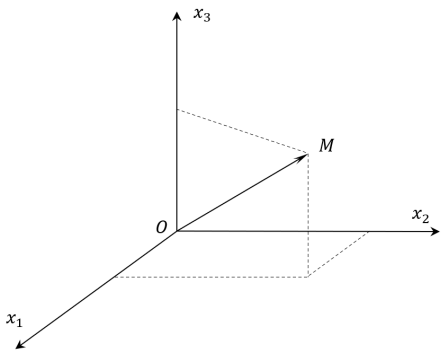

图 1.1.1　空间

在之前的学习中，我们假设你已经掌握了向量的加法运算，并且将在习题中验证该运算满足结合律、交换律，存在零元（$\mathbf{0}$），且每个向量（$\boldsymbol{x}$）都有一个负元（$-\boldsymbol{x}$）。这就是向量空间 $\mathbb{R}^3$ 的内部合成法则。同时你还掌握了将向量乘以一个实数 λ 的运算（比例为 λ 的位似变换），这是向量空间的第二条法则，不难证明该法则具备良好的性质。

集合 P_n（系数为实数、次数小于或等于 n 的多项式）同样赋予了满足结合律、交换律的加法运算，该运算存在零元（零多项式），且每个多项式 p 都有一个负元 $-p$。你同样掌握了将多项式 p 乘以一个实数 λ 的运算（只需将其所有系数都乘以 λ），该乘积也具备良好的性质，因此 P_n 构成一

个向量空间。

在上述两个例子中，第二条法则均为由集合中的元素与一个实数相乘构成。因此，我们称集合 $\mathbb{R}^3$ 和 P_n 是实数域 $\mathbb{R}$ 上的向量空间。

注 1.1.1

现在考虑复数集合 $\mathbb{C}$，内部合成律是复数的加法。对于第二条定律，有两种可能的选择。如果考虑一个复数与一个实数的乘积，则得到 $\mathbb{R}$ 上的向量空间，但如果考虑一个复数与一个复数的乘积，则得到 $\mathbb{C}$ 上的向量空间。

1.1.2 向量子空间

该定义有时也可以用如下简洁的形式来表述：

$$\forall \boldsymbol{x} \in F,\ \forall \boldsymbol{y} \in F,\ \forall \lambda \in K,\ \forall \mu \in K,\ \lambda \boldsymbol{x} + \mu \boldsymbol{y} \in F. \tag{1.1.1}$$

例如，在 $\mathbb{R}^2$ 中，方向向量为 $\boldsymbol{x}$ 的直线都是向量子空间，此时

$$F = \{\lambda \boldsymbol{x} \mid \lambda \in \mathbb{R}\}. \tag{1.1.2}$$

在 $\mathbb{R}^3$ 中，由两个不成比例的向量 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 所生成的平面是向量子空间，此时

$$F = \{\lambda \boldsymbol{x} + \mu \boldsymbol{y} \mid \lambda \in \mathbb{R},\ \mu \in \mathbb{R}\}. \tag{1.1.3}$$

当 $k \leq n$ 时，多项式空间 P_k 是 P_n 的一个向量子空间。

1.1.3 线性无关族与生成族

定义 1.1.1

设 $\{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_p\}$ 是向量空间 E 中的一族向量。如果存在不全为零的标量 $\lambda_1, \ldots, \lambda_p \in K$，使得

$$\lambda_1 \boldsymbol{x}_1 + \lambda_2 \boldsymbol{x}_2 + \cdots + \lambda_p \boldsymbol{x}_p = \boldsymbol{0}, \tag{1.1.4}$$

则称该向量族是**线性相关的**。

当该向量族所含向量多于两个时，上述定义等价于：该向量族中至少有一个向量可以表示为其余向量的线性组合。

定义 1.1.2

不是线性相关的向量族称为**线性无关族**。在这种情况下，有

$$\lambda_1 \boldsymbol{x}_1 + \lambda_2 \boldsymbol{x}_2 + \cdots + \lambda_p \boldsymbol{x}_p = \boldsymbol{0} \quad \Longleftrightarrow \quad \lambda_1 = \lambda_2 = \cdots = \lambda_p = 0. \tag{1.1.5}$$

例如，在 $\mathbb{R}^2$ 中，向量族

$$\{\boldsymbol{x}_1, \boldsymbol{x}_2, \boldsymbol{x}_3\} = \{(1,0),(0,1),(1,2)\}$$

是线性相关的，因为 $\boldsymbol{x}_3 = \boldsymbol{x}_1 + 2\boldsymbol{x}_2$。相反，向量族

$$\{\boldsymbol{x}_1, \boldsymbol{x}_2\} = \{(1,0),(0,1)\}$$

是线性无关的（请读者自行证明）。

定义 1.1.3

设 $\{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_p\}$ 是向量空间 E 中的一族向量。如果 E 中的任意向量 $\boldsymbol{x}$ 都可以表示为 $\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_p$ 的线性组合，即存在 $\lambda_1, \ldots, \lambda_p \in K$，使得

$$\boldsymbol{x} = \lambda_1 \boldsymbol{x}_1 + \lambda_2 \boldsymbol{x}_2 + \cdots + \lambda_p \boldsymbol{x}_p, \tag{1.1.6}$$

则称该向量族是 E 的一个**生成族**。

此时称向量空间 E 由向量族 $\{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_p\}$ 所生成，并记为

$$E = \mathrm{vect}\langle \boldsymbol{x}_1, \ldots, \boldsymbol{x}_p \rangle. \tag{1.1.7}$$

1.1.4　向量空间的基

我们考虑一个向量空间 E，它存在一个有限元素的生成族。例如，向量族

$$\{(1,0,0),(0,1,0),(0,0,1)\} \tag{1.1.8}$$

是 $\mathbb{R}^3$ 的一个生成族，而

$$\{1, x, x^2, \ldots, x^n\} \tag{1.1.9}$$

是 P_n 的一个生成族。某些向量空间，例如实连续函数空间，没有有限元素的生成族，但这不在本课程讨论范围之内。

定义 1.1.4

向量空间 E 的一个基 $B = \{\boldsymbol{e}_1, \ldots, \boldsymbol{e}_n\}$ 是一个同时线性无关且生成整个空间的向量族。由于 B 是生成族，E 中的任意向量 $\boldsymbol{x}$ 都可以表示为 B 中元素的线性组合，并且可以证明这种表示是唯一的（参见练习 1.10）。

定义 1.1.5

有限维向量空间 E 是指存在一个基包含有限个向量的向量空间；基中向量的个数称为 E 的**维数**。

注意，对于给定的有限维向量空间，可以证明所有基的向量数目相同，这也就保证了“向量空间的维数”定义的合理性。

例如，定义 $\mathbb{R}^n$ 中的向量 $\boldsymbol{e}_i$，其所有分量为零，唯有第 i 个分量为 1，则向量族

$$\{\boldsymbol{e}_1, \ldots, \boldsymbol{e}_n\} \tag{1.1.10}$$

是 $\mathbb{R}^n$ 的一个基，这意味着 $\mathbb{R}^n$ 是一个维数为 n 的向量空间。类似地，向量族

$$\{1, x, x^2, \ldots, x^n\} \tag{1.1.11}$$

是 P_n 的一个基，因此 P_n 的维数为 $n+1$。

一个有趣的（未证明）结论，因为它简化了很多证明，如下：

命题 1.1.1

设 E 是维数为 n 的向量空间，则有：

- 任意 n 个线性无关向量构成 E 的一个基；
- 任意 n 个生成族中的向量构成 E 的一个基。

1.2 线性映射

1.2.1 线性映射的定义

我们考虑两个向量空间 E 和 F，它们都定义在同一域 K 上，$K = \mathbb{R}$ 或 $K = \mathbb{C}$。

定义 1.2.1

一个映射 $u : E \to F$ 称为**线性映射**，如果它满足以下性质：

$$u(\boldsymbol{x} + \boldsymbol{y}) = u(\boldsymbol{x}) + u(\boldsymbol{y}), \quad \forall \boldsymbol{x} \in E, \forall \boldsymbol{y} \in E, \tag{1.2.1}$$

$$u(\lambda \boldsymbol{x}) = \lambda u(\boldsymbol{x}), \quad \forall \boldsymbol{x} \in E, \forall \lambda \in K. \tag{1.2.2}$$

例如，将 $\mathbb{R}$ 映射到 $\mathbb{R}$ 的映射 $x \mapsto e^x$ 不是线性映射，而映射 $x \mapsto 3x$ 是线性映射。

注意，由 u 映射得到的 E 中的零向量是 F 中的零向量（只需在定义中取 $\lambda = 0$）。

定义 1.2.2

设 $u : E \to F$ 是线性映射。

- **核**（noyau）是 E 的一个子空间，记为 $\operatorname{Ker} u$，满足

$$\boldsymbol{x} \in \operatorname{Ker} u \quad \Longleftrightarrow \quad u(\boldsymbol{x}) = \boldsymbol{0}. \tag{1.2.3}$$

- **像**（image）是 F 的一个子空间，记为 $\operatorname{Im} u$，由所有 $u(\boldsymbol{x})$ 组成，$\boldsymbol{x}$ 遍历 E，即

$$\boldsymbol{y} \in \operatorname{Im} u \quad \Longleftrightarrow \quad \exists \boldsymbol{x} \in E,\ \boldsymbol{y} = u(\boldsymbol{x}). \tag{1.2.4}$$

例如，如果 $u:\mathbb{R}^3\to\mathbb{R}$ 是线性映射，定义为

$$u(\boldsymbol{x})=x_1+3x_2+5x_3,\quad \boldsymbol{x}=(x_1,x_2,x_3), \tag{1.2.5}$$

则 $\operatorname{Ker}u$ 是平面

$$x_1+3x_2+5x_3=0, \tag{1.2.6}$$

而 $\operatorname{Im}u=\mathbb{R}$。

核与像的维数之间存在如下关系（未证明）：

命题 1.2.1

设 $u:E\to F$ 是线性映射，则有

$$\dim E=\dim(\operatorname{Ker}u)+\dim(\operatorname{Im}u). \tag{1.2.7}$$

1.2.2　线性映射的复合与逆映射

我们考虑三个向量空间 E、F 和 G，它们定义在同一域 K 上（$K=\mathbb{R}$ 或 $K=\mathbb{C}$）。

定义 1.2.3

设 $f:E\to F$ 和 $g:F\to G$ 是两个线性映射，则 f 与 g 的复合映射 $g\circ f$ 定义为

$$g\circ f:E\to G,\quad \boldsymbol{x}\mapsto g[f(\boldsymbol{x})]. \tag{1.2.8}$$

复合映射确实是线性映射，因为对于任意 $\boldsymbol{x},\boldsymbol{y}\in E$ 与任意 $\lambda\in K$ 有

$$(g\circ f)(\boldsymbol{x}+\boldsymbol{y})=g[f(\boldsymbol{x}+\boldsymbol{y})]=g[f(\boldsymbol{x})+f(\boldsymbol{y})]=g[f(\boldsymbol{x})]+g[f(\boldsymbol{y})]=(g\circ f)(\boldsymbol{x})+(g\circ f)(\boldsymbol{y}), \tag{1.2.9}$$

$$(g\circ f)(\lambda\boldsymbol{x})=g[f(\lambda\boldsymbol{x})]=g[\lambda f(\boldsymbol{x})]=\lambda g[f(\boldsymbol{x})]=\lambda(g\circ f)(\boldsymbol{x}). \tag{1.2.10}$$

回忆一下，映射的逆（不一定是线性映射）通过复合定义：

定义 1.2.4

设 $f:E\to F$ 是一个映射。如果存在一个映射 $f^{-1}:F\to E$，使得

$$f^{-1}\circ f=i_E\quad 且\quad f\circ f^{-1}=i_F, \tag{1.2.11}$$

其中 i_E 是 E 上的恒等映射，则称 f 是**可逆映射**，而 f^{-1} 称为 f 的**逆映射**（或互逆映射）。

同样可知，一个映射可逆当且仅当它是单射且满射，即双射（bijective）（参见所引用文档的定义），此时 f^{-1} 也是双射。

对于线性映射，有如下通过核来判定单射的性质（证明见所引用文档）：

命题 1.2.2

线性映射 u 是单射当且仅当

$$\operatorname{Ker} u = \{\mathbf{0}\}. \tag{1.2.12}$$

对于双射的线性映射 u，可证明其逆映射 u^{-1} 也是线性映射。

1.3 矩阵

1.3.1 矩阵的定义

我们考虑两个向量空间 E 和 F，它们定义在同一域 K 上（$K=\mathbb{R}$ 或 $K=\mathbb{C}$），且维数分别为 $\dim E = n$ 和 $\dim F = m$。

定义 1.3.1

设 $u: E \to F$ 是一个线性映射，选择基

$$\mathscr{E} = \{\boldsymbol{e}_1, \boldsymbol{e}_2, \ldots, \boldsymbol{e}_n\} \subset E, \quad \mathscr{F} = \{\boldsymbol{f}_1, \boldsymbol{f}_2, \ldots, \boldsymbol{f}_m\} \subset F. \tag{1.3.1}$$

与该线性映射 u 对应的**矩阵** $\boldsymbol{A}$ 定义为一个 $m \times n$ 的标量表（即元素属于 K），其构造方式如下：矩阵的第 j 列由向量 $u(\boldsymbol{e}_j)$ 在基 $\mathscr{F}$ 下的坐标组成。换句话说，设 a_{ij} 表示矩阵 $\boldsymbol{A}$ 中第 i 行第 j 列的元素，则有

$$u(\boldsymbol{e}_j) = \sum_{i=1}^{m} a_{ij} \boldsymbol{f}_i, \quad 1 \le j \le n. \tag{1.3.2}$$

矩阵 $\boldsymbol{A}$ 通常记为

$$\boldsymbol{A} = \begin{pmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1j} & \cdots & a_{1n} \\ a_{21} & a_{22} & a_{23} & \cdots & a_{2j} & \cdots & a_{2n} \\ a_{31} & a_{32} & a_{33} & \cdots & a_{3j} & \cdots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots & & \vdots \\ a_{i1} & a_{i2} & a_{i3} & \cdots & a_{ij} & \cdots & a_{in} \\ \vdots & \vdots & \vdots & & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & a_{m3} & \cdots & a_{mj} & \cdots & a_{mn} \end{pmatrix}. \tag{1.3.3}$$

矩阵 $\boldsymbol{A}$ 称为 $m \times n$ 矩阵，或类型为 (m, n) 的矩阵。记 M_{mn} 为所有此类矩阵的集合（必要时可指明域 K）。

- 若 $m = n$，矩阵称为**方阵**。
- 若 $m = 1$，矩阵称为**行矩阵**，或称行向量。
- 若 $n = 1$，矩阵称为**列矩阵**，或称列向量。
- 若 $m = n$ 且 $a_{ij} = 0$ 对于 $i \neq j$，矩阵称为**对角矩阵**。
- 若 $m = n$，$a_{ij} = 0$ 对于 $i \neq j$ 且 $a_{ii} = 1$，矩阵称为**单位矩阵**。

- 若 $m=n$ 且 $a_{ij}=0$ 对于 $i<j$，矩阵称为**下三角矩阵**。
- 若 $m=n$ 且 $a_{ij}=0$ 对于 $i>j$，矩阵称为**上三角矩阵**。

例如，在二维平面 E 中，如果取一个正交规范基（$\mathscr{F}=\mathscr{E}=\{\boldsymbol{e}_1,\boldsymbol{e}_2\}$），角度为 θ 的旋转 u 的矩阵为：

$$u(\boldsymbol{e}_1)=\cos\theta\,\boldsymbol{e}_1+\sin\theta\,\boldsymbol{e}_2,\quad u(\boldsymbol{e}_2)=-\sin\theta\,\boldsymbol{e}_1+\cos\theta\,\boldsymbol{e}_2, \tag{1.3.4}$$

对应的矩阵为

$$\boldsymbol{A}=\begin{pmatrix}\cos\theta & -\sin\theta\\ \sin\theta & \cos\theta\end{pmatrix}. \tag{1.3.5}$$

在后续中，我们记 $\boldsymbol{A}_j, 1\le j\le n$ 为矩阵 $\boldsymbol{A}$ 的第 j 列，$\boldsymbol{A}_i, 1\le i\le m$ 为矩阵 $\boldsymbol{A}$ 的第 i 行。

1.3.2　矩阵的加法与乘法

矩阵本质上是一个数表（元素属于 $\mathbb{R}$ 或 $\mathbb{C}$），但如果不参考它所表示的线性映射，矩阵本身几乎无法做任何合理的推导。我们始终以此为前提：任意 $m\times n$ 矩阵都可以看作线性映射

$$u:\mathbb{R}^n\to\mathbb{R}^m\quad(\text{或}u:\mathbb{C}^n\to\mathbb{C}^m) \tag{1.3.6}$$

在基向量 $\{\boldsymbol{e}_1,\dots,\boldsymbol{e}_n\}=\mathscr{E}\subset E$ 和 $\{\boldsymbol{f}_1,\dots,\boldsymbol{f}_m\}=\mathscr{F}\subset F$ 下的矩阵表示为

$$u(\boldsymbol{e}_j)=\sum_{i=1}^{m}a_{ij}\boldsymbol{f}_i,\quad 1\le j\le n. \tag{1.3.7}$$

在此基础上，我们可以定义矩阵的加法以及矩阵与标量的乘法。

定义 1.3.2

设 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 为同型矩阵（$m\times n$），则它们的和 $\boldsymbol{A}+\boldsymbol{B}$ 定义为矩阵 $\boldsymbol{C}$，其元素为

$$c_{ij}=a_{ij}+b_{ij},\quad 1\le i\le m,\ 1\le j\le n. \tag{1.3.8}$$

该矩阵 $\boldsymbol{C}$ 对应的线性映射是由 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 对应的线性映射之和。

同样，矩阵 $\boldsymbol{A}$ 与标量 $\lambda\in K$ 的乘积记为 $\lambda\boldsymbol{A}$，其定义为将 $\boldsymbol{A}$ 的每个元素乘以 λ。

定义 1.3.3

设 E,F,G 为向量空间，$\dim E=n,\dim F=m,\dim G=q$，并设线性映射

$$v:E\to F,\quad u:F\to G,\quad w=u\circ v:E\to G. \tag{1.3.9}$$

令 $\boldsymbol{B}$ 为 v 在基 $\mathscr{E}$ 和 $\mathscr{F}$ 下的矩阵，$\boldsymbol{A}$ 为 u 在基 $\mathscr{F}$ 和 $\mathscr{G}$ 下的矩阵，则 w 在基 $\mathscr{E}$ 和 $\mathscr{G}$ 下的矩阵为矩阵乘积

$$\boldsymbol{C}=\boldsymbol{A}\boldsymbol{B}. \tag{1.3.10}$$

由定义可得矩阵乘法公式：

$$c_{ij} = \sum_{k=1}^{m} a_{ik} b_{kj}, \quad i = 1, \ldots, q,\ j = 1, \ldots, n. \tag{1.3.11}$$

命题 1.3.1

设 $u : E \to F$ 为线性映射，$\boldsymbol{y} = u(\boldsymbol{x})$，$\mathscr{E} = \{\boldsymbol{e}_1, \ldots, \boldsymbol{e}_n\} \subset E$ 与 $\mathscr{F} = \{\boldsymbol{f}_1, \ldots, \boldsymbol{f}_p\} \subset F$ 为基，$\boldsymbol{x}$ 在 $\mathscr{E}$ 下的坐标为

$$\boldsymbol{X} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \ \boldsymbol{y} \text{ 在} \mathscr{F} \text{ 下的坐标为 } \boldsymbol{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{pmatrix}. \tag{1.3.12}$$

若 $\boldsymbol{A}$ 为 u 在基 $\mathscr{E}, \mathscr{F}$ 下的矩阵，则有

$$\boldsymbol{Y} = \boldsymbol{A}\boldsymbol{X}. \tag{1.3.13}$$

该结论的证明留作习题。

1.3.3 矩阵的逆与转置

设 $u : E \to E$ 是双射且线性映射，则 u 可逆，其对应矩阵 $\boldsymbol{A}$ 为方阵。对应 u^{-1} 的矩阵记为 $\boldsymbol{A}^{-1}$，满足

$$\boldsymbol{A}\boldsymbol{A}^{-1} = \boldsymbol{A}^{-1}\boldsymbol{A} = \boldsymbol{I}, \tag{1.3.14}$$

由此可得矩阵逆的定义。

定义 1.3.4

设 $\boldsymbol{A}$ 为方阵，若存在矩阵 $\boldsymbol{A}^{-1}$ 满足

$$\boldsymbol{A}\boldsymbol{A}^{-1} = \boldsymbol{A}^{-1}\boldsymbol{A} = \boldsymbol{I}, \tag{1.3.15}$$

则称 $\boldsymbol{A}^{-1}$ 为 $\boldsymbol{A}$ 的**逆矩阵**。若存在，逆矩阵是唯一的（见习题 1.22）。

此外，由

$$\boldsymbol{A}\boldsymbol{B}\,\boldsymbol{B}^{-1}\boldsymbol{A}^{-1} = \boldsymbol{B}^{-1}\boldsymbol{A}^{-1}\boldsymbol{A}\boldsymbol{B} = \boldsymbol{I} \tag{1.3.16}$$

可以推得

$$(\boldsymbol{A}\boldsymbol{B})^{-1} = \boldsymbol{B}^{-1}\boldsymbol{A}^{-1}. \tag{1.3.17}$$

定义 1.3.5

设 $\boldsymbol{A} \in \boldsymbol{M}_{m,n}$，称矩阵 $\boldsymbol{A}^T \in \boldsymbol{M}_{n,m}$ 为 $\boldsymbol{A}$ 的**转置矩阵**，其定义为将 $\boldsymbol{A}$ 的行与列交换，即

$$(\boldsymbol{A}^T)_{ij} = a_{ji}, \quad i = 1, \ldots, n,\ j = 1, \ldots, m. \tag{1.3.18}$$

矩阵转置具有如下性质：

- $(\boldsymbol{A}^T)^T = \boldsymbol{A}$,
- $(\boldsymbol{A}+\boldsymbol{B})^T = \boldsymbol{A}^T + \boldsymbol{B}^T$,
- $(\lambda\boldsymbol{A})^T = \lambda\boldsymbol{A}^T$。

若 $\boldsymbol{X}$ 与 $\boldsymbol{Y}$ 为列向量，则 $\boldsymbol{X}^T\boldsymbol{Y} = \boldsymbol{Y}^T\boldsymbol{X}$ 是一个标量，具体为

$$\boldsymbol{X}^T\boldsymbol{Y} = \boldsymbol{Y}^T\boldsymbol{X} = \sum_{i=1}^{m} x_i y_i. \tag{1.3.19}$$

若矩阵乘积 $\boldsymbol{AB}$ 存在，则有

$$(\boldsymbol{AB})^T = \boldsymbol{B}^T\boldsymbol{A}^T. \tag{1.3.20}$$

该结论可以通过逐元素对比两边矩阵证明。

1.3.4　基底变换的定义

定义 1.3.6

设 $\mathscr{E} = \{\boldsymbol{e}_1, \boldsymbol{e}_2, \ldots, \boldsymbol{e}_n\}$ 与 $\mathscr{E}' = \{\boldsymbol{e}'_1, \boldsymbol{e}'_2, \ldots, \boldsymbol{e}'_n\}$ 为向量空间 E 的两个基底，称从基底 $\mathscr{E}$ 到基底 $\mathscr{E}'$ 的**过渡矩阵**为 $\boldsymbol{P}$，其定义为：

$$\boldsymbol{P} = \begin{array}{c} \begin{array}{cccccc} \boldsymbol{e}'_1 & \boldsymbol{e}'_2 & \ldots & \boldsymbol{e}'_j & \ldots & \boldsymbol{e}'_n \end{array} \\ \begin{pmatrix} p_{11} & p_{12} & \ldots & p_{1j} & \ldots & p_{1n} \\ p_{21} & p_{22} & \ldots & p_{2j} & \ldots & p_{2n} \\ \ldots & \ldots & \ldots & \ldots & \ldots & \ldots \\ p_{i1} & p_{i2} & \ldots & p_{ij} & \ldots & p_{in} \\ \ldots & \ldots & \ldots & \ldots & \ldots & \ldots \\ p_{m1} & p_{m2} & \ldots & p_{mj} & \ldots & p_{mn} \end{pmatrix} \end{array} \begin{array}{c} \\ \boldsymbol{e}_1 \\ \boldsymbol{e}_2 \\ \ldots \\ \boldsymbol{e}_i \\ \ldots \\ \boldsymbol{e}_m \end{array} \tag{1.3.21}$$

即将“新基底”$\mathscr{E}'$ 中每个向量在“旧基底”$\mathscr{E}$ 下的分量按列排列而成。

矩阵 $\boldsymbol{P}$ 可逆，其逆矩阵 $\boldsymbol{P}^{-1}$ 为从 $\mathscr{E}'$ 到 $\mathscr{E}$ 的过渡矩阵。

命题 1.3.2

（基底变换下向量分量的变化）设 $\boldsymbol{x} \in E$，在基底 $\mathscr{E}$ 与 $\mathscr{E}'$ 下的分量分别为 $(x_1, x_2, \ldots, x_n)$ 和 $(x'_1, x'_2, \ldots, x'_n)$。则有

$$\boldsymbol{X} = \boldsymbol{P}\boldsymbol{X}' \quad \text{或等价地} \quad \boldsymbol{X}' = \boldsymbol{P}^{-1}\boldsymbol{X}, \tag{1.3.22}$$

其中

$$\boldsymbol{X} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}, \quad \boldsymbol{X}' = \begin{pmatrix} x'_1 \\ \vdots \\ x'_n \end{pmatrix}. \tag{1.3.23}$$

定理 1.3.1

（基底变换下矩阵的相似变换）设 $u \in \mathscr{L}(E;E)$，$\boldsymbol{A}$ 与 $\boldsymbol{A}'$ 分别为 u 在基底 $\mathscr{E}$ 和 $\mathscr{E}'$ 下的矩阵，$\boldsymbol{P}$ 为从 $\mathscr{E}$ 到 $\mathscr{E}'$ 的过渡矩阵，则有

$$\boldsymbol{A}' = \boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}. \tag{1.3.24}$$

矩阵 $\boldsymbol{A}$ 与 $\boldsymbol{A}'$ 称为**相似矩阵**。

1.3.5 线性映射与矩阵的秩

定义 1.3.7

设 $u: E \to F$ 为一个线性映射，称 u 的**秩**为其像空间的维数，记作

$$\operatorname{rang}(u) = \dim(\operatorname{Im} u). \tag{1.3.25}$$

由于 $\operatorname{Im} u$ 是 F 的向量子空间，因此有

$$\operatorname{rang}(u) \leq \dim F, \tag{1.3.26}$$

当 u 为满射时等号成立。另一方面，由线性映射的基本维数公式

$$\dim E = \dim(\operatorname{Ker} u) + \dim(\operatorname{Im} u) \tag{1.3.27}$$

可知

$$\operatorname{rang}(u) \leq \dim E. \tag{1.3.28}$$

定义 1.3.8

设 $\boldsymbol{A} \in \mathscr{M}_{m,n}$，称 $\boldsymbol{A}$ 的**像**为由所有形如 $\boldsymbol{Y} = \boldsymbol{A}\boldsymbol{X}$ 的列向量构成的向量子空间，记作 $\operatorname{Im} \boldsymbol{A}$。

该空间也可由 $\boldsymbol{A}$ 的列向量 $\boldsymbol{A}_1, \boldsymbol{A}_2, \ldots, \boldsymbol{A}_n$ 张成，因为

$$\boldsymbol{Y} \in \operatorname{Im} \boldsymbol{A} \quad \Longleftrightarrow \quad \boldsymbol{Y} = \boldsymbol{A}\boldsymbol{X} \quad \Longleftrightarrow \quad \boldsymbol{Y} = \sum_{i=1}^{n} x_i \boldsymbol{A}_i. \tag{1.3.29}$$

定义 1.3.9

称矩阵 $\boldsymbol{A}$ 的**核**为

$$\operatorname{Ker} \boldsymbol{A} = \{\boldsymbol{X} \in \mathscr{M}_{n,1} \mid \boldsymbol{A}\boldsymbol{X} = \boldsymbol{0}\}. \tag{1.3.30}$$

定理 1.3.2

设 $\boldsymbol{A} \in \mathscr{M}_{m,n}$，则有

$$\dim(\operatorname{Ker} \boldsymbol{A}) + \dim(\operatorname{Im} \boldsymbol{A}) = n. \tag{1.3.31}$$

定义 1.3.10

设 $\boldsymbol{A} \in \mathscr{M}_{m,n}$，称 $\boldsymbol{A}$ 的**秩**为其像空间的维数，记作

$$\operatorname{rang}(\boldsymbol{A}) = \dim(\operatorname{Im} \boldsymbol{A}). \tag{1.3.32}$$

- 若 $u \in \mathscr{L}(E;F)$ 且 $\boldsymbol{A}$ 为 u 在任意基下的矩阵表示，则

$$\operatorname{rang}(u) = \operatorname{rang}(\boldsymbol{A}). \tag{1.3.33}$$

- $\boldsymbol{A}$ 与其转置矩阵 $\boldsymbol{A}^T$ 具有相同的秩。

矩阵秩的实际计算　根据定义及上述结果，矩阵秩的计算可归结为：

- 计算矩阵列向量的线性无关个数；
- 计算矩阵行向量的线性无关个数。

取其中较易计算的方法即可。

另外，如果已知与矩阵 $\boldsymbol{A}$ 对应的线性映射 u 的秩，也可直接得到 $\boldsymbol{A}$ 的秩。在行列式章节中，还将介绍另一种计算矩阵秩的方法。

1.4　行列式

1.4.1　递归定义行列式

如你将看到的，行列式的概念只能对方阵矩阵定义。

定义 1.4.1

设 $\boldsymbol{A} \in \mathscr{M}_{n,n}$，通过递归定义行列式函数

$$\det : \mathscr{M}_{n,n} \to K, \quad \boldsymbol{A} \mapsto \det \boldsymbol{A} \tag{1.4.1}$$

具体定义如下：

1. 当 $n = 1$，若 $\boldsymbol{A} = (a)$，则

$$\det \boldsymbol{A} = a. \tag{1.4.2}$$

2. 当 $n > 1$，记 $\boldsymbol{A}|i,j|$ 为从 $\boldsymbol{A}$ 中删除第 i 行和第 j 列得到的 $(n-1)\times(n-1)$ 子矩阵，则

$$\det \boldsymbol{A} = \sum_{k=1}^{n} (-1)^{1+k} a_{1k} \det(\boldsymbol{A}|1,k|). \tag{1.4.3}$$

定义中标量 $\det \boldsymbol{A}$ 称为矩阵 $\boldsymbol{A}$ 的**行列式**。

例如，对于 2×2 方阵：

$$\det\begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} = a_{11}a_{22} - a_{12}a_{21}. \tag{1.4.4}$$

对于 3×3 方阵：

$$\det\begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} = a_{11}\begin{vmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{vmatrix} - a_{12}\begin{vmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{vmatrix} + a_{13}\begin{vmatrix} a_{21} & a_{22} \\ a_{31} & a_{32} \end{vmatrix}, \tag{1.4.5}$$

即

$$\det \boldsymbol{A} = a_{11}a_{22}a_{33} - a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33} + a_{12}a_{31}a_{23} + a_{13}a_{21}a_{32} - a_{13}a_{22}a_{31}. \tag{1.4.6}$$

命题 1.4.1

递归定义行列式可立即得到如下性质：

1. 下三角矩阵的行列式等于对角线元素的乘积。
2. 对角矩阵的行列式等于对角线元素的乘积，特别地，单位矩阵的行列式为 1。
3. 若 $\overline{\boldsymbol{A}}$ 为矩阵 $\boldsymbol{A}$ 的共轭矩阵，则

$$\det \overline{\boldsymbol{A}} = \overline{\det \boldsymbol{A}}. \tag{1.4.7}$$

1.4.2 行列式与列向量

定理 1.4.1

行列式是每一列的线性函数，因此它是列向量集合的多重线性映射。具体来说，对于 $\boldsymbol{A}\in\mathscr{M}_{n,n}$ 的列向量 $\boldsymbol{A}_1,\ldots,\boldsymbol{A}_n$ 和标量 $\lambda\in K$，以及列向量 $\boldsymbol{B},\boldsymbol{C}$，有

$$\det(\boldsymbol{A}_1,\ldots,\boldsymbol{A}_{k-1},\lambda\boldsymbol{A}_k,\boldsymbol{A}_{k+1},\ldots,\boldsymbol{A}_n) = \lambda\det(\boldsymbol{A}_1,\ldots,\boldsymbol{A}_n), \tag{1.4.8}$$

$$\begin{aligned}\det(\boldsymbol{A}_1,\ldots,\boldsymbol{A}_{k-1},\boldsymbol{B}+\boldsymbol{C},\boldsymbol{A}_{k+1},\ldots,\boldsymbol{A}_n) &= \det(\boldsymbol{A}_1,\ldots,\boldsymbol{A}_{k-1},\boldsymbol{B},\boldsymbol{A}_{k+1},\ldots,\boldsymbol{A}_n) \\ &\quad + \det(\boldsymbol{A}_1,\ldots,\boldsymbol{A}_{k-1},\boldsymbol{C},\boldsymbol{A}_{k+1},\ldots,\boldsymbol{A}_n)\end{aligned} \tag{1.4.9}$$

由此可得以下结论：

1. 对于 $\boldsymbol{A}\in\mathscr{M}_{n,n}$，有

$$\det(\lambda\boldsymbol{A}) = \det(\lambda\boldsymbol{A}_1,\ldots,\lambda\boldsymbol{A}_n) = \lambda^n\det\boldsymbol{A}, \tag{1.4.10}$$

   因为每一列都提取一个 λ。

2. 若某一列为零列，则行列式为零：

$$\det(\boldsymbol{A}_1,\ldots,\boldsymbol{A}_{k-1},\boldsymbol{0},\boldsymbol{A}_{k+1},\ldots,\boldsymbol{A}_n) = 0, \tag{1.4.11}$$

   因为零列可视为 0 与任意列的乘积。

定理 1.4.2

设 $\boldsymbol{A} \in \mathscr{M}_{n,n}$，则有以下重要性质：

1. 若矩阵中有两列相等，则行列式为零。
2. 交换矩阵的两列，行列式变号。
3. 在某一列上加上其他列的线性组合，行列式不变。

1.4.3　行列式的基本性质

以下结果是线性系统理论的基础，本节不作证明。

定理 1.4.3

设 $\boldsymbol{A} \in \mathscr{M}_{n,n}$，则有

$$\det \boldsymbol{A} = \det \boldsymbol{A}^T. \tag{1.4.12}$$

该结果使得之前关于列向量的行列式性质可以显然地推广到行向量。具体包括：

1. 行列式是每一行的多重线性函数。
2. 若矩阵有两行相等，则行列式为零。
3. 交换矩阵的两行，行列式变号。
4. 在某一行上加上其他行的线性组合，行列式不变。

上述性质允许我们从任意一行或任意一列通过递归计算行列式：

定理 1.4.4

对 $\boldsymbol{A} \in \mathscr{M}_{n,n}$，有以下展开公式：

1. 按第 i 行展开：

$$\det \boldsymbol{A} = a_{i1}\operatorname{cof}(a_{i1}) + a_{i2}\operatorname{cof}(a_{i2}) + \cdots + a_{in}\operatorname{cof}(a_{in}), \tag{1.4.13}$$

2. 按第 j 列展开：

$$\det \boldsymbol{A} = a_{1j}\operatorname{cof}(a_{1j}) + a_{2j}\operatorname{cof}(a_{2j}) + \cdots + a_{nj}\operatorname{cof}(a_{nj}), \tag{1.4.14}$$

其中

$$\operatorname{cof}(a_{ij}) = (-1)^{i+j}\det \boldsymbol{A}_{|i,j|} \tag{1.4.15}$$

称为元素 a_{ij} 的余子式。

定理 1.4.5

设 $\boldsymbol{A} \in \mathscr{M}_{n,n}$，则

$$\boldsymbol{A}\text{ 可逆} \iff \det \boldsymbol{A} \neq 0. \tag{1.4.16}$$

定理 1.4.6

设 $\boldsymbol{A}, \boldsymbol{B} \in \mathscr{M}_{n,n}$，则

$$\det(\boldsymbol{AB}) = \det \boldsymbol{A} \det \boldsymbol{B}. \tag{1.4.17}$$

由此可得，如果矩阵可逆，则

$$\det(\boldsymbol{AA}^{-1}) = \det \boldsymbol{A} \det \boldsymbol{A}^{-1} = \det \boldsymbol{I} = 1. \tag{1.4.18}$$

1.4.4 与秩相关的性质

秩的概念在后续处理最小二乘问题中非常重要。

定义 1.4.2

设 $\boldsymbol{A} \in \mathscr{M}_{m,n}$，称从 $\boldsymbol{A}$ 中选出的行与列组成的矩阵为 **提取矩阵**。具体地，给定两个索引集合

$$I = \{i_1, i_2, \ldots, i_p\} \subset \{1, 2, \ldots, m\}, \quad J = \{j_1, j_2, \ldots, j_q\} \subset \{1, 2, \ldots, n\}, \tag{1.4.19}$$

则提取矩阵 $\hat{\boldsymbol{A}} \in \mathscr{M}_{p,q}$ 的元素为

$$\hat{a}_{kl} = a_{i_k j_l}. \tag{1.4.20}$$

例如，如果

$$I = \{1, 3\}, \quad J = \{2, 3, 5\}, \quad \boldsymbol{A} = \begin{pmatrix} 1 & 7 & 5 & 6 & 8 \\ 3 & 4 & 8 & -1 & 6 \\ 7 & 5 & 4 & 3 & 2 \end{pmatrix}, \tag{1.4.21}$$

则提取矩阵为

$$\hat{\boldsymbol{A}} = \begin{pmatrix} 7 & 5 & 8 \\ 5 & 4 & 2 \end{pmatrix}. \tag{1.4.22}$$

记号 1.4.1

基于提取矩阵的概念，可以定义分块矩阵，例如：

$$\boldsymbol{A} = \begin{pmatrix} \boldsymbol{A}_{11} & \boldsymbol{A}_{12} \\ r\boldsymbol{A}_{21} & \boldsymbol{A}_{22} \end{pmatrix}, \tag{1.4.23}$$

其中 $\boldsymbol{A}_{ij} \in \mathscr{M}_{m_i,n_j}$，因此 $\boldsymbol{A} \in \mathscr{M}_{m,n}$，且 $m = m_1 + m_2$，$n = n_1 + n_2$。

定理 1.4.7

设 $\boldsymbol{A} \in \mathscr{M}_{m,n}$，则 $\boldsymbol{A}$ 的秩是存在可逆方阵提取矩阵 $\hat{\boldsymbol{A}} \in \mathscr{M}_{r,r}$ 的最大整数 r。

此定理有时用于确定矩阵的秩，但更常用的是：如果已知 $\boldsymbol{A}$ 的秩为 r，则可以从 $\boldsymbol{A}$ 中提取一个 $r \times r$ 的可逆矩阵。它也可用于证明下述命题。

命题 1.4.2

对任意 $\boldsymbol{A} \in \mathscr{M}_{m,n}$，有

$$\operatorname{rang}(\boldsymbol{A}) = \operatorname{rang}(\boldsymbol{A}^T). \tag{1.4.24}$$

证明. 若 $\hat{\boldsymbol{A}}$ 是 $\boldsymbol{A}$ 的可逆方阵提取矩阵，则 $\hat{\boldsymbol{A}}^T$ 是 $\boldsymbol{A}^T$ 的可逆方阵提取矩阵，从而命题成立。 □

由此可以通过矩阵的秩来刻画矩阵的可逆性：

命题 1.4.3

设 $\boldsymbol{A} \in \mathscr{M}_{n,n}$，则下列条件等价：

$$\boldsymbol{A} \text{ 可逆} \iff \det \boldsymbol{A} \neq 0 \iff \ker \boldsymbol{A} = \{0\} \iff \operatorname{rang} \boldsymbol{A} = n. \tag{1.4.25}$$

1.5　线性方程组

1.5.1　方阵线性方程组

在求解线性系统时，通常记未知向量为 $\boldsymbol{x}$（其分量为 $x_1, \ldots, x_n$），右端向量为 $\boldsymbol{b}$（其分量为 $b_1, \ldots, b_n$）。由矩阵的像空间定义可知，对于 $\boldsymbol{A} \in \mathscr{M}_{n,n}$，方程组

$$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b} \tag{1.5.1}$$

有解当且仅当 $b \in \operatorname{Im} \boldsymbol{A}$。然而这个理论结果在实际中难以验证。下面的定理则非常关键。

定理 1.5.1

设 $\boldsymbol{A} \in \mathscr{M}_{n,n}$，方程组 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 有唯一解当且仅当

$$\det \boldsymbol{A} \neq 0. \tag{1.5.2}$$

证明. 如果 $\det \boldsymbol{A} \neq 0$，则 $\boldsymbol{A}$ 可逆，唯一解为

$$\boldsymbol{x} = \boldsymbol{A}^{-1}\boldsymbol{b}. \tag{1.5.3}$$

反之，如果 $\det \boldsymbol{A} = 0$，$\boldsymbol{A}$ 不可逆，且 $\ker \boldsymbol{A} \neq \{0\}$。因此存在非零向量 $\boldsymbol{x}^*$ 满足 $\boldsymbol{A}\boldsymbol{x}^* = \boldsymbol{0}$，方程组 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 不可能有唯一解，因为若 $\boldsymbol{x}$ 是解，则 $\boldsymbol{x} + \boldsymbol{x}^*$ 也是解。 □

下面给出所谓的 **Cramer 公式**的“理论解法”：

定理 1.5.2

设 $\boldsymbol{A} \in \mathscr{M}_{n,n}$，方程组 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 的解可用 Cramer 公式表示：对每个 $j = 1, 2, \ldots, n$，有

$$\det(\boldsymbol{A}_1, \boldsymbol{A}_2, \ldots, \boldsymbol{A}_{j-1}, \boldsymbol{b}, \boldsymbol{A}_{j+1}, \ldots, \boldsymbol{A}_n) = x_j \det \boldsymbol{A}, \tag{1.5.4}$$

其中 $\boldsymbol{A}_i$ 表示矩阵 $\boldsymbol{A}$ 的第 i 列。

定理 1.5.3

矩阵 $\boldsymbol{A}$ 的逆矩阵由下式给出：

$$\boldsymbol{A}^{-1} = \frac{1}{\det \boldsymbol{A}} \big(\operatorname{co}(\boldsymbol{A})\big)^T, \tag{1.5.5}$$

其中

$$\operatorname{co}(\boldsymbol{A})_{ij} = \operatorname{cof}(a_{ij}) = (-1)^{i+j} \det \boldsymbol{A}_{|i,j|}, \tag{1.5.6}$$

$\operatorname{co}(\boldsymbol{A})$ 称为 $\boldsymbol{A}$ 的余子式矩阵。

注意：在实际数值计算中，Cramer 公式通常不用于求逆矩阵，而更经济的方法是数值方法；Cramer 公式更多用于形式化计算。

1.5.2 任意维度的线性方程组

我们考虑一个由 n 个方程、p 个未知数组成的线性方程组：

$$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}, \quad \boldsymbol{x} \in \mathscr{M}_{p,1},\ \boldsymbol{b} \in \mathscr{M}_{n,1}, \quad \boldsymbol{A} \in \mathscr{M}_{n,p}. \tag{1.5.7}$$

齐次系统 ($b = 0$) 当 $\boldsymbol{b} = \boldsymbol{0}$ 时，方程组称为齐次方程组。此时我们需要寻找满足

$$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{0} \tag{1.5.8}$$

的向量 $\boldsymbol{x}$，即求矩阵 $\boldsymbol{A}$ 的核 $\ker \boldsymbol{A}$。显然，零向量 $\boldsymbol{0}$ 总是解。实际求解通常使用 ***Gauss* 消元法**（见本章习题）。

例 1.5.1: 齐次系统示例

虑方程组：

$$\begin{cases} x_1 + x_2 + x_3 = 0, \\ x_1 + 2x_2 - x_3 = 0, \\ x_1 + 3x_3 = 0, \\ 2x_1 + x_2 + 4x_3 = 0. \end{cases} \tag{1.5.9}$$

经过消元，得到等价系统：

$$\begin{cases} x_1 + x_2 + x_3 = 0, \\ x_2 - 2x_3 = 0, \\ \text{其余方程与上面相同。} \end{cases} \tag{1.5.10}$$

解得

$$x_2 = 2x_3, \quad x_1 = -3x_3, \quad x = x_3 \begin{pmatrix} -3 \\ 2 \\ 1 \end{pmatrix}. \tag{1.5.11}$$

因此，$\ker \boldsymbol{A}$ 的维度为 1，从而系统的秩为 $3-1=2$。

非齐次系统 ($b \neq 0$)　当 $b \neq 0$ 时，方程组称为非齐次方程组。此时可能不存在显而易见的解。方法仍然是使用 *Gauss* 消元法求解 $\boldsymbol{Ax}=\boldsymbol{b}$，并检查是否出现矛盾方程。

例 1.5.2: 非齐次系统示例

考虑方程组：

$$\begin{cases} x_1+x_2+x_3=1, \\ x_1+2x_2-x_3=-1, \\ x_1+3x_3=3, \\ 2x_1+x_2+4x_3=4. \end{cases} \tag{1.5.12}$$

经过消元，得到等价系统：

$$\begin{cases} x_1+x_2+x_3=1, \\ x_2-2x_3=-2, \\ \text{其余方程与上面相同。} \end{cases} \tag{1.5.13}$$

解得：

$$x_2=2x_3-2, \quad x_1=-3x_3+3, \quad x=x_3\begin{pmatrix}-3\\2\\1\end{pmatrix}+\begin{pmatrix}3\\-2\\0\end{pmatrix}. \tag{1.5.14}$$

可见，非齐次系统的解可表示为 **齐次解**与**特解**的和。

无解情况　方程组

$$\begin{cases} x_1+x_2+x_3=1, \\ x_1+2x_2-x_3=-1, \\ x_1+3x_3=3, \\ 2x_1+x_2+4x_3=2 \end{cases} \tag{1.5.15}$$

无解（参见本章习题）。

1.6　特征值

1.6.1 特征值

定义 1.6.1

设 $\boldsymbol{A} \in \mathscr{M}_{n,n}$。如果存在非零向量 $\boldsymbol{Y} \in \mathscr{M}_{n,1}$ 和标量 $\lambda \in K$ 使得

$$\boldsymbol{A}\boldsymbol{Y} = \lambda \boldsymbol{Y}, \tag{1.6.1}$$

则称 λ 为 $\boldsymbol{A}$ 的**特征值**，并称 $\boldsymbol{Y}$ 为与 λ 对应的**特征向量**，$(\lambda, \boldsymbol{Y})$ 称为 $\boldsymbol{A}$ 的**特征对**。

定义 1.6.2

$\boldsymbol{A}$ 的**特征多项式**定义为：

$$\Pi_{\boldsymbol{A}}(s) = \det(s\boldsymbol{I} - \boldsymbol{A}), \tag{1.6.2}$$

其中 $\boldsymbol{I}$ 为 $n \times n$ 单位矩阵。

命题 1.6.1

λ 是 $\boldsymbol{A}$ 的特征值的一个必要且充分条件是 λ 为特征多项式的根，即：

$$\det(\lambda \boldsymbol{I} - \boldsymbol{A}) = 0. \tag{1.6.3}$$

证明. 根据定义，λ 是 $\boldsymbol{A}$ 的特征值当且仅当存在非零向量 $\boldsymbol{Y}$ 满足

$$(\lambda \boldsymbol{I} - \boldsymbol{A})\boldsymbol{Y} = \boldsymbol{0}.$$

这等价于 $(\lambda \boldsymbol{I} - \boldsymbol{A})$ 不可逆，即

$$\det(\lambda \boldsymbol{I} - \boldsymbol{A}) = 0.$$

□

实用性质：

- 三角矩阵的特征值是其对角线元素。
- $\boldsymbol{A}$ 不可逆 $\iff$ 0 是 $\boldsymbol{A}$ 的特征值。
- $\boldsymbol{A}$ 与 $\boldsymbol{A}^T$ 具有相同的特征值，但特征向量可能不同。

命题 1.6.2

任意 $\boldsymbol{A} \in \mathscr{M}_{n,n}$ 都有 n 个复特征值（计重）。设其特征值为 $\lambda_1, \ldots, \lambda_n$（可能重复），则有：

$$\operatorname{trace}(\boldsymbol{A}) = \sum_{i=1}^{n} \lambda_i, \quad \det \boldsymbol{A} = \prod_{i=1}^{n} \lambda_i. \tag{1.6.4}$$

1.6.2　特征值与相似矩阵

定义 1.6.3

设 $\boldsymbol{A}, \boldsymbol{B} \in \mathscr{M}_{n,n}$。如果存在可逆矩阵 $\boldsymbol{P} \in \mathscr{M}_{n,n}$ 使得

$$\boldsymbol{B} = \boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}, \tag{1.6.5}$$

则称 $\boldsymbol{A}$ 与 $\boldsymbol{B}$ **相似**。

显然，相似矩阵具有相同的行列式。但反之不成立：即行列式相同的两矩阵不一定相似。

命题 1.6.3

相似矩阵具有相同的特征多项式，因此具有相同的特征值。

证明. 若 $\boldsymbol{A}$ 与 $\boldsymbol{B}$ 相似，则

$$s\boldsymbol{I} - \boldsymbol{B} = s\boldsymbol{I} - \boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P} = \boldsymbol{P}^{-1}(s\boldsymbol{I} - \boldsymbol{A})\boldsymbol{P}.$$

因此

$$\det(s\boldsymbol{I} - \boldsymbol{B}) = \det(\boldsymbol{P}^{-1}(s\boldsymbol{I} - \boldsymbol{A})\boldsymbol{P}) = \det(\boldsymbol{P}^{-1})\det(s\boldsymbol{I} - \boldsymbol{A})\det(\boldsymbol{P}) = \det(s\boldsymbol{I} - \boldsymbol{A}),$$

即 $\Pi_{\boldsymbol{A}} = \Pi_{\boldsymbol{B}}$。 □

注意： 相似矩阵具有相同的特征值，但特征向量一般不同。不过可以建立两者之间的关系：如果 $(\lambda, \boldsymbol{Y})$ 是 $\boldsymbol{A}$ 的特征对，则

$$\boldsymbol{A}\boldsymbol{Y} = \lambda\boldsymbol{Y} \implies \boldsymbol{P}\boldsymbol{B}\boldsymbol{P}^{-1}\boldsymbol{Y} = \lambda\boldsymbol{Y} \implies \boldsymbol{B}(\boldsymbol{P}^{-1}\boldsymbol{Y}) = \lambda(\boldsymbol{P}^{-1}\boldsymbol{Y}).$$

因此

$$\boldsymbol{Z} = \boldsymbol{P}^{-1}\boldsymbol{Y}$$

是 $\boldsymbol{B}$ 的特征向量，对应特征值 λ（这也提供了另一个证明前一命题的方法）。

补充说明： *Gauss* 消元法可以将方程组 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 转化为等价方程组 $\boldsymbol{U}\boldsymbol{x} = \boldsymbol{c}$，其中 $\boldsymbol{U}$ 为上三角矩阵并且两方程组有相同解。但一般情况下 $\boldsymbol{A}$ 与 $\boldsymbol{U}$ 不相似，因此 *Gauss* 消元法不能直接用于计算 $\boldsymbol{A}$ 的特征值。

1.6.3　矩阵的对角化

特征值与相似矩阵　在很多情况下，我们习惯只考虑实系数矩阵，但它们只是复系数矩阵的特例。本节旨在讨论在何种情况下可以找到与给定矩阵 $\boldsymbol{A}$ 相似的对角矩阵 $\boldsymbol{D}$。矩阵 $\boldsymbol{D}$ 的对角元素即为 $\boldsymbol{A}$ 的特征值，这些特征值在物理学的许多应用中具有重要意义，即使它们可能是复数。

定义 1.6.4

矩阵 $\boldsymbol{A} \in \mathscr{M}_{n,n}$ 如果存在与之相似的对角矩阵 $\boldsymbol{D} \in \mathscr{M}_{n,n}(\mathbb{R})$（实对角化）或 $\boldsymbol{D} \in \mathscr{M}_{n,n}(\mathbb{C})$（复对角化），则称 $\boldsymbol{A}$ 可对角化。

由于 $\boldsymbol{A}$ 与 $\boldsymbol{D}$ 相似，因此存在可逆矩阵 $\boldsymbol{P}$ 使得

$$\boldsymbol{D} = \boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P} \quad \Longleftrightarrow \quad \boldsymbol{A}\boldsymbol{P} = \boldsymbol{P}\boldsymbol{D},$$

这等价于

$$\boldsymbol{A}\boldsymbol{Y}_i = \lambda_i \boldsymbol{Y}_i, \quad i = 1, \ldots, n,$$

其中 $\boldsymbol{Y}_1, \ldots, \boldsymbol{Y}_n$ 为矩阵 $\boldsymbol{P}$ 的列向量，$\lambda_1, \ldots, \lambda_n$ 为对角矩阵 $\boldsymbol{D}$ 的对角元素。因此，$\boldsymbol{D}$ 的对角线由 $\boldsymbol{A}$ 的特征值构成，而 $\boldsymbol{P}$ 的列向量是对应的特征向量。

重要结论（对称矩阵的实对角化） 以下结论在理论上非常有用，但证明较为复杂，可参考 MT23 第 5 章：

定理 1.6.1

设 $\boldsymbol{A} \in \mathscr{M}_{n,n}(\mathbb{R})$ 为对称矩阵，则：

1. $\boldsymbol{A}$ 的所有特征值都是实数；
2. 存在 $\mathbb{R}^n$ 的一个正交基由 $\boldsymbol{A}$ 的特征向量构成（使用 $\mathbb{R}^n$ 的标准内积）；
3. $\boldsymbol{A}$ 在 $\mathbb{R}$ 上可对角化。更具体地，存在一个正交矩阵 $\boldsymbol{P}$ 使得

$$\boldsymbol{D} = \boldsymbol{P}^T\boldsymbol{A}\boldsymbol{P}$$

为对角矩阵。

回顾概念：

- $\mathbb{R}^n$ 的标准内积定义为

$$\boldsymbol{x}^T\boldsymbol{y} = \sum_{i=1}^{n} x_i y_i,$$

对应的欧几里得范数为

$$\|\boldsymbol{x}\| = \sqrt{\boldsymbol{x}^T\boldsymbol{x}} = \sqrt{\sum_{i=1}^{n} x_i^2}.$$

- 若两个向量内积为零，则它们正交。
- 向量组构成正交规范基（orthonormal basis）需满足：两两正交且每个向量的范数为 1。
- 矩阵 $\boldsymbol{Q} \in \mathscr{M}_{n,n}(\mathbb{R})$ 称为正交矩阵，当且仅当 $\boldsymbol{Q}^T\boldsymbol{Q} = \boldsymbol{I}$。
- 若 $\boldsymbol{Q}$ 为正交矩阵，则其列向量 $\boldsymbol{Q}_i$ 构成 $\mathbb{R}^n$ 的正交规范基（正交矩阵的概念将在最小二乘法章节再次使用）。

1.6.4　特征值与正定矩阵

定义 1.6.5

称对称矩阵 $\boldsymbol{A} \in \mathscr{M}_{n,n}(\mathbb{R})$ 为半正定（semi-définie positive），如果对任意向量 $\boldsymbol{x} \in \mathbb{R}^n$ 有

$$\boldsymbol{x}^T \boldsymbol{A} \boldsymbol{x} \geq 0.$$

若进一步满足

$$\boldsymbol{x}^T \boldsymbol{A} \boldsymbol{x} = 0 \implies \boldsymbol{x} = \boldsymbol{0},$$

则称 $\boldsymbol{A}$ 为正定（définie positive）。

如果 $\boldsymbol{B} \in \mathscr{M}_{m,n}(\mathbb{R})$，则矩阵 $\boldsymbol{B}\boldsymbol{B}^T \in \mathscr{M}_{m,m}(\mathbb{R})$ 和 $\boldsymbol{B}^T\boldsymbol{B} \in \mathscr{M}_{n,n}(\mathbb{R})$ 都是对称矩阵。

命题 1.6.4

设 $\boldsymbol{B} \in \mathscr{M}_{m,n}(\mathbb{R})$，则：

1. $\boldsymbol{B}^T\boldsymbol{B}$ 是半正定的；
2. 若 $n \leq m$ 且 $\boldsymbol{B}$ 的秩为 n，则 $\boldsymbol{B}^T\boldsymbol{B}$ 是正定的。

证明留作练习。

命题 1.6.5

设 $\boldsymbol{A} \in \mathscr{M}_{n,n}(\mathbb{R})$ 为对称矩阵。则：

- $\boldsymbol{A}$ 正定 $\iff$ $\boldsymbol{A}$ 的所有特征值严格大于 0；
- $\boldsymbol{A}$ 半正定 $\iff$ $\boldsymbol{A}$ 的所有特征值非负。

证明. 我们分两步证明：

- 正定（或半正定）$\implies$ 特征值正（或非负）：设 $(\lambda, \boldsymbol{Y})$ 是 $\boldsymbol{A}$ 的特征对，则

  $$\boldsymbol{A}\boldsymbol{Y} = \lambda \boldsymbol{Y} \implies \boldsymbol{Y}^T\boldsymbol{A}\boldsymbol{Y} = \lambda \boldsymbol{Y}^T\boldsymbol{Y}.$$

  由于 $\boldsymbol{Y} \neq \boldsymbol{0}$，有 $\boldsymbol{Y}^T\boldsymbol{A}\boldsymbol{Y} > 0$（或 ≥ 0），且 $\boldsymbol{Y}^T\boldsymbol{Y} > 0$，从而得到 $\lambda > 0$（或 $\lambda \geq 0$）。
- 特征值正（或非负）$\implies$ 正定（或半正定）：设 $\boldsymbol{A}$ 的特征向量构成正交规范基 $\{\boldsymbol{Y}_1, \ldots, \boldsymbol{Y}_n\}$，任意向量 $\boldsymbol{x} \in \mathbb{R}^n$ 可写为

  $$\boldsymbol{x} = \sum_{i=1}^n \alpha_i \boldsymbol{Y}_i \implies \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x} = \sum_{i=1}^n \alpha_i^2 \lambda_i \geq 0.$$

  若所有 $\lambda_i > 0$，则 $\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x} = 0 \implies \alpha_i = 0 \implies \boldsymbol{x} = \boldsymbol{0}$。

□

结论： 对称正定矩阵不存在零特征值，因此它必然是可逆的。

Chapter 2

线性方程组的求解

2.1　研究背景

2.1.1　热传导方程

在开始研究之前，我们先来看一个简单的例子，该例子表明我们会遇到求解**大型线性方程组**的需求。本例题为一维**稳态热传导方程**的求解问题：

$$\begin{cases} -\dfrac{\mathrm{d}^2 u}{\mathrm{d}x^2}(x) = f(x), \quad x \in (0,1), \\ u(0) = 0, \\ u(1) = 0. \end{cases} \tag{2.1.1}$$

我们可将 $u(x)$ 理解为**长度为 1 的细杆**的温度分布（细杆的所有物理常数均已做归一化处理），细杆内部由热流 $f(x)$ 提供热源，细杆的两端始终保持零度。在某些特殊情况下，我们可以求得该方程的精确解；当已知函数 f 的一个**二阶原函数**时，就属于这类可求精确解的情况。在一般情况下，我们可以在若干个点 (x_k)（$k = 0, \ldots, N$）处求解 $u(x)$ 的近似值。为简化计算，我们选取**等距点** x_k，因此步长 $h = \dfrac{1}{N}$，且满足 $x_k = kh$。

在点 x_k 处，原方程可改写为：

$$\begin{cases} -\dfrac{\mathrm{d}^2 u}{\mathrm{d}x^2}(x_k) = f(x_k), \quad k = 1, \ldots, N-1, \\ u(x_0) = 0, \\ u(x_N) = 0. \end{cases} \tag{2.1.2}$$

由该方程可知，函数 u 在区间 $[0,1]$ 的**边界点**处的取值是已知的。方程中出现的导数将通过**仅利用网格点** (x_k) **处的** u **值**的公式进行近似计算。我们可以利用下述经典公式对 u 的二阶导数做近似：

$$\frac{\mathrm{d}^2 u}{\mathrm{d}x^2}(x_k) = \frac{u(x_{k-1}) - 2u(x_k) + u(x_{k+1})}{h^2} + \mathscr{O}(h^2). \tag{2.1.3}$$

若我们忽略余项 $\mathscr{O}(h^2)$（可以认为，当区间的**剖分数** N 足够大时，这一近似方式是合理的），

则可通过建立下述方程组得到近似值 $v_k \approx u(x_k)$：

$$\begin{cases} -\dfrac{v_{k-1}-2v_k+v_{k+1}}{h^2} = f(x_k), \quad k=1,\dots,N-1, \\ v_0 = 0, \\ v_N = 0, \end{cases} \tag{2.1.4}$$

该方程组可进一步化为下述**矩阵形式**：

$$\frac{1}{h^2}\begin{pmatrix} 2 & -1 & & 0 \\ -1 & 2 & -1 & \\ & \vdots & \vdots & \vdots \\ & -1 & 2 & -1 \\ 0 & & -1 & 2 \end{pmatrix}\begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_{N-2} \\ v_{N-1} \end{pmatrix} = \begin{pmatrix} f(x_1) \\ f(x_2) \\ \vdots \\ f(x_{N-2}) \\ f(x_{N-1}) \end{pmatrix}, \tag{2.1.5}$$

且满足边界条件 $v_0 = v_N = 0$。

由此便得到一个物理问题的实例，其近似求解最终归结为求解一个线性方程组（本例中方程组的系数矩阵具有十分特殊的形式：它是一个**三对角矩阵**）。接下来我们将介绍求解线性方程组的各类「合理」方法，此处的「合理」指的是这些方法能够很容易地在计算机上实现。

2.2 Guass 消元法

2.2.1 三角方程组的求解

在后续所有内容中，我们考虑一个矩阵 $\boldsymbol{A} \in \mathscr{M}_{n,n}(\mathbb{R})$，并假设该矩阵可逆。我们需要求解线性方程组

$$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}, \tag{2.2.1}$$

其中 $\boldsymbol{b} \in \mathbb{R}^n$ 为已知向量。一种容易处理的情形是 $\boldsymbol{A}$ 为下三角矩阵（为明确概念起见）：此时满足

$$a_{ij} = 0, \text{ 对任意} j > i. \tag{2.2.2}$$

此外，由于 $\boldsymbol{A}$ 可逆，必然有 $a_{ii} \neq 0$ 对所有 i 成立。求解方法十分直接：

$$x_1 = \frac{b_1}{a_{11}}, \tag{2.2.3}$$

随后有

$$a_{21}x_1 + a_{22}x_2 = b_2 \implies x_2 = \frac{1}{a_{22}}\left(b_2 - a_{21}x_1\right). \tag{2.2.4}$$

因此我们可以写出一般公式：

$$x_i = \frac{1}{a_{ii}}\left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j\right), \text{ 对} i = 2,3,\dots,n. \tag{2.2.5}$$

由此我们可以按照自然顺序得到未知量的取值。

当矩阵 $\boldsymbol{A}$ 为上三角矩阵时，未知量的计算公式为

$$\begin{cases} x_n = \dfrac{b_n}{a_{nn}}, \\ \\ x_i = \dfrac{1}{a_{ii}}\left(b_i - \displaystyle\sum_{j=i+1}^{n} a_{ij}x_j\right), \quad 对 i = n-1, n-2, \ldots, 1. \end{cases} \tag{2.2.6}$$

需要注意的是，在后一种情形下，我们按照指标递减的顺序得到未知量的取值。

2.2.2　*Gauss* 消元法的原理与第一步

Gauss 消元法的原理在于将线性方程组 $\boldsymbol{Ax} = \boldsymbol{b}$ 转化为如下形式：

$$\hat{\boldsymbol{A}}\boldsymbol{x} = \hat{\boldsymbol{b}}, \tag{2.2.7}$$

其中矩阵 $\hat{\boldsymbol{A}}$ 为上三角矩阵，该新方程组的求解相对简单，正如我们刚才所看到的那样。

注意！ 矩阵 $\hat{\boldsymbol{A}}$ 与 $\boldsymbol{A}$ 并不相似。换言之，不应认为矩阵 $\boldsymbol{A}$ 与 $\hat{\boldsymbol{A}}$ 具有相同的特征值。这很遗憾，因为 $\hat{\boldsymbol{A}}$ 的特征值就是其对角线元素。关于这一点，需要指出的是，对于秩大于 5 的矩阵，不可能通过有限步计算得到其特征值。

方程组 (2.2.7) 与原始方程组 (2.2.1) 仅仅是等价的，该方法通过逐次消去方程之间的未知量来实现。

首先，我们消除第一个未知量，即 x_1：从

$$\boldsymbol{A}^{(1)} = \boldsymbol{A} = \begin{pmatrix} a_{11} & a_{12} & \ldots & a_{1j} & \ldots & a_{1n} \\ a_{21} & a_{22} & \ldots & a_{2j} & \ldots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots & & \vdots \\ a_{i1} & a_{i2} & \ldots & a_{ij} & \ldots & a_{in} \\ \vdots & \vdots & & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \ldots & a_{nj} & \ldots & a_{nn} \end{pmatrix}, \quad \boldsymbol{b}^{(1)} = \boldsymbol{b} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_i \\ \vdots \\ b_n \end{pmatrix} \tag{2.2.8}$$

出发。

我们可以通过从 $\boldsymbol{A}$ 的第二行减去第一行乘以系数 $\dfrac{a_{21}}{a_{11}}$ 来消除前两个方程之间的未知量 x_1，前提是 a_{11} 非零，我们暂时假设这一条件成立。这导致将

$$a_{2j}^{(1)} = a_{2j} \quad \longrightarrow \quad a_{2j}^{(2)} = a_{2j} - \frac{a_{21}}{a_{11}}a_{1j}, \quad 对 j = 1, 2, \ldots, n \tag{2.2.9}$$

以及相应地

$$b_2^{(1)} = b_2 \quad \longrightarrow \quad b_2^{(2)} = b_2 - \frac{a_{21}}{a_{11}}b_1. \tag{2.2.10}$$

矩阵和系统右端项向量变为如下形式：

$$\begin{pmatrix} a_{11} & a_{12} & \dots & a_{1j} & \dots & a_{1n} \\ 0 & a_{22}^{(2)} & \dots & a_{2j}^{(2)} & \dots & a_{2n}^{(2)} \\ \vdots & \vdots & \ddots & \vdots & & \vdots \\ a_{i1} & a_{i2} & \dots & a_{ij} & \dots & a_{in} \\ \vdots & \vdots & & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nj} & \dots & a_{nn} \end{pmatrix}, \quad \begin{pmatrix} b_1 \\ b_2^{(2)} \\ \vdots \\ b_i \\ \vdots \\ b_n \end{pmatrix}, \tag{2.2.11}$$

其中注意到系数 $a_{21}^{(2)}$ 为零（我们正是为此目的而进行上述操作），这意味着未知量 x_1 不再出现在系统的第二个方程中。

我们可以对第三行重复此操作，从第三行减去第一行乘以系数 $\dfrac{a_{31}}{a_{11}}$，依此类推。对于第 i 行，得到如下公式：

$$\begin{cases} a_{ij}^{(1)} = a_{ij} \quad \longrightarrow \quad a_{ij}^{(2)} = a_{ij} - \dfrac{a_{i1}}{a_{11}} a_{1j}, \quad 对 j = 1, 2, \dots, n, \\ b_i^{(1)} = b_i \quad \longrightarrow \quad b_i^{(2)} = b_i - \dfrac{a_{i1}}{a_{11}} b_1. \end{cases} \tag{2.2.12}$$

当对所有行完成消元后，我们得到一个形如 $\boldsymbol{A}^{(2)}\boldsymbol{x} = \boldsymbol{b}^{(2)}$ 的线性方程组，其中

$$\boldsymbol{A}^{(2)} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1j} & \dots & a_{1n} \\ 0 & a_{22}^{(2)} & \dots & a_{2j}^{(2)} & \dots & a_{2n}^{(2)} \\ \vdots & \vdots & \ddots & \vdots & & \vdots \\ 0 & a_{i2}^{(2)} & \dots & a_{ij}^{(2)} & \dots & a_{in}^{(2)} \\ \vdots & \vdots & & \vdots & \ddots & \vdots \\ 0 & a_{n2}^{(2)} & \dots & a_{nj}^{(2)} & \dots & a_{nn}^{(2)} \end{pmatrix}, \quad \boldsymbol{b}^{(2)} = \begin{pmatrix} b_1 \\ b_2^{(2)} \\ \vdots \\ b_i^{(2)} \\ \vdots \\ b_n^{(2)} \end{pmatrix}. \tag{2.2.13}$$

我们称刚刚完成了 *Gauss* 消元法的**第一步**，这一步的作用是在第一列对角线下方产生零元素。

2.2.3 第二步

第二步在于消除第 3、4、…、n 个方程中的第二个未知量 x_2。为此，我们从第三行开始，现在假设 $a_{22}^{(2)}$ 非零。这导致如下公式：

$$\begin{cases} a_{3j}^{(2)} \quad \longrightarrow \quad a_{3j}^{(3)} = a_{3j}^{(2)} - \dfrac{a_{32}^{(2)}}{a_{22}^{(2)}} a_{2j}^{(2)}, \quad 对 j = 2, 3, \dots, n, \\ \\ b_3^{(2)} \quad \longrightarrow \quad b_3^{(3)} = b_3^{(2)} - \dfrac{a_{32}^{(2)}}{a_{22}^{(2)}} b_2^{(2)}. \end{cases} \tag{2.2.14}$$

对于第 i 行（$i = 3, \dots, n$），公式可写为：

$$\begin{cases} a_{ij}^{(2)} \quad \longrightarrow \quad a_{ij}^{(3)} = a_{ij}^{(2)} - \dfrac{a_{i2}^{(2)}}{a_{22}^{(2)}} a_{2j}^{(2)}, \quad 对 j = 2, 3, \dots, n, \\ \\ b_i^{(2)} \quad \longrightarrow \quad b_i^{(3)} = b_i^{(2)} - \dfrac{a_{i2}^{(2)}}{a_{22}^{(2)}} b_2^{(2)}. \end{cases} \tag{2.2.15}$$

当计算进行到第 n 行后，我们得到一个形如 $\boldsymbol{A}^{(3)}\boldsymbol{x}=\boldsymbol{b}^{(3)}$ 的方程组，其中

$$\boldsymbol{A}^{(3)}=\begin{pmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1j} & \dots & a_{1n} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \dots & a_{2j}^{(2)} & \dots & a_{2n}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \dots & a_{3j}^{(3)} & \dots & a_{3n}^{(3)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & & \vdots \\ 0 & 0 & a_{n3}^{(3)} & \dots & a_{nj}^{(3)} & \dots & a_{nn}^{(3)} \end{pmatrix}, \quad \boldsymbol{b}^{(3)}=\begin{pmatrix} b_1 \\ b_2^{(2)} \\ b_3^{(3)} \\ \vdots \\ b_n^{(3)} \end{pmatrix}. \tag{2.2.16}$$

2.2.4　一般步骤

现在我们可以定义一般算法。假设我们已经完成了 *Gauss* 消元法的 $k-1$ 步，得到一个形如 $\boldsymbol{A}^{(k)}\boldsymbol{x}=\boldsymbol{b}^{(k)}$ 的方程组，其中 $\boldsymbol{A}^{(k)}$ 和 $\boldsymbol{b}^{(k)}$ 由下式给出：

$$\boldsymbol{A}^{(k)}=\begin{pmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1k} & \dots & a_{1n} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \dots & a_{2k}^{(2)} & \dots & a_{2n}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \dots & a_{3k}^{(3)} & \dots & a_{3n}^{(3)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & & \vdots \\ 0 & 0 & 0 & \dots & a_{kk}^{(k)} & \dots & a_{kn}^{(k)} \\ \vdots & \vdots & \vdots & & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & a_{nk}^{(k)} & \dots & a_{nn}^{(k)} \end{pmatrix}, \quad \boldsymbol{b}^{(k)}=\begin{pmatrix} b_1 \\ b_2^{(2)} \\ b_3^{(3)} \\ \vdots \\ b_k^{(k)} \\ \vdots \\ b_n^{(k)} \end{pmatrix}. \tag{2.2.17}$$

第 k 步在于消除第 $k+1$、$k+2$、…、n 个方程中的变量 x_k。这导致如下公式，定义对 $i=k+1,k+2,\dots,n$：

$$\begin{cases} a_{ij}^{(k)} \quad\longrightarrow\quad a_{ij}^{(k+1)}=a_{ij}^{(k)}-\dfrac{a_{ik}^{(k)}}{a_{kk}^{(k)}}a_{kj}^{(k)}, \quad \text{对} j=k,k+1,\dots,n, \\ \\ b_i^{(k)} \quad\longrightarrow\quad b_i^{(k+1)}=b_i^{(k)}-\dfrac{a_{ik}^{(k)}}{a_{kk}^{(k)}}b_k^{(k)}. \end{cases} \tag{2.2.18}$$

- 可以看到，矩阵 $\boldsymbol{A}^{(k)}$ 和向量 $\boldsymbol{b}^{(k)}$ 的第 i 行一旦满足 $i\le k$，就不再被算法修改。
- 在第 k 步，我们在一个大小为 $n-k+1$ 的方阵上进行消元。
- 在步骤中对矩阵 $\boldsymbol{A}$ 所做的修改不会改变行列式的值，因为一行总是被它自身加上” 主元” 行的线性组合所替换。因此有
$$\det\boldsymbol{A}=\det\boldsymbol{A}^{(k)}, \quad \text{对} k=1,\dots,n. \tag{2.2.19}$$
- 算法在第 $k=n$ 步终止。如此得到的矩阵 $\boldsymbol{A}^{(n)}$ 就是所求的上三角矩阵 $\hat{\boldsymbol{A}}$，而 $\boldsymbol{b}^{(n)}$ 是方程组 $\hat{\boldsymbol{A}}\boldsymbol{x}=\hat{\boldsymbol{b}}$ 中的向量 $\hat{\boldsymbol{b}}$，该方程组与方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 等价。

2.2.5　*Gauss* 消元算法

从 $\boldsymbol{A}^{(1)}=\boldsymbol{A}$ 和 $\boldsymbol{b}^{(1)}=\boldsymbol{b}$ 出发，我们通过递归构造，对 $k=1,2,\dots,n$，得到矩阵 $\boldsymbol{A}^{(k)}$ 和向量 $\boldsymbol{b}^{(k)}$，使得方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 与 $\boldsymbol{A}^{(k)}\boldsymbol{x}=\boldsymbol{b}^{(k)}$ 等价，此外矩阵 $\boldsymbol{A}^{(n)}$ 是上三角矩阵。

定义 2.2.1

我们称数 $a_{kk}^{(k)}$ 为**主元**。

正如我们已经指出的，消元法的第 k 步只修改第 $k+1$ 到 n 行和列。这意味着在实际操作中，我们不需要保存 $\boldsymbol{A}^{(k)}$ 和 $\boldsymbol{b}^{(k)}$ 的不同版本。因此，我们在原始的矩阵 $\boldsymbol{A}$ 和向量 $\boldsymbol{b}$ 上工作，逐步覆盖旧项。

注意！

- 我们无法事先知道主元是否非零，实际上算法的第 k 步会修改第 $k+1$、$k+2$、…、n 行的对角项的值。
- 如果在某一步 k 有 $a_{kk}^{(k)}=0$，算法可能会停止。不幸的是，即使矩阵是正则的（可逆的），这种情况也可能发生，如下例所示：

$$\boldsymbol{A}=\begin{pmatrix}0 & 1\\ 1 & 1\end{pmatrix} \tag{2.2.20}$$

其中 $a_{11}^{(1)}=0$！通过检查这个小例子，我们看到通过交换 $\boldsymbol{A}$ 的两行，系统就变成三角形式，*Gauss* 消元法就完成了！因此，我们可以期望通过必要时交换行和/或列，总能找到一个非零主元。

算法 1 *Gauss* 消元算法

输入： 矩阵 $\boldsymbol{A}\in\mathscr{M}_{n,n}$，向量 $\boldsymbol{b}\in\mathbb{R}^n$，容差 $\varepsilon>0$

输出： 上三角矩阵 $\boldsymbol{A}$ 和修改后的向量 $\boldsymbol{b}$，或错误信息

```
for k = 1, 2, ..., n − 1 do
    if |a_kk| < ε then
        停止算法并给出错误信息
    else
        for i = k + 1, k + 2, ..., n do
            c ← a_ik / a_kk
            b_i ← b_i − c · b_k
            a_ik ← 0
            for j = k + 1, k + 2, ..., n do
                a_ij ← a_ij − c · a_kj
            end for
        end for
    end if
end for
if |a_nn| < ε then
    停止算法并给出错误信息
end if
```

2.2.6 *Gauss* 消元的矩阵表示

Gauss 消元法在于构造一系列矩阵 $\boldsymbol{A}^{(1)}$、$\boldsymbol{A}^{(2)}$、...、$\boldsymbol{A}^{(n)}$。我们要求解的系统的矩阵是三角矩阵 $\boldsymbol{A}^{(n)}$。给定指标 i，我们将用矩阵 $\boldsymbol{A}^{(n)}$ 的行来表示 $\boldsymbol{A}$ 的第 i 行。为了记号清晰，我们将矩阵 $\boldsymbol{C}$ 的第 i 行记为：$\underline{\boldsymbol{C}}_i$。

首先可以注意到，从矩阵 $\boldsymbol{A}^{(i)}$ 开始，第 i 行不再被修改，即：

$$\underline{\boldsymbol{A}}_i^{(i)} = \underline{\boldsymbol{A}}_i^{(i+1)} = \ldots = \underline{\boldsymbol{A}}_i^{(n)}. \tag{2.2.21}$$

我们依次展开矩阵 $\boldsymbol{A}^{(1)}$、$\boldsymbol{A}^{(2)}$、...的第 i 行：

$$\begin{aligned}
&\underline{\boldsymbol{A}}_i^{(1)} = \underline{\boldsymbol{A}}_i,\\
&\underline{\boldsymbol{A}}_i^{(2)} = \underline{\boldsymbol{A}}_i^{(1)} - m_{i1}\underline{\boldsymbol{A}}_1^{(1)},\ \text{其中} m_{i1} = \frac{a_{i1}^{(1)}}{a_{11}^{(1)}},\\
&\underline{\boldsymbol{A}}_i^{(3)} = \underline{\boldsymbol{A}}_i^{(2)} - m_{i2}\underline{\boldsymbol{A}}_2^{(2)},\ \text{其中} m_{i2} = \frac{a_{i2}^{(2)}}{a_{22}^{(2)}},\\
&\qquad\vdots\\
&\underline{\boldsymbol{A}}_i^{(i)} = \underline{\boldsymbol{A}}_i^{(i-1)} - m_{i,i-1}\underline{\boldsymbol{A}}_{i-1}^{(i-1)},\ \text{其中} m_{i,i-1} = \frac{a_{i,i-1}^{(i-1)}}{a_{i-1,i-1}^{(i-1)}}.
\end{aligned}$$

将前面的等式相加，得到：

$$\underline{\boldsymbol{A}}_i = m_{i1}\underline{\boldsymbol{A}}_1^{(1)} + m_{i2}\underline{\boldsymbol{A}}_2^{(2)} + \ldots + m_{i,i-1}\underline{\boldsymbol{A}}_{i-1}^{(i-1)} + \underline{\boldsymbol{A}}_i^{(i)}. \tag{2.2.22}$$

利用方程 (2.2.21)，有：

$$\underline{\boldsymbol{A}}_i = m_{i1}\underline{\boldsymbol{A}}_1^{(n)} + m_{i2}\underline{\boldsymbol{A}}_2^{(n)} + \ldots + m_{i,i-1}\underline{\boldsymbol{A}}_{i-1}^{(n)} + \underline{\boldsymbol{A}}_i^{(n)}. \tag{2.2.23}$$

如果设 $m_{ii} = 1$，$m_{ij} = 0$ 对 $j > i$，则得到：

$$\underline{\boldsymbol{A}}_i = m_{i1}\underline{\boldsymbol{A}}_1^{(n)} + \ldots + m_{i,i-1}\underline{\boldsymbol{A}}_{i-1}^{(n)} + m_{ii}\underline{\boldsymbol{A}}_i^{(n)} + m_{i,i+1}\underline{\boldsymbol{A}}_{i+1}^{(n)} + \ldots + m_{in}\underline{\boldsymbol{A}}_n^{(n)}. \tag{2.2.24}$$

利用矩阵乘法的性质，这可以写成：

$$\underline{\boldsymbol{A}}_i = (m_{i1}\ m_{i2}\ \ldots\ m_{in})\underline{\boldsymbol{A}}^{(n)}, \tag{2.2.25}$$

因此 $\boldsymbol{A} = \boldsymbol{M}\boldsymbol{A}^{(n)}$，其中 $\boldsymbol{M}$ 是由下式定义的矩阵：

$$\boldsymbol{M} = \begin{pmatrix}
1 & 0 & \ldots & \ldots & \ldots & 0\\
m_{21} & 1 & 0 & \ldots & \ldots & 0\\
m_{31} & m_{32} & 1 & 0 & \ldots & 0\\
\vdots & \vdots & \vdots & \ddots & \ddots & \vdots\\
\vdots & \vdots & \vdots & \ddots & \ddots & \vdots\\
m_{n1} & m_{n2} & \ldots & \ldots & m_{n,n-1} & 1
\end{pmatrix}. \tag{2.2.26}$$

矩阵 $\boldsymbol{M}$ 是下三角矩阵，对角线元素为 1，该矩阵通常记为 $\boldsymbol{L}$；矩阵 $\boldsymbol{A}^{(n)}$ 是上三角矩阵，通常记为 $\boldsymbol{U}$。我们刚刚写出了 $\boldsymbol{A}$ 的一个分解形式：$\boldsymbol{A}=\boldsymbol{L}\boldsymbol{U}$。

类似地，可以证明 $\boldsymbol{A}=\boldsymbol{L}^{(k-1)}\boldsymbol{A}^{(k)}$，其中

$$\boldsymbol{L}^{(k-1)}=\begin{pmatrix} 1 & 0 & \dots & \dots & \dots & \dots & 0 \\ m_{21} & 1 & 0 & \dots & \dots & \dots & 0 \\ \vdots & \vdots & \ddots & \ddots & \ddots & \ddots & \vdots \\ m_{k1} & \dots & m_{k,k-1} & 1 & 0 & \dots & 0 \\ m_{k+1,1} & \dots & m_{k+1,k-1} & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ m_{n1} & \dots & m_{n,k-1} & 0 & \dots & 0 & 1 \end{pmatrix}. \tag{2.2.27}$$

2.2.7 LU 分解的唯一性

在上一节中，我们证明了如果可以对矩阵 $\boldsymbol{A}$ 应用 *Gauss* 消元法（当主元非零时这是可能的），则矩阵 $\boldsymbol{A}$ 可以分解为一个下三角矩阵 $\boldsymbol{L}$ 和一个上三角矩阵 $\boldsymbol{U}$ 的乘积。于是我们有如下定理：

定理 2.2.1

如果在 *Gauss* 消元过程中主元非零，则存在一个下三角矩阵 $\boldsymbol{L}$ 和一个上三角矩阵 $\boldsymbol{U}$，使得

$$\boldsymbol{A}=\boldsymbol{L}\boldsymbol{U}. \tag{2.2.28}$$

此外，如果要求 $\boldsymbol{L}$ 的对角线元素等于 1，则分解是唯一的。

证明. 只需证明唯一性。设存在另一个分解：

$$\boldsymbol{A}=\tilde{\boldsymbol{L}}\tilde{\boldsymbol{U}}, \tag{2.2.29}$$

其中 $\tilde{\boldsymbol{L}}$ 的对角线元素等于 1。因此有

$$\boldsymbol{L}\boldsymbol{U}=\tilde{\boldsymbol{L}}\tilde{\boldsymbol{U}}, \tag{2.2.30}$$

由于矩阵 $\boldsymbol{L}$ 和 $\boldsymbol{U}$ 可逆，可以写成

$$\tilde{\boldsymbol{L}}^{-1}\boldsymbol{L}=\boldsymbol{U}\tilde{\boldsymbol{U}}^{-1}. \tag{2.2.31}$$

而 $\tilde{\boldsymbol{L}}^{-1}\boldsymbol{L}$ 是一个下三角矩阵，其对角线元素等于 1；$\boldsymbol{U}\tilde{\boldsymbol{U}}^{-1}$ 是一个上三角矩阵。这两个矩阵相等当且仅当，一方面它们是对角矩阵，另一方面它们的对角线元素相等（$\tilde{\boldsymbol{L}}^{-1}\boldsymbol{L}$ 的对角线元素等于 1），因此

$$\tilde{\boldsymbol{L}}^{-1}\boldsymbol{L}=\boldsymbol{U}\tilde{\boldsymbol{U}}^{-1}=\boldsymbol{I}, \tag{2.2.32}$$

从而 $\boldsymbol{L}=\tilde{\boldsymbol{L}}$ 且 $\boldsymbol{U}=\tilde{\boldsymbol{U}}$。 □

在此证明中，我们使用了关于三角矩阵的结果，这些结果在线性代数复习章节的练习中已经证明。特别地，两个下三角（或上三角）矩阵的乘积是下三角（或上三角）矩阵，下三角（或上三角）矩阵的逆是下三角（或上三角）矩阵，其对角线元素是原矩阵对角线元素的倒数。

2.3　直接计算分解 $A = LU$

2.3.1　LU 分解的动机

在某些情况下，我们需要多次求解线性方程组 $\boldsymbol{Ax} = \boldsymbol{b}$，其中矩阵 $\boldsymbol{A}$ 相同，但右端项 $\boldsymbol{b}$ 不同。此时，对不变的矩阵 $\boldsymbol{A}$ 重复进行消元操作似乎是不必要的，我们只需对右端项 $\boldsymbol{b}$ 执行这些操作。由于这些操作是线性的，我们应该能够将它们写成矩阵形式。

重新考虑方程组

$$\boldsymbol{Ax} = \boldsymbol{b}. \tag{2.3.1}$$

如果我们有一个分解 $\boldsymbol{A} = \boldsymbol{LU}$，例如在上一节中得到的分解（但我们将在下面的小节中直接计算它），则可以将 $\boldsymbol{Ax} = \boldsymbol{b}$ 重写为

$$\boldsymbol{LUx} = \boldsymbol{b}. \tag{2.3.2}$$

该方程组的解可以通过依次求解两个方程组得到：

$$\begin{cases} \boldsymbol{Ly} = \boldsymbol{b}, \\ \boldsymbol{Ux} = \boldsymbol{y}, \end{cases} \tag{2.3.3}$$

这对应于求解两个三角方程组。

行列式的计算　正如我们已经强调的，矩阵 $\boldsymbol{U}$ 与 $\boldsymbol{A}$ 并不相似，然而有

$$\det(\boldsymbol{A}) = \det(\boldsymbol{LU}) = \det(\boldsymbol{L})\det(\boldsymbol{U}) = \det(\boldsymbol{U}) = \prod_{k=1}^{n} a_{kk}^{(k)}, \tag{2.3.4}$$

这提供了一种计算 $\boldsymbol{A}$ 的行列式的经济方法（相对于按行或列展开）。例如，当 $n = 10$ 时，使用 *Gauss* 方法需要大约 10^3 次运算，而直接计算需要大约 10^7 次运算。在这种情况下，我们不需要显式地写出 $\boldsymbol{L}$，因为它的行列式先验地等于 1。

2.3.2　直接计算 LU 分解的原理

回顾 Doolittle 算法的经典表述。我们暂时忘记 *Gauss* 消元算法，直接寻找 $\boldsymbol{A}$ 的一个形如 $\boldsymbol{A} = \boldsymbol{LU}$ 的分解，其中 $\boldsymbol{L}$ 是下三角矩阵，$\boldsymbol{U}$ 是上三角矩阵。为了确保分解的唯一性，我们要求 $\boldsymbol{L}$ 的对角线为单位元（$l_{ii} = 1$，$i = 1, \ldots, n$）。

我们通过一个例子来说明，设矩阵

$$\boldsymbol{A} = \begin{pmatrix} 2 & 1 & -2 \\ 4 & 5 & -3 \\ -2 & 5 & 3 \end{pmatrix}, \tag{2.3.5}$$

我们寻找

$$\boldsymbol{L} = \begin{pmatrix} 1 & 0 & 0 \\ \times & 1 & 0 \\ \times & \times & 1 \end{pmatrix}, \quad \boldsymbol{U} = \begin{pmatrix} \times & \times & \times \\ 0 & \times & \times \\ 0 & 0 & \times \end{pmatrix} \tag{2.3.6}$$

使得 $\boldsymbol{A}=\boldsymbol{LU}$。

- 将 $\boldsymbol{A}$ 的第一行与 $\boldsymbol{LU}$ 的第一行对应，由此得到 $\boldsymbol{U}$ 的第一行：

$$\boldsymbol{LU}=\begin{pmatrix}1&0&0\\ \times&1&0\\ \times&\times&1\end{pmatrix}\begin{pmatrix}2&1&-2\\ 0&\times&\times\\ 0&0&\times\end{pmatrix}=\begin{pmatrix}2&1&-2\\ 4&5&-3\\ -2&5&3\end{pmatrix}. \tag{2.3.7}$$

- 将 $\boldsymbol{A}$ 的第一列与 $\boldsymbol{LU}$ 的第一列对应，由此得到 $\boldsymbol{L}$ 的第一列：

$$\boldsymbol{LU}=\begin{pmatrix}1&0&0\\ 2&1&0\\ -1&\times&1\end{pmatrix}\begin{pmatrix}2&1&-2\\ 0&\times&\times\\ 0&0&\times\end{pmatrix}=\begin{pmatrix}2&1&-2\\ 4&5&-3\\ -2&5&3\end{pmatrix}. \tag{2.3.8}$$

- 将 $\boldsymbol{A}$ 的第二行与 $\boldsymbol{LU}$ 的第二行对应，由此得到 $\boldsymbol{U}$ 的第二行：

$$\boldsymbol{LU}=\begin{pmatrix}1&0&0\\ 2&1&0\\ -1&\times&1\end{pmatrix}\begin{pmatrix}2&1&-2\\ 0&3&1\\ 0&0&\times\end{pmatrix}=\begin{pmatrix}2&1&-2\\ 4&5&-3\\ -2&5&3\end{pmatrix}. \tag{2.3.9}$$

- 将 $\boldsymbol{A}$ 的第二列与 $\boldsymbol{LU}$ 的第二列对应，由此得到 $\boldsymbol{L}$ 的第二列：

$$\boldsymbol{LU}=\begin{pmatrix}1&0&0\\ 2&1&0\\ -1&2&1\end{pmatrix}\begin{pmatrix}2&1&-2\\ 0&3&1\\ 0&0&\times\end{pmatrix}=\begin{pmatrix}2&1&-2\\ 4&5&-3\\ -2&5&3\end{pmatrix}. \tag{2.3.10}$$

- 将 $\boldsymbol{A}$ 的第三行与 $\boldsymbol{LU}$ 的第三行对应，由此得到 $\boldsymbol{U}$ 的第三行：

$$\boldsymbol{LU}=\begin{pmatrix}1&0&0\\ 2&1&0\\ -1&2&1\end{pmatrix}\begin{pmatrix}2&1&-2\\ 0&3&1\\ 0&0&-1\end{pmatrix}=\begin{pmatrix}2&1&-2\\ 4&5&-3\\ -2&5&3\end{pmatrix}. \tag{2.3.11}$$

另一种方法是总是显式地计算矩阵 $\boldsymbol{A}$ 的一个 LU 分解，但这次是 $\boldsymbol{U}$ 的对角线由 1 组成，而不再是 $\boldsymbol{L}$ 的对角线。这种方法在练习中见过，它导出了 Crout 算法。

2.3.3 Doolittle 算法

通过写出 $\boldsymbol{A}=\boldsymbol{LU}$ 并记住矩阵 $\boldsymbol{L}$ 和 $\boldsymbol{U}$ 是三角矩阵，且 $\boldsymbol{L}$ 的对角线元素等于 1，我们得到

$$\underline{\boldsymbol{A}}_i=\underline{\boldsymbol{L}}_i\boldsymbol{U}=\sum_{k=1}^{i-1}l_{ik}\underline{\boldsymbol{U}}_k+\underline{\boldsymbol{U}}_i \quad\Longleftrightarrow\quad \underline{\boldsymbol{U}}_i=\underline{\boldsymbol{A}}_i-\sum_{k=1}^{i-1}l_{ik}\underline{\boldsymbol{U}}_k. \tag{2.3.12}$$

我们看到，为了计算 $\boldsymbol{U}$ 的第 i 行 $\underline{\boldsymbol{U}}_i$ 的元素，我们需要预先知道 $\boldsymbol{U}$ 的第 1 到 $i-1$ 行的元素以及 $\boldsymbol{L}$ 的第 1 到 $i-1$ 列的元素。此外可以注意到，实际上我们只计算 j 在 i 到 n 之间的项 u_{ij}，因为该行的其他项已知为零。

类似地，我们有：

$$\boldsymbol{A}_i = \boldsymbol{L}\boldsymbol{U}_i = \sum_{k=1}^{i-1} u_{ki}\boldsymbol{L}_k + u_{ii}\boldsymbol{L}_i \quad \Longleftrightarrow \quad \boldsymbol{L}_i = \frac{1}{u_{ii}}\left(\boldsymbol{A}_i - \sum_{k=1}^{i-1} u_{ki}\boldsymbol{L}_k\right). \tag{2.3.13}$$

我们看到，为了计算 $\boldsymbol{L}$ 的第 i 列 $\boldsymbol{L}_i$ 的元素，我们需要预先知道 $\boldsymbol{U}$ 的第 1 到 i 行的元素以及 $\boldsymbol{L}$ 的第 1 到 $i-1$ 列的元素。此外可以注意到，实际上我们只计算 j 在 $i+1$ 到 n 之间的项 l_{ji}，因为我们已经知道 $l_{ii}=1$，且该列的其他项为零。

因此，我们将计算：

- $\boldsymbol{U}$ 的第一行，然后是 $\boldsymbol{L}$ 的第一列，
- $\boldsymbol{U}$ 的第二行，然后是 $\boldsymbol{L}$ 的第二列，…

依此类推。如果需要，该算法如下所述，必须补全矩阵 $\boldsymbol{L}$ 和 $\boldsymbol{U}$：对于 $\boldsymbol{U}$，在下三角部分填入零；对于 $\boldsymbol{L}$，在上三角部分填入零，在对角线上填入 1。

算法 2 Doolittle 算法

输入： 矩阵 $\boldsymbol{A} \in \mathscr{M}_{n,n}$

输出： 下三角矩阵 $\boldsymbol{L}$（对角线为 1）和上三角矩阵 $\boldsymbol{U}$，使得 $\boldsymbol{A} = \boldsymbol{L}\boldsymbol{U}$

```
for i = 1, 2, ..., n-1 do
    for j = i, i+1, ..., n do
        u_ij ← a_ij − Σ_{k=1}^{i-1} l_ik u_kj
    end for
    for j = i+1, i+2, ..., n do
        l_ji ← (1/u_ii) (a_ji − Σ_{k=1}^{i-1} l_jk u_ki)
    end for
end for
u_nn ← a_nn − Σ_{k=1}^{n-1} l_nk u_kn
```

2.4　带主元搜索的 LU 分解

2.4.1　分解 $A = LU$ 的可行性

到目前为止我们所做的一切都假设在任何时候都不会遇到零主元。我们将看到，存在一个简单的条件来保证这些主元非零。首先给出一个定义，它将在后续内容中用到：

定义 2.4.1

我们称矩阵 $\boldsymbol{A}$ 的 k **阶主主子矩阵**，并记为 $[\boldsymbol{A}]_k$，为矩阵

$$[\boldsymbol{A}]_k = (a_{ij})_{1\le i\le k,\, 1\le j\le k}. \tag{2.4.1}$$

我们有如下定理：

定理 2.4.1

以下三个命题是等价的：

1. **命题 1：** 所有主元 $a_{kk}^{(k)}$ 都有定义且 $a_{kk}^{(k)} \neq 0$，$k = 1, \ldots, n$。
2. **命题 2：** $\boldsymbol{A}$ 允许一个分解 $\boldsymbol{A} = \boldsymbol{LU}$，其中 $\boldsymbol{U}$ 可逆。
3. **命题 3：** $[\boldsymbol{A}]_1$、$[\boldsymbol{A}]_2$、…、$[\boldsymbol{A}]_n$ 可逆。

证明. 首先注意到前两个命题的等价性是显然的，因为当主元非零时分解是可能的，而且主元 $a_{kk}^{(k)}$ 是 $\boldsymbol{U}$ 的对角线元素。

现在证明命题 3 蕴含命题 1。

$a_{11}^{(1)} = a_{11}$ 总是有定义的，此外 $[\boldsymbol{A}]_1$ 可逆，因此

$$\det[\boldsymbol{A}]_1 = a_{11} = a_{11}^{(1)} \neq 0. \tag{2.4.2}$$

现在假设主元 $a_{ii}^{(i)}$ 对 $i = 1, \ldots, k-1$ 已定义且非零：$a_{ii}^{(i)} \neq 0$ 对 $i = 1, \ldots, k-1$。因此可以定义 $a_{kk}^{(k)}$，我们证明 $a_{kk}^{(k)} \neq 0$。

我们已经注意到，$\boldsymbol{A}$ 的行列式在 *Gauss* 消元的每一步都不被修改，更精确地说，主主子矩阵的行列式也不被修改，因为我们不进行任何行或列的置换。因此有

$$\det([\boldsymbol{A}]_k) = \det([\boldsymbol{A}^{(k)}]_k). \tag{2.4.3}$$

而主主子矩阵 $[\boldsymbol{A}^{(k)}]_k$ 是上三角矩阵，因此

$$\det([\boldsymbol{A}]_k) = \det([\boldsymbol{A}^{(k)}]_k) = \left(\prod_{i=1}^{k-1} a_{ii}^{(i)}\right) a_{kk}^{(k)}, \tag{2.4.4}$$

由于 $[\boldsymbol{A}]_k$ 可逆，其行列式非零，我们推得 $a_{kk}^{(k)} \neq 0$。因此通过归纳法证明了命题 3 蕴含命题 1。

可以证明命题 2 蕴含命题 3：

$\boldsymbol{A} = \boldsymbol{LU} \Rightarrow [\boldsymbol{A}]_k = [\boldsymbol{L}]_k[\boldsymbol{U}]_k$：请证明此结果。因此 $\det[\boldsymbol{A}]_k = 1 \times \det[\boldsymbol{U}]_k$。而 $\boldsymbol{U}$ 是可逆的上三角矩阵，因此 $\boldsymbol{U}$ 的对角线元素非零，所以 $[\boldsymbol{U}]_k$ 也是可逆的上三角矩阵，因此 $\det[\boldsymbol{A}]_k \neq 0$，所以主主子矩阵 $[\boldsymbol{A}]_k$ 可逆。 □

2.4.2 零主元-行置换

我们总是假设矩阵 $\boldsymbol{A}$ 可逆，但这次定理 2.4.2 中陈述的条件不再满足，假设我们有：

$$a_{11}^{(1)} \neq 0, \quad a_{22}^{(2)} \neq 0, \quad \ldots, \quad a_{k-1,k-1}^{(k-1)} \neq 0, \quad a_{kk}^{(k)} = 0. \tag{2.4.5}$$

因此我们可以像之前一样构造矩阵 $\boldsymbol{A}^{(k)}$：

$$\boldsymbol{A}^{(k)} = \begin{pmatrix} a_{11}^{(1)} & \times & \dots & \times & \dots & \times \\ 0 & a_{22}^{(2)} & \dots & \times & \dots & \times \\ \vdots & \vdots & \ddots & \vdots & & \vdots \\ 0 & \dots & 0 & a_{kk}^{(k)} & \dots & a_{kn}^{(k)} \\ \vdots & \vdots & & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & a_{nk}^{(k)} & \dots & a_{nn}^{(k)} \end{pmatrix}. \tag{2.4.6}$$

然而，由于 $a_{kk}^{(k)} = 0$，不可能像之前那样计算 $\boldsymbol{A}^{(k+1)}$。是否存在一个非零系数 $a_{ik}^{(k)}$，$i = k+1, \dots, n$？如果存在，由于组成线性方程组的方程的顺序不起任何作用，我们可以将第 k 行与后续行之一进行置换，当然也需要同时置换右端项。我们将得到一个新的非零系数 $a_{kk}^{(k)}$，从而可以继续。

是否存在一个非零系数 $a_{ik}^{(k)}$，$i > k$？答案是肯定的，我们来证明这一点。

如果设

$$\boldsymbol{S}_k = \begin{pmatrix} a_{kk}^{(k)} & \dots & a_{kn}^{(k)} \\ \vdots & \ddots & \vdots \\ a_{nk}^{(k)} & \dots & a_{nn}^{(k)} \end{pmatrix}, \tag{2.4.7}$$

可以容易地证明

$$\det \boldsymbol{A}^{(k)} = a_{11}^{(1)} a_{22}^{(2)} \dots a_{k-1,k-1}^{(k-1)} \det \boldsymbol{S}_k. \tag{2.4.8}$$

而 $\det \boldsymbol{A}^{(k)} = \det \boldsymbol{A} \neq 0$，因此 $\det \boldsymbol{S}_k \neq 0$，所以 $\boldsymbol{S}_k$ 的第一列不是零列，因此存在一个非零系数 $a_{ik}^{(k)}$，$i > k$。因此，在交换方程顺序的条件下，可以继续 *Gauss* 消元。

命题 2.4.1

在 Gauss 消元法的任何步骤 k，在第 k 列中至少存在一个非零元素，位于满足 $i \geq k$ 的第 i 行。

2.4.3　主元的选择。最大主元

理论上，只有当主元为零时才必须置换方程，即 $\boldsymbol{A}$ 的行。实际上，存在主元非零但希望交换行的情况，这是由于数值误差的原因（参见引用的例子）。可以证明，在消除每个未知量 x_k 时，最好寻找并选择模最大的系数 $a_{ik}^{(k)}$，其中 $k \leq i \leq n$，然后找到后置换相应的行。此外，数值实验也证实了这一数学结果。

因此，在实践中，我们总是（即使 $a_{kk}^{(k)}$ 非零）进行行交换，以便得到绝对值最大的主元：在 *Gauss* 消元的第 k 步，我们将在第 k 列中，对于行指标 i 从 k 到 n，寻找元素 $a_{lk}^{(k)}$，使得

$$\forall i \in \{k, k+1, \dots, n\}, \quad |a_{ik}^{(k)}| \leq |a_{lk}^{(k)}|, \tag{2.4.9}$$

然后交换第 l 行和第 k 行。带行置换的 *Gauss* 消元算法的一步可以表示为

$$\boldsymbol{A}^{(k+1)} = \boldsymbol{M}^{(k)} \boldsymbol{P}^{(k)} \boldsymbol{A}^{(k)}, \tag{2.4.10}$$

其中 $\boldsymbol{P}^{(k)}$ 是允许交换第 l 行和第 k 行的置换矩阵，其中 $l \geq k$。正如在引用的练习中可以证明的，该矩阵的所有元素都为零，除了

$$\begin{cases} p_{ii} = 1, \quad i \neq k, i \neq l, \\ p_{kl} = 1, \\ p_{lk} = 1. \end{cases} \tag{2.4.11}$$

该矩阵是置换矩阵且对称，因此具有性质

$$\boldsymbol{P}^{(k)} = (\boldsymbol{P}^{(k)})^T = (\boldsymbol{P}^{(k)})^{-1}. \tag{2.4.12}$$

2.4.4 分解 $PA = LU$

你可以先研究引用的例子。在一般情况下：

- **第一步：**
  - 在 $\boldsymbol{A}$ 的第一列中进行主元搜索，如果该主元位于第 ℓ 行，则交换 $\boldsymbol{A}$ 的第 1 行和第 ℓ 行，即如果 $\boldsymbol{P}^{(1)}$ 是交换第 1 行和第 ℓ 行的置换矩阵，则计算

$$\hat{\boldsymbol{A}}^{(1)} = \boldsymbol{P}^{(1)}\boldsymbol{A}. \tag{2.4.13}$$

  - 在矩阵 $\hat{\boldsymbol{A}}^{(1)}$ 上执行 *Gauss* 方法的第一步，即确定 $\boldsymbol{L}^{(1)}$ 和 $\boldsymbol{A}^{(2)}$，使得

$$\boldsymbol{P}^{(1)}\boldsymbol{A} = \boldsymbol{L}^{(1)}\boldsymbol{A}^{(2)}. \tag{2.4.14}$$

- **第二步：**
  - 在 $\boldsymbol{A}^{(2)}$ 的第二列中进行主元搜索，如果该主元位于第 ℓ 行，则交换 $\boldsymbol{A}^{(2)}$ 的第 2 行和第 ℓ 行，即计算 $\boldsymbol{P}^{(2)}\boldsymbol{A}^{(2)}$，其中 $\boldsymbol{P}^{(2)}$ 是交换第 2 行和第 ℓ 行的置换矩阵。
    可以注意到 $\boldsymbol{P}^{(2)}\boldsymbol{P}^{(1)}\boldsymbol{A} = \boldsymbol{P}^{(2)}\boldsymbol{L}^{(1)}\boldsymbol{P}^{(2)}\boldsymbol{P}^{(2)}\boldsymbol{A}^{(2)}$，应用命题 2.4.5，$\boldsymbol{P}^{(2)}\boldsymbol{L}^{(1)}\boldsymbol{P}^{(2)} = \hat{\boldsymbol{L}}^{(1)}$，可以设 $\hat{\boldsymbol{A}}^{(2)} = \boldsymbol{P}^{(2)}\boldsymbol{A}^{(2)}$，因此有

$$\boldsymbol{P}^{(2)}\boldsymbol{P}^{(1)}\boldsymbol{A} = \hat{\boldsymbol{L}}^{(1)}\hat{\boldsymbol{A}}^{(2)}. \tag{2.4.15}$$

  - 在矩阵 $\hat{\boldsymbol{A}}^{(2)}$ 上执行 *Gauss* 方法的第二步，即确定 $\boldsymbol{L}^{(2)}$ 和 $\boldsymbol{A}^{(3)}$，使得

$$\boldsymbol{P}^{(2)}\boldsymbol{P}^{(1)}\boldsymbol{A} = \boldsymbol{L}^{(2)}\boldsymbol{A}^{(3)}. \tag{2.4.16}$$

- **一般步骤：**当得到

$$\boldsymbol{P}^{(k-1)} \dots \boldsymbol{P}^{(1)}\boldsymbol{A} = \boldsymbol{L}^{(k-1)}\boldsymbol{A}^{(k)}, \tag{2.4.17}$$

  - 在 $\boldsymbol{A}^{(k)}$ 的第 k 列上进行主元搜索，得到

$$\boldsymbol{P}^{(k)}\boldsymbol{P}^{(k-1)} \dots \boldsymbol{P}^{(1)}\boldsymbol{A} = \hat{\boldsymbol{L}}^{(k-1)}\hat{\boldsymbol{A}}^{(k)}. \tag{2.4.18}$$

  - 执行 *Gauss* 方法的第 k 步，得到

$$\boldsymbol{P}^{(k)}\boldsymbol{P}^{(k-1)} \dots \boldsymbol{P}^{(1)}\boldsymbol{A} = \boldsymbol{L}^{(k)}\boldsymbol{A}^{(k+1)}. \tag{2.4.19}$$

- **最终结果**：经过 $n-1$ 步后得到：

$$\boldsymbol{P}^{(n-1)}\boldsymbol{P}^{(n-2)}\dots\boldsymbol{P}^{(1)}\boldsymbol{A}=\boldsymbol{L}^{(n-1)}\boldsymbol{A}^{(n)}, \tag{2.4.20}$$

如果设 $\boldsymbol{P}=\boldsymbol{P}^{(n-1)}\boldsymbol{P}^{(n-2)}\dots\boldsymbol{P}^{(1)}$，$\boldsymbol{L}=\boldsymbol{L}^{(n-1)}$，$\boldsymbol{U}=\boldsymbol{A}^{(n)}$，则得到所求的分解

$$\boldsymbol{PA}=\boldsymbol{LU}. \tag{2.4.21}$$

定理 2.4.2

设 $\boldsymbol{A}$ 是一个可逆矩阵。则存在一个下三角矩阵 $\boldsymbol{L}$、一个上三角矩阵 $\boldsymbol{U}$ 和一个置换矩阵 $\boldsymbol{P}$，使得

$$\boldsymbol{PA}=\boldsymbol{LU}. \tag{2.4.22}$$

注意，分解 $\boldsymbol{PA}=\boldsymbol{LU}$ 不是唯一的。

我们使用了以下命题：

命题 2.4.2

设 $\boldsymbol{L}^{(k-1)}$ 是一个下三角矩阵，对角线为单位元，且进一步满足

$$[\boldsymbol{L}^{(k-1)}]_{ij}=0,\quad i>j>k-1, \tag{2.4.23}$$

设 $\boldsymbol{P}^{(k)}$ 是带主元搜索的 Gauss 算法第 k 步的置换矩阵，交换第 k 行和第 ℓ 行，其中 $\ell\geq k$。则有

$$\boldsymbol{P}^{(k)}\boldsymbol{L}^{(k-1)}\boldsymbol{P}^{(k)}=\hat{\boldsymbol{L}}^{(k-1)}, \tag{2.4.24}$$

其中 $\hat{\boldsymbol{L}}^{(k-1)}$ 是通过置换 $\boldsymbol{L}^{(k-1)}$ 的第 k 行和第 ℓ 行在第 1 到 $k-1$ 列中的项而得到的下三角矩阵。

证明. 可以将 $\boldsymbol{L}^{(k-1)}$ 写成如下形式：

$$\boldsymbol{L}^{(k-1)}=\boldsymbol{I}+\sum_{p=1}^{k-1}\boldsymbol{z}^{(p)}(\boldsymbol{e}_p)^T, \tag{2.4.25}$$

其中 $z_i^{(p)}=0$ 对 $i\leq p$。然后有

$$\begin{aligned}\boldsymbol{P}^{(k)}\boldsymbol{L}^{(k-1)}\boldsymbol{P}^{(k)}&=\boldsymbol{I}+\sum_{p=1}^{k-1}\boldsymbol{P}^{(k)}\boldsymbol{z}^{(p)}(\boldsymbol{e}_p)^T\boldsymbol{P}^{(k)},\\&=\boldsymbol{I}+\sum_{p=1}^{k-1}\boldsymbol{P}^{(k)}\boldsymbol{z}^{(p)}(\boldsymbol{e}_p)^T,\end{aligned} \tag{2.4.26}$$

因为 $\boldsymbol{P}^{(k)}\boldsymbol{P}^{(k)}=\boldsymbol{I}$ 且 $(\boldsymbol{e}_p)^T\boldsymbol{P}^{(k)}=(\boldsymbol{e}_p)^T$，这是由于 $p<k\leq\ell$（$\boldsymbol{e}_p$ 的置换系数为零）。 □

注意，在实践中，不需要存储所有矩阵 $\boldsymbol{P}^{(k)}$，每次交换时只需更新一个向量 $\boldsymbol{p}$，请参考例子。

2.4.5 分解 $PA = LU$ 的算法

与分解 $\boldsymbol{A} = \boldsymbol{LU}$ 的情况一样，不需要保存连续的矩阵 $\boldsymbol{A}^{(k)}$ 和 $\boldsymbol{L}^{(k)}$。关于置换，我们通过更新一个向量 $\boldsymbol{p}$ 来保存历史记录，该向量初始值为

$$\boldsymbol{p} = [1, 2, \ldots, n]^T, \tag{2.4.27}$$

在该向量上我们将执行由矩阵 $\boldsymbol{P}^{(k)}$（$k = 1, \ldots, n-1$）表示的连续置换。

关于主元元素的搜索，我们将搜索绝对值最大的主元，原因如前所述。

算法 3 分解 $\boldsymbol{PA} = \boldsymbol{LU}$ 的算法

输入： 矩阵 $\boldsymbol{A} \in \mathscr{M}_{n,n}$，容差 $\varepsilon > 0$

输出： 下三角矩阵 $\boldsymbol{L}$（对角线为 1）、上三角矩阵 $\boldsymbol{U}$ 和置换向量 $\boldsymbol{p}$，使得 $\boldsymbol{PA} = \boldsymbol{LU}$，或错误信息

```
L ← I
p ← [1, 2, ..., n]^T
for k = 1, 2, ..., n − 1 do
    找到 ℓ 使得 |a_ℓk| ≥ |a_ik|，i = k, ..., n
    if |a_ℓk| < ε then
        停止算法并给出错误信息
    else
        对向量 p、A 的行以及 L 的第 1 到 k − 1 列的行应用置换 (k, ℓ)
        for i = k + 1, k + 2, ..., n do
            l_ik ← a_ik / a_kk
            for j = k, k + 1, ..., n do
                a_ij ← a_ij − l_ik a_kj
            end for
        end for
    end if
end for
if |a_nn| < ε then
    停止算法并给出错误信息
end if
```

最后一个测试很重要，因为 a_{nn} 的值不是主元，在主循环中没有被测试。在这两种情况下显示的错误信息可能是”矩阵在机器精度下是奇异的”。

2.4.6 应用于线性方程组的求解

如何使用这种分解来求解线性方程组？这与”经典”的 LU 分解一样简单。我们有 $\boldsymbol{Ax} = \boldsymbol{b}$，将其左乘置换矩阵 $\boldsymbol{P}$。因此有

$$\boldsymbol{PAx} = \boldsymbol{Pb}, \tag{2.4.28}$$

即 $\boldsymbol{LUx} = \boldsymbol{Pb}$。该方程组的解通过依次求解两个方程组得到：

$$\begin{cases} \boldsymbol{Ly} = \boldsymbol{Pb}, \\ \boldsymbol{Ux} = \boldsymbol{y}, \end{cases} \tag{2.4.29}$$

这仍然对应于求解两个三角方程组。唯一的区别是这里我们必须在求解之前置换向量 $\boldsymbol{b}$ 的分量。

实际上，我们从不显式地写出置换矩阵 $\boldsymbol{P}$，而是使用（参见前面的算法）由下式定义的向量 $\boldsymbol{p}$：

$$\boldsymbol{p} = \boldsymbol{P}\begin{pmatrix} 1 \\ 2 \\ \vdots \\ n \end{pmatrix}. \tag{2.4.30}$$

因此，向量 $\boldsymbol{c} = \boldsymbol{Pb}$ 是向量

$$\boldsymbol{c} = \begin{pmatrix} b_{p_1} \\ b_{p_2} \\ \vdots \\ b_{p_n} \end{pmatrix}. \tag{2.4.31}$$

对于 $\boldsymbol{A}$ 的行列式计算，有

$$\det(\boldsymbol{PA}) = \det(\boldsymbol{P})\det(\boldsymbol{A}) = \prod_{k=1}^{n} u_{kk}, \tag{2.4.32}$$

其中 $\det(\boldsymbol{P}) = (-1)^q$，其中 q 是对 $\boldsymbol{A}$ 执行的与恒等置换不同的置换次数。

2.4.7　完全主元法

在某些情况下，仅置换行是不够的。实际上，可能在一列中找不到绝对值足够大的元素（相对于我们设定的阈值）。这导致在 *Gauss* 方法的每一步 k，需要在子矩阵

$$\begin{pmatrix} a_{kk} & \dots & a_{kn} \\ \vdots & \ddots & \vdots \\ a_{nk} & \dots & a_{nn} \end{pmatrix} \tag{2.4.33}$$

中搜索绝对值最大的元素。这需要同时进行行和列的置换。这对应于交换方程组中的方程以及未知量。就 $\boldsymbol{A} = \boldsymbol{LU}$ 类型的分解而言，这种方法可以得到分别下三角和上三角的 $\boldsymbol{L}$ 和 $\boldsymbol{U}$，使得

$$\boldsymbol{LU} = \boldsymbol{PAQ}, \tag{2.4.34}$$

其中 $\boldsymbol{P}$ 和 $\boldsymbol{Q}$ 是置换矩阵。这种方法很少使用，因为主元搜索可能很快变得昂贵（当矩阵很大时），相对于可能获得的精度提升。

完全主元选择的问题：部分主元（仅在第 k 列搜索：$k \le i \le n$）或完全主元（在整个子矩阵搜索：$k \le i, j \le n$）是数值分析中典型情况的例子。更精确地说，我们知道在数学上，完全主元法的误差上界比部分主元法好得多。我们知道可以构造一些矩阵，使得部分主元的相对误差上界达到。然而，数值实验表明，在所有实际情况下，部分主元法就足够了。

2.5 对称矩阵的处理

2.5.1 分解 LDL^T

当矩阵 $\boldsymbol{A}$ 对称时，如果分解 $\boldsymbol{A}=\boldsymbol{LU}$ 存在，则可以采取一种特殊形式，利用这种对称性：

命题 2.5.1

如果 $\boldsymbol{A}$ 是对称矩阵，且其所有主主子矩阵都是正则的，则它允许一个唯一的分解形式

$$\boldsymbol{A}=\boldsymbol{LDL}^T, \tag{2.5.1}$$

其中 $\boldsymbol{L}$ 是对角线为单位元的下三角矩阵，$\boldsymbol{D}$ 是正则的对角矩阵。

证明. 根据假设，$\boldsymbol{A}$ 满足具有唯一 LU 分解的条件，其中 $\boldsymbol{L}$ 是对角线为单位元的下三角矩阵。此外，如果记 $\boldsymbol{D}$ 为对角线等于 $\boldsymbol{U}$ 的对角线的对角矩阵，可以写成

$$\boldsymbol{A}=\boldsymbol{LDV}, \tag{2.5.2}$$

其中 $\boldsymbol{V}=\boldsymbol{D}^{-1}\boldsymbol{U}$ 是对角线为单位元的上三角矩阵（因为 $\boldsymbol{U}$ 是正则矩阵，因此其对角线元素非零）。由于 $\boldsymbol{A}$ 对称，有

$$\boldsymbol{A}=\boldsymbol{LDV}=\boldsymbol{V}^T\boldsymbol{DL}^T=\boldsymbol{A}^T. \tag{2.5.3}$$

而我们已经证明了 LU 分解的唯一性（在 $\boldsymbol{L}$ 对角线为单位元的情况下），因此 $\boldsymbol{L}=\boldsymbol{V}$，因为 $\boldsymbol{V}^T$ 是对角线为单位元的下三角矩阵，而 $\boldsymbol{DL}^T$ 是上三角矩阵。分解 $\boldsymbol{LDL}^T$ 的唯一性由 LU 分解的唯一性得出。 □

前面的结果仅仅是存在性结果：在实践中，我们通过不同的方式计算矩阵 $\boldsymbol{L}$ 和 $\boldsymbol{D}$。该算法通过识别等式

$$\boldsymbol{A}=\boldsymbol{LDL}^T \tag{2.5.4}$$

中的 $\boldsymbol{A}$ 的项，逐列（或逐行）计算 $\boldsymbol{D}$ 和 $\boldsymbol{L}$ 的项。

我们现在将看到一种适用于对称正定矩阵的分解方法，它直接来源于对称矩阵的 $\boldsymbol{LDL}^T$ 分解。

2.5.2 Cholesky 分解：存在性

在本节中，$\boldsymbol{A}$ 表示一个对称正定矩阵。为了证明关于分解存在性和唯一性的主要定理，我们需要以下引理：

引理 2.5.1

对称正定矩阵 $\boldsymbol{A}$ 的所有主主子矩阵 $[\boldsymbol{A}]_k$ 都是正则的。

证明. 设 k 固定，$\tilde{\boldsymbol{z}}\in\mathbb{R}^k$ 是任意非零向量。定义

$$\boldsymbol{z}=(\tilde{\boldsymbol{z}}^T,0,\ldots,0)^T=(z_1,z_2,\ldots,z_k,0,\ldots,0)^T. \tag{2.5.5}$$

由于 $\boldsymbol{A}$ 是正定的，

$$0 < \boldsymbol{z}^T \boldsymbol{A} \boldsymbol{z} = \tilde{\boldsymbol{z}}^T [\boldsymbol{A}]_k \tilde{\boldsymbol{z}}, \tag{2.5.6}$$

这表明 $[\boldsymbol{A}]_k$ 是正定的，因此可逆。 □

定理 2.5.1

如果 $\boldsymbol{A}$ 是对称正定矩阵，则它允许一个唯一的分解形式

$$\boldsymbol{A} = \boldsymbol{B}\boldsymbol{B}^T, \tag{2.5.7}$$

其中 $\boldsymbol{B}$ 是对角线元素全为正的下三角矩阵。

证明. 首先，由于 $\boldsymbol{A}$ 是正定的，其所有主主子矩阵都是正则的（参见前面的引理 2.5.2），根据命题 2.5.1，它允许一个形如

$$\boldsymbol{A} = \boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^T \tag{2.5.8}$$

的分解。矩阵 $\boldsymbol{D}$ 的所有对角线元素都是正的。

实际上，对于固定的 i（$1 \le i \le n$），设 $\boldsymbol{z}$ 使得 $\boldsymbol{L}^T \boldsymbol{z} = \boldsymbol{e}_i$。则有

$$0 < \boldsymbol{z}^T \boldsymbol{A} \boldsymbol{z} = (\boldsymbol{L}^T \boldsymbol{z})^T \boldsymbol{D} \boldsymbol{L}^T \boldsymbol{z} = \boldsymbol{e}_i^T \boldsymbol{D} \boldsymbol{e}_i = d_{ii}, \tag{2.5.9}$$

因为 $\boldsymbol{A}$ 是正定的。然后引入对角矩阵 $\boldsymbol{\Lambda}$，使得

$$\lambda_{ii} = \sqrt{d_{ii}}, \tag{2.5.10}$$

可以将 (2.5.8) 重写为

$$\boldsymbol{A} = \boldsymbol{L}\boldsymbol{\Lambda}\boldsymbol{\Lambda}\boldsymbol{L}^T = (\boldsymbol{L}\boldsymbol{\Lambda})(\boldsymbol{L}\boldsymbol{\Lambda})^T = \boldsymbol{B}\boldsymbol{B}^T, \tag{2.5.11}$$

通过设

$$\boldsymbol{B} = \boldsymbol{L}\boldsymbol{\Lambda}. \tag{2.5.12}$$

得到。

现在证明唯一性。设存在另一个分解

$$\boldsymbol{A} = \tilde{\boldsymbol{B}}\tilde{\boldsymbol{B}}^T, \tag{2.5.13}$$

其中 $\tilde{\boldsymbol{B}}$ 是对角线元素为正的三角矩阵。因此可以写成

$$\boldsymbol{B}\boldsymbol{B}^T = \tilde{\boldsymbol{B}}\tilde{\boldsymbol{B}}^T \Rightarrow \boldsymbol{B}^{-1}\boldsymbol{B}\boldsymbol{B}^T(\tilde{\boldsymbol{B}}^T)^{-1} = \boldsymbol{B}^{-1}\tilde{\boldsymbol{B}}\tilde{\boldsymbol{B}}^T(\tilde{\boldsymbol{B}}^T)^{-1} \Rightarrow \boldsymbol{B}^T(\tilde{\boldsymbol{B}}^T)^{-1} = \boldsymbol{B}^{-1}\tilde{\boldsymbol{B}}. \tag{2.5.14}$$

在这个最后的等式中，左边的矩阵是上三角矩阵，右边的矩阵是下三角矩阵，这只有当它们是对角矩阵时才可能，因此

$$\boldsymbol{B}^T(\tilde{\boldsymbol{B}}^T)^{-1} = \boldsymbol{B}^{-1}\tilde{\boldsymbol{B}} = \boldsymbol{D}, \tag{2.5.15}$$

这意味着

$$\forall i = 1, 2, \ldots, n, \quad \frac{b_{ii}}{\tilde{b}_{ii}} = \frac{\tilde{b}_{ii}}{b_{ii}} = d_{ii} \Rightarrow (b_{ii})^2 = (\tilde{b}_{ii})^2, \tag{2.5.16}$$

因此最终 $b_{ii} = \tilde{b}_{ii}$，因为这些数是正的，所以

$$d_{ii} = 1. \tag{2.5.17}$$

$\boldsymbol{D}$ 因此是单位矩阵，所以 $\boldsymbol{B} = \tilde{\boldsymbol{B}}$，从而得到唯一性。 □

与分解 $\boldsymbol{LDL}^T$ 的情况一样，前面的结果仅仅是存在性结果，在实践中我们通过识别等式

$$\boldsymbol{A} = \boldsymbol{B}\boldsymbol{B}^T \tag{2.5.18}$$

中的 $\boldsymbol{A}$ 的项，逐列（或逐行）计算矩阵 $\boldsymbol{B}$。

2.5.3 Cholesky 算法

这是 LU 分解对矩阵 $\boldsymbol{A}$ 为对称正定矩阵的系统的适应。该算法分为三个步骤：

- 计算系统矩阵的分解，
- 求解第一个三角方程组，
- 求解第二个三角方程组。

更精确地说，我们寻找系统矩阵 $\boldsymbol{A}$ 的一个形如 $\boldsymbol{A} = \boldsymbol{B}\boldsymbol{B}^T$（参见引用的段落）的分解，其中 $\boldsymbol{B}$ 是对角线元素为正的下三角矩阵（$\boldsymbol{B}^T$ 表示其转置）。我们通过识别得到这个分解：

$$a_{11} = \boldsymbol{B}_1(\boldsymbol{B}^T)_1 = b_{11}^2. \tag{2.5.19}$$

由于 b_{11} 必须为正，有

$$b_{11} = \sqrt{a_{11}}. \tag{2.5.20}$$

$$\boldsymbol{A}_1 = \boldsymbol{B}(\boldsymbol{B}^T)_1 = b_{11}\boldsymbol{B}_1 \quad \Longleftrightarrow \quad \boldsymbol{B}_1 = \frac{1}{b_{11}}\boldsymbol{A}_1, \tag{2.5.21}$$

这允许确定 $\boldsymbol{B}$ 的第一列。

类似地，我们定义 $\boldsymbol{B}$ 的第二列。

$$a_{22} = \boldsymbol{B}_2(\boldsymbol{B}^T)_2 = b_{21}^2 + b_{22}^2. \tag{2.5.22}$$

由于 b_{22} 必须为正，有

$$b_{22} = \sqrt{a_{22} - b_{21}^2}. \tag{2.5.23}$$

$$\boldsymbol{A}_2 = \boldsymbol{B}(\boldsymbol{B}^T)_2 = b_{21}\boldsymbol{B}_1 + b_{22}\boldsymbol{B}_2 \quad \Longleftrightarrow \quad \boldsymbol{B}_2 = \frac{1}{b_{22}}(\boldsymbol{A}_2 - b_{21}\boldsymbol{B}_1), \tag{2.5.24}$$

这完成了 $\boldsymbol{B}$ 的第二列的确定。

一般来说，当我们确定了 $\boldsymbol{B}$ 的前 $j-1$ 列时，写出：

$$a_{jj} = \boldsymbol{B}_j(\boldsymbol{B}^T)_j = \sum_{k=1}^{j} b_{jk}^2 \quad \Longleftrightarrow \quad b_{jj}^2 = a_{jj} - \sum_{k=1}^{j-1} b_{jk}^2. \tag{2.5.25}$$

由于 b_{jj} 必须为正，有

$$b_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} b_{jk}^2}. \tag{2.5.26}$$

$$\boldsymbol{A}_j = \boldsymbol{B}(\boldsymbol{B}^T)_j = \sum_{k=1}^{j} b_{jk}\boldsymbol{B}_k \quad \Longleftrightarrow \quad \boldsymbol{B}_j = \frac{1}{b_{jj}}\left(\boldsymbol{A}_j - \sum_{k=1}^{j-1} b_{jk}\boldsymbol{B}_k\right), \tag{2.5.27}$$

这完成了 $\boldsymbol{B}$ 的第 j 列的确定。我们将依次确定第 1、2、…、$n-1$ 列，然后通过计算

$$b_{nn} = \sqrt{a_{nn} - \sum_{k=1}^{n-1} b_{nk}^2} \tag{2.5.28}$$

来完成。

与 Doolittle 分解一样，在每一列 j 中，我们只计算 $i \geq j$ 的项 b_{ij}，因为该列的其他项已知为零。

因此有算法：

算法 4 Cholesky 算法

输入： 对称正定矩阵 $\boldsymbol{A} \in \mathscr{M}_{n,n}$

输出： 下三角矩阵 $\boldsymbol{B}$（对角线元素为正），使得 $\boldsymbol{A} = \boldsymbol{B}\boldsymbol{B}^T$，或错误信息

```
for j = 1, 2, ..., n-1 do
    b_jj ← sqrt(a_jj − Σ_{k=1}^{j-1} b_jk^2)
    for i = j+1, j+2, ..., n do
        b_ij ← (1/b_jj) (a_ij − Σ_{k=1}^{j-1} b_ik b_jk)
    end for
end for
b_nn ← sqrt(a_nn − Σ_{k=1}^{n-1} b_nk^2)
```

如果矩阵是正定的，我们取平方根的数都是正的，我们用来除的数都是非零的（因为我们已经证明了分解存在）。然而，在算法中包含测试以确保这些性质得到验证是谨慎的做法。

Chapter 3

最小二乘问题的求解

3.1　最小二乘问题的一般表述

3.1.1　一个例子：平滑问题

如果给定平面上的一族点 $(t_i, b_i)_{1\le i\le m}$（t_i 互不相同），则存在唯一的次数小于或等于 $m-1$ 的多项式 $P(t)$，使得

$$P(t_i) = b_i, \quad i = 1, \ldots, m, \tag{3.1.1}$$

这就是点 (t_i, b_i) 的插值多项式。如果点的数量 m 太大，或者纵坐标有噪声，通常我们更倾向于寻找一个函数 $f(t)$，它在给定类别（多项式、有理分式、三角多项式、指数函数...）中" 最好地" 逼近点 (t_i, b_i)，此时我们称之为近似、平滑或回归（参见图 3.1.1）。

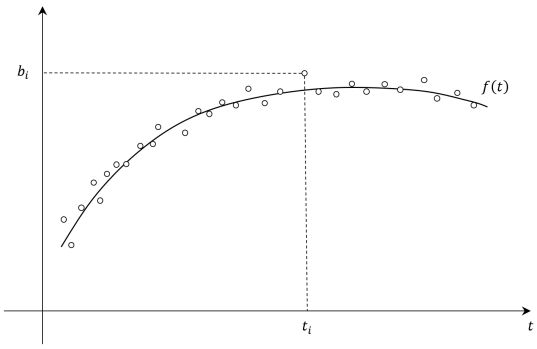

图 3.1.1　一个平滑问题

设有一族函数

$$f_1(t), f_2(t), \ldots, f_n(t), \quad n \le m, \tag{3.1.2}$$

它们是线性无关的。给定 n 个实数 $x_1, x_2, \ldots, x_n$，可以引入数 $E(\boldsymbol{x})$

$$E(\boldsymbol{x}) = \sum_{i=1}^{m} [f(t_i) - b_i]^2, \tag{3.1.3}$$

其中 $f(t) = \sum_{k=1}^{n} x_k f_k(t)$。量 $E(\boldsymbol{x})$ 表示给定值与 f 在点 t_i 处的值之间的平方误差之和。近似问题可以表述如下：

寻找 $\hat{\boldsymbol{x}} \in \mathbb{R}^n$，使得 $E(\hat{\boldsymbol{x}}) \le E(\boldsymbol{x})$，$\forall \boldsymbol{x} \in \mathbb{R}^n$。

例如，如果我们希望进行多项式回归，即取 $f(t)$ 为次数 $\le n-1$ 的多项式，有

$$f_k(t) = t^{k-1}, \quad k = 1, \ldots, n, \quad f(t) = x_1 + x_2 t + \ldots + x_n t^{n-1}. \tag{3.1.4}$$

多项式这种不寻常的写法，以 x_k 作为系数，可以突出最小二乘问题的未知量就是这些系数。

3.1.2 矩阵形式

假设我们需要求解线性方程组 $\boldsymbol{Ax} = \boldsymbol{b}$（$\boldsymbol{A} \in \mathscr{M}_{m,n}$），其中右端项 $\boldsymbol{b}$ 非零，且假设方程个数严格大于未知数个数（$m > n$）。在大多数情况下，该方程组没有解。此时我们寻求一个近似解，使得差值 $\boldsymbol{Ax} - \boldsymbol{b}$ 尽可能小。一种可能的选择是最小化该差值的欧几里得范数。在本章中，我们仅使用欧几里得范数。

定义 3.1.1

设给定 $\boldsymbol{A} \in \mathscr{M}_{m,n}(\mathbb{R})$ 和 $\boldsymbol{b} \in \mathbb{R}^m$。我们称如下问题为**最小二乘问题**：

$$\min_{\boldsymbol{x} \in \mathbb{R}^n} \|\boldsymbol{Ax} - \boldsymbol{b}\|_2^2. \tag{3.1.5}$$

我们记 $\hat{\boldsymbol{x}}$ 为该问题的解。后续将证明，在以下基本假设下，该解存在且唯一：

$\boldsymbol{A}$ 的列向量线性无关。

或者，等价地

$$\operatorname{rang} \boldsymbol{A} = n. \tag{3.1.6}$$

一个特殊情况是 $m = n$ 且 $\boldsymbol{A}$ 可逆，此时 $\hat{\boldsymbol{x}}$ 是 $\boldsymbol{Ax} = \boldsymbol{b}$ 的唯一解，但本章关注的是更一般的情况（$m > n$）。

对于平滑问题，另一个例子已在前面段落中介绍。一般而言，不可能使一个依赖于 n 个未知数的函数 $f(t)$（例如 $n-1$ 次多项式）通过 m 个点（$m > n$）。因此，很可能不存在 $\boldsymbol{x} \in \mathbb{R}^n$ 使得以下量

$$\sum_{k=1}^{n} x_k f_k(t_i) - b_i, \quad 1 \le i \le m \tag{3.1.7}$$

为零。

该表达式可以写成 $\boldsymbol{Ax} - \boldsymbol{b}$ 的形式，其中

$$a_{ij} = f_j(t_i), \quad 1 \le i \le m, \quad 1 \le j \le n, \tag{3.1.8}$$

因此我们需要最小化

$$E(\boldsymbol{x}) = \sum_{i=1}^{m} \left[\sum_{k=1}^{n} x_k f_k(t_i) - b_i \right]^2. \tag{3.1.9}$$

此时最小值将不为零。

3.1.3　法方程

稍后我们将给出最小二乘问题的纯代数解法。然而，我们现在将给出一种解析方法，使我们能够从不同角度看待这个问题。首先，让我们显式地写出需要最小化的函数。我们有

$$\begin{aligned} E(\boldsymbol{x}) &= \|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2^2 = (\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b})^T(\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}) \\ &= \boldsymbol{x}^T\boldsymbol{A}^T\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}^T\boldsymbol{A}\boldsymbol{x} - \boldsymbol{x}^T\boldsymbol{A}^T\boldsymbol{b} + \|\boldsymbol{b}\|_2^2 \\ &= \boldsymbol{x}^T\boldsymbol{A}^T\boldsymbol{A}\boldsymbol{x} - 2(\boldsymbol{A}^T\boldsymbol{b})^T\boldsymbol{x} + \|\boldsymbol{b}\|_2^2. \end{aligned} \tag{3.1.10}$$

最小二乘问题因此可以重新表述为

$$\min_{\boldsymbol{x}\in\mathbb{R}^n} J(\boldsymbol{x}) = \boldsymbol{x}^T\boldsymbol{G}\boldsymbol{x} - 2\boldsymbol{h}^T\boldsymbol{x}, \tag{3.1.11}$$

其中 $\boldsymbol{G} = \boldsymbol{A}^T\boldsymbol{A}$ 是对称矩阵，$\boldsymbol{h} = \boldsymbol{A}^T\boldsymbol{b}$ 是给定的向量。

定义 3.1.2

我们称形如

$$J(\boldsymbol{x}) = \boldsymbol{x}^T\boldsymbol{G}\boldsymbol{x} - 2\boldsymbol{h}^T\boldsymbol{x} \tag{3.1.12}$$

的函数 $J:\mathbb{R}^n\to\mathbb{R}$ 为**二次函数**，其中 $\boldsymbol{G}$ 是 $n\times n$ 对称矩阵，$\boldsymbol{h}$ 是 $\mathbb{R}^n$ 中的给定向量。

回顾一下，如果 $J:\mathbb{R}\to\mathbb{R}$ 连续可导，且在 $\hat{x}\in\mathbb{R}$ 处取得最小值，则 $J'(\hat{x})=0$。类似地，设 $J:\mathbb{R}^n\to\mathbb{R}$ 连续可导，则

$$J(\hat{\boldsymbol{x}}) \le J(\boldsymbol{x}) \quad \forall \boldsymbol{x}\in\mathbb{R}^n \quad \Rightarrow \quad \nabla J(\hat{\boldsymbol{x}}) = \boldsymbol{0}, \tag{3.1.13}$$

其中 ∇ 是梯度算子。

这里，J 的梯度计算给出（参见引用的文档）

$$\nabla J(\boldsymbol{x}) = 2(\boldsymbol{G}\boldsymbol{x} - \boldsymbol{h}) \tag{3.1.14}$$

因此最小二乘问题的解 $\hat{\boldsymbol{x}}$ 必须满足

$$\boldsymbol{G}\hat{\boldsymbol{x}} = \boldsymbol{h}, \tag{3.1.15}$$

即

$$\boldsymbol{A}^T\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}^T\boldsymbol{b}. \tag{3.1.16}$$

这些关系式称为问题的**法方程**，它们是 $\hat{\boldsymbol{x}}$ 为最小值的必要条件。进一步可以证明这些条件也是充分的，因此有下面的定理。

定理 3.1.1

设给定 $\boldsymbol{A}\in\mathscr{M}_{m,n}(\mathbb{R})$ 和 $\boldsymbol{b}\in\mathbb{R}^m$，如果假设矩阵 $\boldsymbol{A}$ 的秩为 n，则最小二乘问题

$$\min_{\boldsymbol{x}\in\mathbb{R}^n} \|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2^2 \tag{3.1.17}$$

有唯一解 $\hat{\boldsymbol{x}}$，由下式给出：

$$\boldsymbol{A}^T\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}^T\boldsymbol{b}. \tag{3.1.18}$$

证明. 首先注意到，如果 $\boldsymbol{A}$ 的秩为 n，则 $\boldsymbol{G} = \boldsymbol{A}^T\boldsymbol{A}$ 是正定矩阵。事实上：

$$\boldsymbol{x}^T\boldsymbol{G}\boldsymbol{x} = \|\boldsymbol{A}\boldsymbol{x}\|_2^2 \geq 0 \quad \forall \boldsymbol{x} \in \mathbb{R}^n, \tag{3.1.19}$$

另一方面，由于 $\boldsymbol{A}$ 的秩为 n，$\operatorname{Ker}\boldsymbol{A}$ 的维数为零，因此

$$\boldsymbol{x}^T\boldsymbol{G}\boldsymbol{x} = 0 \quad \Leftrightarrow \quad \|\boldsymbol{A}\boldsymbol{x}\|_2^2 = 0 \quad \Leftrightarrow \quad \boldsymbol{A}\boldsymbol{x} = \boldsymbol{0} \quad \Leftrightarrow \quad \boldsymbol{x} = \boldsymbol{0}. \tag{3.1.20}$$

矩阵 $\boldsymbol{G}$ 是正定的，因此可逆，所以存在唯一解 $\hat{\boldsymbol{x}}$ 满足

$$\boldsymbol{A}^T\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}^T\boldsymbol{b} \quad \Leftrightarrow \quad \boldsymbol{G}\hat{\boldsymbol{x}} = \boldsymbol{h}. \tag{3.1.21}$$

现在证明

$$\forall \boldsymbol{x} \in \mathbb{R}^n, \quad \boldsymbol{x} \neq \hat{\boldsymbol{x}} \quad \Rightarrow \quad J(\boldsymbol{x}) > J(\hat{\boldsymbol{x}}). \tag{3.1.22}$$

设 $\boldsymbol{y} = \boldsymbol{x} - \hat{\boldsymbol{x}}$，因此 $\boldsymbol{y} \neq \boldsymbol{0}$。有

$$\begin{aligned} J(\hat{\boldsymbol{x}} + \boldsymbol{y}) &= (\hat{\boldsymbol{x}} + \boldsymbol{y})^T\boldsymbol{G}(\hat{\boldsymbol{x}} + \boldsymbol{y}) - 2\boldsymbol{h}^T(\hat{\boldsymbol{x}} + \boldsymbol{y}) \\ &= \hat{\boldsymbol{x}}^T\boldsymbol{G}\hat{\boldsymbol{x}} + \boldsymbol{y}^T\boldsymbol{G}\boldsymbol{y} + 2\hat{\boldsymbol{x}}^T\boldsymbol{G}\boldsymbol{y} - 2\boldsymbol{h}^T\boldsymbol{y} - 2\boldsymbol{h}^T\hat{\boldsymbol{x}} \\ &= \hat{\boldsymbol{x}}^T\boldsymbol{G}\hat{\boldsymbol{x}} + \boldsymbol{y}^T\boldsymbol{G}\boldsymbol{y} + 2(\boldsymbol{G}\hat{\boldsymbol{x}} - \boldsymbol{h})^T\boldsymbol{y} - 2\boldsymbol{h}^T\hat{\boldsymbol{x}} \\ &= \boldsymbol{y}^T\boldsymbol{G}\boldsymbol{y} + \hat{\boldsymbol{x}}^T\boldsymbol{G}\hat{\boldsymbol{x}} - 2\boldsymbol{h}^T\hat{\boldsymbol{x}}, \end{aligned} \tag{3.1.23}$$

因为 $\boldsymbol{G}\hat{\boldsymbol{x}} = \boldsymbol{h}$。因此

$$J(\hat{\boldsymbol{x}} + \boldsymbol{y}) = J(\hat{\boldsymbol{x}}) + \boldsymbol{y}^T\boldsymbol{G}\boldsymbol{y}. \tag{3.1.24}$$

由于 $\boldsymbol{G}$ 是正定矩阵，且 $\boldsymbol{y} \neq \boldsymbol{0}$，有 $\boldsymbol{y}^T\boldsymbol{G}\boldsymbol{y} > 0$，因此

$$J(\hat{\boldsymbol{x}} + \boldsymbol{y}) > J(\hat{\boldsymbol{x}}), \quad \forall \boldsymbol{y} \in \mathbb{R}^n, \quad \boldsymbol{y} \neq \boldsymbol{0}, \tag{3.1.25}$$

这表明 $\hat{\boldsymbol{x}}$ 实现了 J 的最小值。 □

3.2 第三章文档

3.2.1 二次形式的梯度

设二次函数

$$J(\boldsymbol{x}) = \boldsymbol{x}^T\boldsymbol{G}\boldsymbol{x} - 2\boldsymbol{h}^T\boldsymbol{x}, \tag{3.2.1}$$

其中 $\boldsymbol{G}$ 是对称矩阵。我们希望计算其梯度，即

$$\nabla J(\boldsymbol{x}) = \left(\frac{\partial J}{\partial x_1}, \frac{\partial J}{\partial x_2}, \ldots, \frac{\partial J}{\partial x_n}\right). \tag{3.2.2}$$

展开函数 J：

$$J(\boldsymbol{x}) = \sum_{i=1}^{n} x_i(\boldsymbol{G}\boldsymbol{x})_i - 2\sum_{i=1}^{n} h_i x_i. \tag{3.2.3}$$

则

$$\frac{\partial J}{\partial x_k} = (\boldsymbol{G}\boldsymbol{x})_k + \sum_{i=1}^{n} x_i \frac{\partial}{\partial x_k}(\boldsymbol{G}\boldsymbol{x})_i - 2h_k, \tag{3.2.4}$$

且

$$\frac{\partial}{\partial x_k}(\boldsymbol{G}\boldsymbol{x})_i = \frac{\partial}{\partial x_k}\left(\sum_{j=1}^{n} g_{ij}x_j\right) = g_{ik} = g_{ki}, \tag{3.2.5}$$

因为 $\boldsymbol{G}$ 是对称矩阵。

因此

$$\begin{aligned}\frac{\partial J}{\partial x_k} &= (\boldsymbol{G}\boldsymbol{x})_k + \sum_{i=1}^{n} x_i g_{ki} - 2h_k \\ &= (\boldsymbol{G}\boldsymbol{x})_k + (\boldsymbol{G}\boldsymbol{x})_k - 2h_k \\ &= 2(\boldsymbol{G}\boldsymbol{x})_k - 2h_k,\end{aligned} \tag{3.2.6}$$

由此得到结果

$$\nabla J(\boldsymbol{x}) = 2(\boldsymbol{G}\boldsymbol{x} - \boldsymbol{h}). \tag{3.2.7}$$

Chapter 4

迭代方法

4.1　线性方程组求解的迭代方法

4.1.1　一般原理

迭代方法用于求解非常大尺寸的线性方程组，或者当我们有一个解的估计值并希望改进它时。

迭代方法在于构造一系列向量 $\boldsymbol{x}^{(0)}, \boldsymbol{x}^{(1)}, \ldots, \boldsymbol{x}^{(k)}, \ldots$，我们希望，或者更好的是我们能够证明，该序列将收敛到待求解线性方程组的解。

设给定 $\boldsymbol{A} \in \mathscr{M}_{n,n}(\mathbb{R})$ 为正则矩阵，$\boldsymbol{b} \in \mathbb{R}^n$。我们希望通过如下形式的迭代方法来求解问题：

$$f(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b} = \boldsymbol{0} \tag{4.1.1}$$

迭代方法的形式为：

$$\begin{cases} \boldsymbol{x}^{(0)} \text{ 给定}, \\ \boldsymbol{M}\boldsymbol{x}^{(k+1)} = \boldsymbol{N}\boldsymbol{x}^{(k)} + \boldsymbol{b}, \end{cases} \tag{4.1.2}$$

其中矩阵 $\boldsymbol{M}, \boldsymbol{N} \in \mathscr{M}_{n,n}(\mathbb{R})$，$\boldsymbol{M}$ 可逆，需要适当选择。

如果该迭代方法收敛，即如果序列 $\boldsymbol{x}^{(k)}$ 收敛到 $\bar{\boldsymbol{x}}$，则在极限情况下有

$$(\boldsymbol{M} - \boldsymbol{N})\bar{\boldsymbol{x}} = \boldsymbol{b}, \tag{4.1.3}$$

如果满足

$$\boldsymbol{A} = \boldsymbol{M} - \boldsymbol{N}, \tag{4.1.4}$$

则这对应于求解 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$。

满足 $\boldsymbol{A} = \boldsymbol{M} - \boldsymbol{N}$ 的矩阵 $\boldsymbol{M}$ 和 $\boldsymbol{N}$ 有无穷多种选择，我们将给出两个例子。当然，我们的想法是选择一个特别容易求逆的矩阵 $\boldsymbol{M}$，例如对角矩阵，或者下三角矩阵。这两种选择分别对应于 ***Jacobi* 方法**和 ***Gauss-Seidel* 方法**。

4.1.2 *Jacobi* 方法

线性方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 可以写成

$$\begin{cases}\sum_{j=1}^{n} a_{1j}x_j = b_1, \\ \cdots \\ \sum_{j=1}^{n} a_{ij}x_j = b_i, \quad 对 2 \le i \le n-1, \\ \cdots \\ \sum_{j=1}^{n} a_{nj}x_j = b_n.\end{cases} \tag{4.1.5}$$

Jacobi 方法在于，在每次迭代 k 中，将每个方程相对于其中一个变量求解，其他变量固定为前一次迭代得到的值。设给定向量 $\boldsymbol{x}^{(k)}$，则我们通过以下公式依次确定 $\boldsymbol{x}^{(k+1)}$ 的分量：

$$\begin{cases}a_{11}x_1^{(k+1)} = b_1 - \sum_{j=2}^{n} a_{1j}x_j^{(k)}, \\ \cdots \\ a_{ii}x_i^{(k+1)} = b_i - \sum_{j=1,j\neq i}^{n} a_{ij}x_j^{(k)}, \quad 对 2 \le i \le n-1, \\ \cdots \\ a_{nn}x_n^{(k+1)} = b_n - \sum_{j=1}^{n-1} a_{nj}x_j^{(k)}.\end{cases} \tag{4.1.6}$$

前面的公式只有在 $\boldsymbol{A}$ 的所有对角系数都非零时才真正定义了 $\boldsymbol{x}^{(k+1)}$。这不是一个限制，因为可以证明，如果矩阵可逆，则存在其行的一个置换，使得由此得到的矩阵的所有对角元素都非零（参见练习）。

我们可以将前面的关系写成矩阵形式。为此，引入 $\boldsymbol{A}$ 的如下分解：

$$\boldsymbol{A} = \boldsymbol{D} - \boldsymbol{E} - \boldsymbol{F}, \tag{4.1.7}$$

其中

- $\boldsymbol{D}$ 是对角矩阵，包含 $\boldsymbol{A}$ 的对角线元素，
- $\boldsymbol{E}$ 是下三角矩阵（$-\boldsymbol{A}$ 的下三角部分），
- $\boldsymbol{F}$ 是上三角矩阵（$-\boldsymbol{A}$ 的上三角部分）。

利用这些记号，可以将方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 写成如下形式：

$$\boldsymbol{Dx} = (\boldsymbol{E}+\boldsymbol{F})\boldsymbol{x} + \boldsymbol{b}, \tag{4.1.8}$$

Jacobi 方法可以写成

$$\begin{cases}\boldsymbol{x}^{(0)} \text{ 给定}, \\ \boldsymbol{Dx}^{(k+1)} = (\boldsymbol{E}+\boldsymbol{F})\boldsymbol{x}^{(k)} + \boldsymbol{b}.\end{cases} \tag{4.1.9}$$

4.1.3 *Gauss-Seidel* 方法

这是 *Jacobi* 方法的一个修改，它在于对每个方程使用已经计算出的 $\boldsymbol{x}^{(k+1)}$ 的分量，这导致以下公式：

$$\begin{cases} a_{11}x_1^{(k+1)} = b_1 - \sum_{j=2}^{n} a_{1j}x_j^{(k)}, \\ \cdots \\ a_{ii}x_i^{(k+1)} = b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{ij}x_j^{(k)}, \quad 对 2 \le i \le n-1, \\ \cdots \\ a_{nn}x_n^{(k+1)} = b_n - \sum_{j=1}^{n-1} a_{nj}x_j^{(k+1)}. \end{cases} \tag{4.1.10}$$

以矩阵形式，这等价于将方程组 $\boldsymbol{Ax} = \boldsymbol{b}$ 写成如下形式：

$$(\boldsymbol{D} - \boldsymbol{E})\boldsymbol{x} = \boldsymbol{Fx} + \boldsymbol{b}, \tag{4.1.11}$$

其中矩阵 $\boldsymbol{D}$、$\boldsymbol{E}$ 和 $\boldsymbol{F}$ 已在关于 *Jacobi* 方法的段落中给出。

Gauss-Seidel 方法因此可以写成

$$\begin{cases} \boldsymbol{x}^{(0)} \text{ 给定}, \\ (\boldsymbol{D} - \boldsymbol{E})\boldsymbol{x}^{(k+1)} = \boldsymbol{Fx}^{(k)} + \boldsymbol{b}. \end{cases} \tag{4.1.12}$$

在每次迭代中，需要求解的方程组的矩阵是下三角矩阵。

我们注意到，刚才看到的 *Jacobi* 方法和 *Gauss-Seidel* 方法都可以写成形式 $\boldsymbol{Mx}^{(k+1)} = \boldsymbol{Nx}^{(k)} + \boldsymbol{b}$：

- 对于 *Jacobi* 方法：$\boldsymbol{M} = \boldsymbol{D}$，$\boldsymbol{N} = \boldsymbol{E} + \boldsymbol{F}$，
- 对于 *Gauss-Seidel* 方法：$\boldsymbol{M} = \boldsymbol{D} - \boldsymbol{E}$，$\boldsymbol{N} = \boldsymbol{F}$。

4.1.4 迭代方法的收敛性研究

首先研究迭代方法

$$\begin{cases} \boldsymbol{x}^{(0)} \text{ 给定}, \\ \boldsymbol{x}^{(k+1)} = \boldsymbol{Cx}^{(k)} + \boldsymbol{d} \end{cases} \tag{4.1.13}$$

的收敛性。

命题 4.1.1

如果存在一个从属矩阵范数使得

$$\|\boldsymbol{C}\| < 1, \tag{4.1.14}$$

则方法 (4.1.13) 对任意初始值 $\boldsymbol{x}^{(0)}$ 的选择都是收敛的，且它收敛到方程组

$$(\boldsymbol{I} - \boldsymbol{C})\bar{\boldsymbol{x}} = \boldsymbol{d} \tag{4.1.15}$$

的解。

证明. 首先，方程组 $(\boldsymbol{I}-\boldsymbol{C})\bar{\boldsymbol{x}}=\boldsymbol{d}$ 的解 $\bar{\boldsymbol{x}}$ 存在且唯一，因为矩阵 $\boldsymbol{I}-\boldsymbol{C}$ 可逆。事实上

$$\boldsymbol{x}\in \mathrm{Ker}(\boldsymbol{I}-\boldsymbol{C}) \quad \Leftrightarrow \quad \boldsymbol{x}=\boldsymbol{C}\boldsymbol{x} \quad \Rightarrow \quad \|\boldsymbol{x}\|=\|\boldsymbol{C}\boldsymbol{x}\|\le\|\boldsymbol{C}\|\|\boldsymbol{x}\|, \tag{4.1.16}$$

如果 $\|\boldsymbol{x}\|\neq 0$，简化后会有 $1\le\|\boldsymbol{C}\|$，这与假设矛盾，因此 $\|\boldsymbol{x}\|=0$，所以 $\boldsymbol{x}=\boldsymbol{0}$。我们刚刚证明了 $\mathrm{Ker}(\boldsymbol{I}-\boldsymbol{C})=\{\boldsymbol{0}\}$，由于矩阵 $\boldsymbol{I}-\boldsymbol{C}$ 是方阵，这等价于 $\boldsymbol{I}-\boldsymbol{C}$ 可逆。

现在证明 $\boldsymbol{x}^{(k)}$ 收敛到方程组 $(\boldsymbol{I}-\boldsymbol{C})\bar{\boldsymbol{x}}=\boldsymbol{d}$ 的解 $\bar{\boldsymbol{x}}$。有

$$\begin{aligned}\boldsymbol{x}^{(k)}-\bar{\boldsymbol{x}}&=\boldsymbol{C}(\boldsymbol{x}^{(k-1)}-\bar{\boldsymbol{x}})\\&=\boldsymbol{C}^2(\boldsymbol{x}^{(k-2)}-\bar{\boldsymbol{x}})\\&=\dots\\&=\boldsymbol{C}^k(\boldsymbol{x}^{(0)}-\bar{\boldsymbol{x}}),\end{aligned} \tag{4.1.17}$$

因此

$$\|\boldsymbol{x}^{(k)}-\bar{\boldsymbol{x}}\|\le\|\boldsymbol{C}^k\|\|\boldsymbol{x}^{(0)}-\bar{\boldsymbol{x}}\|\le\|\boldsymbol{C}\|^k\|\boldsymbol{x}^{(0)}-\bar{\boldsymbol{x}}\|. \tag{4.1.18}$$

当 k 趋于无穷时取极限。由于 $\|\boldsymbol{C}\|<1$，$\|\boldsymbol{C}\|^k$ 趋于 0，因此 $\boldsymbol{x}^{(k)}$ 趋于 $\bar{\boldsymbol{x}}$。 □

定义 4.1.1

如果满足

$$|a_{ii}|>\sum_{j\neq i}|a_{ij}|, \quad \forall i, \quad 1\le i\le n, \tag{4.1.19}$$

则称矩阵 $\boldsymbol{A}$ 是**严格对角占优**的。

命题 4.1.2

如果矩阵 $\boldsymbol{A}$ 是严格对角占优的，则 *Jacobi* 方法和 *Gauss-Seidel* 方法都是收敛的。

证明. 我们证明 *Jacobi* 方法的这一命题。*Gauss-Seidel* 方法的证明将在习题课中完成。

Jacobi 方法可以写成

$$\boldsymbol{x}^{(k+1)}=\boldsymbol{D}^{-1}[\boldsymbol{b}+(\boldsymbol{E}+\boldsymbol{F})\boldsymbol{x}^{(k)}], \tag{4.1.20}$$

因此迭代矩阵为

$$\boldsymbol{C}=\boldsymbol{D}^{-1}(\boldsymbol{E}+\boldsymbol{F}). \tag{4.1.21}$$

由于 $\boldsymbol{A}$ 是对角占优的，有

$$\|\boldsymbol{D}^{-1}(\boldsymbol{E}+\boldsymbol{F})\|_\infty=\max_{1\le i\le n}\left(\frac{1}{|a_{ii}|}\sum_{j\neq i}|a_{ij}|\right)<1, \tag{4.1.22}$$

因此方法是收敛的。 □

另一个对应用有趣的结果如下（我们不加证明地承认）：

命题 4.1.3

如果矩阵 $\boldsymbol{A}$ 是对称正定的，则 *Gauss-Seidel* 方法是收敛的。

关于迭代方法收敛性的一个有趣且被承认的结果，给出了基于矩阵 $\boldsymbol{C}$ 的谱半径的刻画。

定理 4.1.1

迭代方法 (4.1.13) 收敛的一个必要且充分条件是

$$\rho(\boldsymbol{C}) < 1, \tag{4.1.23}$$

其中 $\rho(\boldsymbol{C})$ 表示矩阵 $\boldsymbol{C}$ 的**谱半径**（即其特征值的最大模）。

4.2　单变量非线性方程的求解

4.2.1　二分法

我们希望求解 $f(x) = 0$，其中 f 是从 $\mathbb{R}$ 到 $\mathbb{R}$ 的非线性函数（否则这是显然的！）。

因此我们寻找一个实数 x^*，使得 $f(x^*) = 0$。与所有迭代方法一样，我们将构造一个实数序列 $x^{(0)}, x^{(1)}, \ldots, x^{(k)}, \ldots$，它收敛到 x^*。由于这里序列的项是实数，我们将更简单地记为 $x_0, x_1, \ldots, x_k, \ldots$。

二分法的原理非常简单。假设 $f : [a, b] \to \mathbb{R}$ 连续，且 $f(a)f(b) < 0$，即在 $[a, b]$ 中至少有一个 f 的实根。然后取区间的中点 $c = (a + b)/2$。如果 $f(c) = 0$（或在数值上非常接近 0），我们认为问题已解决。否则可能出现两种情况。如果 $f(a)f(c) < 0$，则 f 在 $[a, c]$ 中有一个实根（至少一个，无论如何，奇数个根），否则 $f(a)f(c) > 0$，因此 $f(a)f(b) \cdot f(a)f(c) < 0$，这给出 $f(b)f(c) < 0$，f 在 $[c, b]$ 中有一个实根。然后我们在包含至少一个根的区间上迭代该过程。

二分法可以写成：

$$\begin{gathered} a_0 = a, \quad b_0 = b, \quad x_0 = \frac{a_0 + b_0}{2}, \\ \text{如果} f(x_k)f(a_k) < 0 \text{ 则} a_{k+1} = a_k \text{ 且} b_{k+1} = x_k, \text{ 否则} a_{k+1} = x_k \text{ 且} b_{k+1} = b_k, \\ x_{k+1} = \frac{a_{k+1} + b_{k+1}}{2}. \end{gathered} \tag{4.2.1}$$

显然，在每次迭代中，根 x^* 的定位区间长度 l_k 被除以 2。此外，我们知道 $|x_k - x^*| \le l_k$，因此如果证明 l_k 趋于 0，则序列 (x_k) 收敛到 x^*。

命题 4.2.1

线段序列 $([a_k, b_k])_{k \ge 0}$ 满足

$$l_k = b_k - a_k = \frac{b - a}{2^k}, \quad k \ge 1. \tag{4.2.2}$$

这个命题在数值计算方面很有用；实际上，它告诉我们计算根到精度 ε 所需的最小迭代次数，

其中 $\varepsilon > 0$ 是用户事先固定的精度（停止测试）。实际上，可以证明（在练习中）这个数 n 必须满足

$$n \geq \log_2 \left(\frac{b-a}{\varepsilon} \right). \tag{4.2.3}$$

4.2.2 不动点方法的原理

为了求解 $f(x) = 0$，我们可以将其转化为等价的问题 $g(x) = x$（例如通过设 $g(x) = f(x) + x$）。但是定义 g 有很多可能的选择！求解 $g(x) = x$ 称为寻找 g 的**不动点**。

例如，为了计算实数 $a > 0$ 的平方根，我们求解 $x^2 = a$。存在不同的方法将其转化为不动点问题：

- $x = \dfrac{a}{x}$，且 $g_1(x) = \dfrac{a}{x}$，
- $2x = x + \dfrac{a}{x}$，即 $x = 2x - \dfrac{a}{x}$，且 $g_2(x) = 2x - \dfrac{a}{x}$，
- $x = \dfrac{x}{2} + \dfrac{a}{2x}$，且 $g_3(x) = \dfrac{x}{2} + \dfrac{a}{2x}$。

为了求解 $g(x) = x$（等价于 $f(x) = 0$ 的问题），所谓的**不动点方法**在于按以下方式构造序列 $x_0, x_1, \ldots, x_k, \ldots$：

$$\begin{cases} x_0 \text{ 给定}, \\ x_{k+1} = g(x_k), \quad k \geq 0. \end{cases} \tag{4.2.4}$$

如果序列 (x_k) 收敛，g 的连续性意味着它收敛到 g 的一个不动点 x^*。事实上

$$x^* = \lim_{k\to\infty} x_{k+1} = g\left(\lim_{k\to\infty} x_k\right) = g(x^*). \tag{4.2.5}$$

我们将在练习中看到，对于上面提到的例子，不同的序列在图形上如何表现。我们会发现它们并不总是收敛，因此必须仔细选择函数 g。下一段给出函数 g 的一些条件，使得序列收敛。

4.2.3 不动点方法的收敛性

命题 4.2.2

设函数 $g : [a, b] \to [a, b]$ 在 $[a, b]$ 上连续可导，且假设

$$|g'(x)| \leq k < 1, \quad \forall x \in [a, b]. \tag{4.2.6}$$

则 g 在 $[a, b]$ 中具有唯一的不动点 x^*，且序列

$$\begin{cases} x_0 \text{ 给定在} [a, b] \text{ 中}, \\ x_{n+1} = g(x_n), \quad n \geq 0 \end{cases} \tag{4.2.7}$$

收敛到 x^*。

证明. 第一部分是介值定理的直接结果。事实上，如果我们不在明显的情况 $g(a)=a$ 或 $g(b)=b$ 中，函数 $H(x)=g(x)-x$ 满足 $H(a)=g(a)-a>0$（因为 $g(a)\in[a,b]$）和 $H(b)=g(b)-b<0$（因为 $g(b)\in[a,b]$）。因此存在 (a,b) 中的一个点 x^*，使得 $H(x^*)=0$，即 g 的一个不动点。在练习中可以容易地证明这个不动点是唯一的。

为了证明序列收敛到 x^*，我们计算

$$|x_n-x^*|=|g(x_{n-1})-g(x^*)|\le k|x_{n-1}-x^*|. \tag{4.2.8}$$

迭代该过程，我们得到

$$|x_n-x^*|\le k^n|x_0-x^*|. \tag{4.2.9}$$

由于 $k<1$，序列 k^n 在 $n\to\infty$ 时趋于 0，这证明了序列的收敛性。 □

注意到，如果我们有一个映射 $g:[a,b]\to\mathbb{R}$，使得 $|g'(x)|\ge k\ge 1$，$\forall x\in[a,b]$，且它在 $[a,b]$ 中有一个不动点，则前面定义的序列 (x_n) 在以下意义下是发散的。要么 x_n 离开 g 的定义域，要么

$$|x_n-x^*|\ge k^n|x_0-x^*|, \tag{4.2.10}$$

因此序列 (x_n) 远离 x^*（在最好的情况下，如果 $k=1$，它保持在恒定距离）。

我们说不动点方法具有**线性收敛性**，因为

$$|x_{n+1}-x^*|=|g(x_n)-g(x^*)|\le k|xd_n-x^*|. \tag{4.2.11}$$

与二分法一样，我们可以估计获得给定精度所需的迭代次数。事实上，您可以在练习中证明

$$|x_n-x^*|\le\frac{k^n}{1-k}|x_1-x_0|. \tag{4.2.12}$$

d 因此，对于给定的精度 ε，迭代次数 n 由下式给出：

$$\frac{k^n}{1-k}|x_1-x_0|\le\varepsilon\quad\Rightarrow\quad n\le\frac{\ln\left(\dfrac{(1-k)\varepsilon}{|x_1-x_0|}\right)}{\ln k}. \tag{4.2.13}$$

在前面的命题中，我们假设导数的绝对值在整个区间 $[a,b]$ 上以 1 为上界。如果我们考虑在引用的段落中处理的实数平方根的例子，我们描述了三个函数 g，对于它们，不动点 x^* 对应于这个平方根。计算相应的导数：

- $g_1(x)=\dfrac{a}{x}$，$g_1'(x)=-\dfrac{a}{x^2}$，$g_1'(x^*)=-1$，
- $g_2(x)=2x-\dfrac{a}{x}$，$g_2'(x)=2+\dfrac{a}{x^2}$，$g_2'(x^*)=3$，
- $g_3(x)=\dfrac{x}{2}+\dfrac{a}{2x}$，$g_3'(x)=\dfrac{1}{2}-\dfrac{a}{2x^2}$，$g_3'(x^*)=0$。

命题 4.2.3

设 x^* 是连续可导函数 g 的一个不动点，使得 $|g'(x^*)|<1$，则如果 x_0 足够接近 x^*，由 $x_{n+1}=g(x_n)$ 定义的序列 (x_n) 收敛到 x^*。

证明. 由于 g' 连续，存在一个包含 x^* 的区间，使得 $|g'(x)| < 1$。更精确地说，存在 $\alpha > 0$，使得

$$|g'(x)| < 1, \quad \forall x \in [x^* - \alpha, x^* + \alpha]. \tag{4.2.14}$$

然后容易证明 g 是从 $I = [x^* - \alpha, x^* + \alpha]$ 到自身的映射。事实上，如果 $x \in I$，

$$|g(x) - x^*| = |g(x) - g(x^*)| \le \max_{x \in I} |g'(x)| \cdot |x - x^*| \le \alpha. \tag{4.2.15}$$

另一方面，由于函数 $|g'|$ 连续，它在区间 I 上达到最大值，因此对于 I 中的所有 x，有 $|g'(x)| \le k < 1$。这使得我们可以应用引用段落的命题，从而证明如果 x_0 在 I 中，即足够接近 x^*，则序列 $x_{n+1} = g(x_n)$ 收敛到 x^*。 □

注意到，如果 $|g'(x^*)| > 1$，存在一个区间 $[x^* - \alpha, x^* + \alpha]$，在其上 $|g'(x)| \ge k > 1$。前面定义的序列 (x_n) 几乎不可能收敛到 x^*。事实上，如果我们从接近 x^* 的地方开始，有

$$|x_1 - x^*| \ge k|x_0 - x^*| > |x_0 - x^*|, \tag{4.2.16}$$

且 x_1 远离 x^*。这种情况将持续，直到我们离开区间 $[x^* - \alpha, x^* + \alpha]$。然后，由于我们不知道 g 的行为，后续的迭代可能" 重新进入" 该区间。我们收敛的唯一机会是" 落在" x^* 上。因此，在这种情况下不应使用此方法。

4.2.4 *Newton* 方法求解方程

Newton 方法用于计算 $f(x) = 0$ 的根，其中 f 是从 $[a, b]$ 到 $\mathbb{R}$ 的二次连续可导函数。其原理如下：设给定 x_0，我们在 x_0 处写出 *Taylor* 展开：

$$f(x) = f(x_0) + (x - x_0)f'(x_0) + (x - x_0)^2 R(x - x_0). \tag{4.2.17}$$

Newton 方法在于忽略高于 1 阶的项（这等价于在局部将曲线近似为其切线），然后认为 x_1 是使如此得到的 f 的近似值等于零的点，即

$$0 = f(x_0) + (x_1 - x_0)f'(x_0), \tag{4.2.18}$$

这给出

$$x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}. \tag{4.2.19}$$

这样描述的从 x_0 到 x_1 的步骤也允许从 x_n 到 x_{n+1}。

求解方程 $f(x) = 0$ 的 Newton 算法如下：

$$\begin{cases} x_0 \text{ 给定}, \\ x_{n+1} = x_n - \dfrac{f(x_n)}{f'(x_n)}, \quad n \ge 0. \end{cases} \tag{4.2.20}$$

因此，这是一个不动点方法 $x_{n+1} = g(x_n)$，其中 g 定义为

$$g(x) = x - \frac{f(x)}{f'(x)}. \tag{4.2.21}$$

Newton 方法是一个不动点方法，使得 $g'(x^*)=0$，即导数在函数 g 的不动点处为零。

另一种更图形化的呈现 *Newton* 方法的方式，是将 x_{n+1} 作为曲线 $y=f(x)$ 在点 x_n 处的切线与 $0x$ 轴的交点（参见练习）。

如果不动点方法收敛到 x^*，则当 n 趋于 $+\infty$ 时取极限，有：

$$x^* = x^* - \frac{f(x^*)}{f'(x^*)}. \tag{4.2.22}$$

我们看到，如果 $f'(x^*)\neq 0$，则确实得到 $f(x^*)=0$。从现在起，我们假设这个条件满足，即曲线 $y=f(x)$ 在它与 Ox 轴相交时不是与该轴相切的。

4.2.5　*Newton* 方法求解方程的收敛性

命题 4.2.4

设 f 是在 $[a,b]$ 上二次连续可导的函数，$x^*\in[a,b]$ 使得 $f(x^*)=0$ 且 $f'(x^*)\neq 0$。则存在 $\alpha>0$，使得由 *Newton* 方法生成的序列

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)} \tag{4.2.23}$$

对任意 $x_0\in[x^*-\alpha, x^*+\alpha]$ 都收敛到 x^*。

证明. 由于这是一个函数 $g(x)=x-\dfrac{f(x)}{f'(x)}$ 的不动点方法，我们计算该函数在不动点处的导数：

$$\begin{aligned} g'(x) &= 1 - \frac{(f'(x))^2 - f''(x)f(x)}{(f'(x))^2} \\ &= \frac{f''(x)f(x)}{(f'(x))^2}, \end{aligned} \tag{4.2.24}$$

由于 $f(x^*)=0$，我们有 $g'(x^*)=0$。因此可以应用命题 4.2.3，它证明了存在 α，使得如果 $x_0\in[x^*-\alpha,x^*+\alpha]$，则序列 $x_{n+1}=g(x_n)$ 收敛到不动点。 □

这个命题给出了收敛的充分条件，但幸运的是，即使从远离解的地方开始，*Newton* 方法也经常收敛。现在让我们证明收敛速度是二次的，这比线性更好。

命题 4.2.5

设 g 是从 $[a,b]$ 到 $[a,b]$ 的二次连续可导函数，$x^*\in[a,b]$ 使得 $g(x^*)=x^*$ 且 $g'(x^*)=0$，$x_0\in[a,b]$，定义 $x_{n+1}=g(x_n)$，则：

$$|x_{n+1}-x^*| \leq \frac{M}{2}|x_n-x^*|^2, \tag{4.2.25}$$

其中 $M=\max_{x\in[a,b]}|g''(x)|$。

证明. 在点 x^* 处的 *Taylor* 展开由下式给出：

$$g(x_n) = g(x^*) + (x_n-x^*)g'(x^*) + \frac{(x_n-x^*)^2}{2}g''(\xi), \tag{4.2.26}$$

其中 ξ 严格位于 x_n 和 x^* 之间。根据 g 的假设，我们得到

$$|x_{n+1}-x^*| = \left|\frac{(x_n-x^*)^2}{2}g''(\xi)\right| \le \frac{M}{2}|x_n-x^*|^2. \tag{4.2.27}$$

我们说收敛速度是**二次的**。 □

4.2.6 割线法

该方法可以看作是 *Newton* 方法的近似，*Newton* 方法在引用的段落中已介绍。事实上，*Newton* 方法需要在每次迭代时计算函数在某点的导数。如果导数的计算在时间上昂贵或不够精确（例如它是数值近似的结果），我们可以用以下方式近似导数：

$$f'(x_n) = \frac{f(x_n)-f(x_{n-1})}{x_n-x_{n-1}}. \tag{4.2.28}$$

我们因此得到割线法：

$$\begin{cases} x_0, x_1 \text{ 给定，使得} f(x_0)f(x_1) < 0, \\ x_{n+1} = x_n - \dfrac{f(x_n)(x_n-x_{n-1})}{f(x_n)-f(x_{n-1})}. \end{cases} \tag{4.2.29}$$

这意味着，在图形上，我们用”弦”代替切线。实际上，这是通过点 $(x_n, f(x_n))$ 和 $(x_{n-1}, f(x_{n-1}))$ 的直线与 Ox 轴的交点（练习）。

该方法不是不动点方法，因为序列的每个点都是从前面两个点构造的。序列的收敛性只能对某些足够接近 x^*（$f(x^*)=0$ 的解）的 x_0 和 x_1 值得到保证。误差的研究是复杂的，但它表明

$$|x_{n+1}-x^*| \le K|x_n-x^*|^{\frac{1+\sqrt{5}}{2}}, \tag{4.2.30}$$

其中 K 是依赖于函数 f 和根 x^* 的常数。收敛速度等于黄金比例，大于线性收敛但小于二次收敛，因为

$$1 < \frac{1+\sqrt{5}}{2} < 2. \tag{4.2.31}$$

因此，该方法应该比 *Newton* 方法收敛得慢。但是割线法的一次迭代只需要在点 x_n 处计算一次 f（除了第一次迭代），而 *Newton* 方法需要计算 f 和 f'。因此，即使我们假设计算 f 和 f' 的成本相同，*Newton* 方法的一次迭代相当于割线法的两次迭代。因此，对于收敛速度的比较，需要将 $\sqrt{2}=1.414$ 与 $(1+\sqrt{5})/2=1.618$ 进行比较，因此比较结果有利于割线法。

然而，如我们所描述的割线法的一个缺点是，如果两个连续的点在一条”几乎平行”于 Ox 轴的直线上，与 Ox 轴的交点会趋向”无穷”。该方法的一个变体是确保两个连续的点总是包围 f 的根。因此，我们从包围 x^* 的 x_0 和 x_1 开始，为了计算 x_{n+1}，只有当 x_n 和 x_{n-1} 包围 x^* 时才使用它们。否则，我们使用 x_n 和 x_{n-2}。可以证明，对于在 x^* 附近凹性符号恒定的函数 f，用于计算 x_{n+1} 的点之一会固定（练习），使得该方法的行为如同

$$x_{n+1} = x_n - \frac{f(x_n)(x_n-x_0)}{f(x_n)-f(x_0)}. \tag{4.2.32}$$

我们因此回到一个具有线性收敛速度的不动点方法。我们因此以收敛速度为代价获得了全局收敛性。

4.3　非线性方程组的求解

4.3.1　两个非线性方程的 *Newton* 方法

我们现在希望求解两个方程两个未知数：

$$f_1(x_1,x_2)=0,\quad f_2(x_1,x_2)=0. \tag{4.3.1}$$

我们现在处理 $\mathbb{R}^2$ 中的向量，可以记为

$$\boldsymbol{x}=\begin{pmatrix}x_1\\x_2\end{pmatrix},\quad \boldsymbol{f}(\boldsymbol{x})=\begin{pmatrix}f_1(\boldsymbol{x})\\f_2(\boldsymbol{x})\end{pmatrix}=\begin{pmatrix}f_1(x_1,x_2)\\f_2(x_1,x_2)\end{pmatrix}. \tag{4.3.2}$$

与我们在本章中看到的所有迭代方法一样，我们将构造一个向量序列，期望它收敛到 $\boldsymbol{f}(\boldsymbol{x})=\boldsymbol{0}$ 的解，我们将序列的向量记为 $\boldsymbol{x}^{(0)},\boldsymbol{x}^{(1)},\ldots,\boldsymbol{x}^{(k)},\ldots$。

我们用于引入单方程 *Newton* 方法的一阶 *Taylor* 展开近似可以推广到两个方程，甚至 n 个方程。让我们对两个方程进行显式展开：

设 $\boldsymbol{x}^{(0)}$ 是一个给定的向量。在该点写出 *Taylor* 展开：

$$\begin{cases} f_1(\boldsymbol{x})=f_1(\boldsymbol{x}^{(0)})+\dfrac{\partial f_1}{\partial x_1}(\boldsymbol{x}^{(0)})(x_1-x_1^{(0)})+\dfrac{\partial f_1}{\partial x_2}(\boldsymbol{x}^{(0)})(x_2-x_2^{(0)})+\text{余项},\\[2ex] f_2(\boldsymbol{x})=f_2(\boldsymbol{x}^{(0)})+\dfrac{\partial f_2}{\partial x_1}(\boldsymbol{x}^{(0)})(x_1-x_1^{(0)})+\dfrac{\partial f_2}{\partial x_2}(\boldsymbol{x}^{(0)})(x_2-x_2^{(0)})+\text{余项}. \end{cases} \tag{4.3.3}$$

如果我们记 $D\boldsymbol{f}(\boldsymbol{x}^{(0)})$ 为 $\boldsymbol{f}$ 在点 $\boldsymbol{x}^{(0)}$ 处的 ***Jacobi* 矩阵**，定义为：

$$D\boldsymbol{f}(\boldsymbol{x}^{(0)})=\begin{pmatrix}\dfrac{\partial f_1}{\partial x_1}(\boldsymbol{x}^{(0)}) & \dfrac{\partial f_1}{\partial x_2}(\boldsymbol{x}^{(0)})\\ \dfrac{\partial f_2}{\partial x_1}(\boldsymbol{x}^{(0)}) & \dfrac{\partial f_2}{\partial x_2}(\boldsymbol{x}^{(0)})\end{pmatrix}=\begin{pmatrix}(\nabla f_1(\boldsymbol{x}^{(0)}))^T\\(\nabla f_2(\boldsymbol{x}^{(0)}))^T\end{pmatrix}, \tag{4.3.4}$$

其中

$$\nabla f_1(\boldsymbol{x}^{(0)})=\begin{pmatrix}\dfrac{\partial f_1}{\partial x_1}(\boldsymbol{x}^{(0)})\\ \dfrac{\partial f_1}{\partial x_2}(\boldsymbol{x}^{(0)})\end{pmatrix},\quad \nabla f_2(\boldsymbol{x}^{(0)})=\begin{pmatrix}\dfrac{\partial f_2}{\partial x_1}(\boldsymbol{x}^{(0)})\\ \dfrac{\partial f_2}{\partial x_2}(\boldsymbol{x}^{(0)})\end{pmatrix}, \tag{4.3.5}$$

前面的关系可以写成：

$$\boldsymbol{f}(\boldsymbol{x})=\boldsymbol{f}(\boldsymbol{x}^{(0)})+D\boldsymbol{f}(\boldsymbol{x}^{(0)})(\boldsymbol{x}-\boldsymbol{x}^{(0)})+\text{余项}, \tag{4.3.6}$$

或者：

$$\boldsymbol{f}(\boldsymbol{x})=\boldsymbol{f}(\boldsymbol{x}^{(0)})+\begin{pmatrix}(\nabla f_1(\boldsymbol{x}^{(0)}))^T(\boldsymbol{x}-\boldsymbol{x}^{(0)})\\(\nabla f_2(\boldsymbol{x}^{(0)}))^T(\boldsymbol{x}-\boldsymbol{x}^{(0)})\end{pmatrix}+\text{余项}. \tag{4.3.7}$$

注意： $\boldsymbol{f}(\boldsymbol{x})$、$\boldsymbol{f}(\boldsymbol{x}^{(0)})$、$\boldsymbol{x}-\boldsymbol{x}^{(0)}$、”余项”、$\nabla f_1(\boldsymbol{x}^{(0)})$、$\nabla f_2(\boldsymbol{x}^{(0)})$ 都是列向量。$D\boldsymbol{f}(\boldsymbol{x}^{(0)})$ 是一个矩阵。$D\boldsymbol{f}(\boldsymbol{x}^{(0)})(\boldsymbol{x}-\boldsymbol{x}^{(0)})$ 是一个列向量。因此所有的乘积和求和都是一致的。

忽略余项，我们通过使如此得到的 $\boldsymbol{f}$ 的近似值等于零来计算下一个迭代 $\boldsymbol{x}^{(1)}$：

$$\mathbf{0} = \boldsymbol{f}(\boldsymbol{x}^{(0)}) + D\boldsymbol{f}(\boldsymbol{x}^{(0)})(\boldsymbol{x}^{(1)} - \boldsymbol{x}^{(0)}). \tag{4.3.8}$$

向量 $\boldsymbol{x}^{(1)} - \boldsymbol{x}^{(0)}$ 通过求解线性方程组来计算：

$$D\boldsymbol{f}(\boldsymbol{x}^{(0)})(\boldsymbol{x}^{(1)} - \boldsymbol{x}^{(0)}) = -\boldsymbol{f}(\boldsymbol{x}^{(0)}). \tag{4.3.9}$$

当我们得到向量 $\boldsymbol{h} = \boldsymbol{x}^{(1)} - \boldsymbol{x}^{(0)}$ 后，我们计算 $\boldsymbol{x}^{(1)} = \boldsymbol{h} + \boldsymbol{x}^{(0)}$。

我们对向量 $\boldsymbol{x}^{(1)}$ 重复相同的步骤以获得向量 $\boldsymbol{x}^{(2)}$。当两个连续迭代的差值，即向量 $\boldsymbol{h}$ 的范数小于事先固定的 ε 时，我们停止。

求解两个非线性方程组 $\boldsymbol{f}(\boldsymbol{x}) = \mathbf{0}$ 的 *Newton* 方法由下式给出：

给定 $\boldsymbol{x}^{(0)} \in \mathbb{R}^2$，然后对 $k \geq 0$：

1. 求解线性方程组 $D\boldsymbol{f}(\boldsymbol{x}^{(k)})\boldsymbol{h} = -\boldsymbol{f}(\boldsymbol{x}^{(k)})$。
2. 设 $\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} + \boldsymbol{h}$。

当涉及两个非线性方程时，很容易求逆矩阵来求解方程组。相反，当我们需要求解 n 个非线性方程时，我们使用 *Gauss* 方法来求解允许计算两个连续迭代差值的线性方程组。

4.3.2 不动点方法

本段落中呈现的结果是在引用的段落中呈现的一维结果的推广。g 是从 $\mathbb{R}^n$ 到 $\mathbb{R}^n$ 的函数，$\boldsymbol{x}$ 和 $g(\boldsymbol{x})$ 是向量。与之前一样，我们构造一个由下式定义的序列：

$$\begin{cases} \boldsymbol{x}^{(0)} \text{ 给定}, \\ \boldsymbol{x}^{(k+1)} = g(\boldsymbol{x}^{(k)}). \end{cases} \tag{4.3.10}$$

当” 一切顺利” 时，该序列收敛到满足 $\hat{\boldsymbol{x}} = g(\hat{\boldsymbol{x}})$ 的 $\hat{\boldsymbol{x}}$。

我们将给出两个主要定理，您可以在文档中找到它们的证明。

定理 4.3.1

设 g 是从 $\mathbb{R}^n$ 到 $\mathbb{R}^n$ 的映射，λ 是实数，$0 \leq \lambda < 1$，使得对于 $\mathbb{R}^n$ 中的任意 $\boldsymbol{z}$ 和 $\boldsymbol{y}$，有

$$\|g(\boldsymbol{z}) - g(\boldsymbol{y})\| \leq \lambda \|\boldsymbol{z} - \boldsymbol{y}\|. \tag{4.3.11}$$

则存在唯一的 $\hat{\boldsymbol{x}} \in \mathbb{R}^n$，使得 $\hat{\boldsymbol{x}} = g(\hat{\boldsymbol{x}})$，且由

$$\begin{cases} \boldsymbol{x}^{(0)} \text{ 给定}, \\ \boldsymbol{x}^{(k+1)} = g(\boldsymbol{x}^{(k)}) \end{cases} \tag{4.3.12}$$

定义的序列 $\{\boldsymbol{x}^{(k)}\}_{k \geq 0}$ 收敛到 $\hat{\boldsymbol{x}}$。

定义 4.3.1

设 g 是从 $\mathbb{R}^n$ 到 $\mathbb{R}^n$ 的函数。我们称 g 在 $\boldsymbol{x}$ 处的 ***Jacobi* 矩阵**为矩阵 $Dg(\boldsymbol{x}) \in \mathscr{M}_{n,n}(\mathbb{R})$，定义为

$$Dg(\boldsymbol{x}) = \begin{pmatrix} \dfrac{\partial g_1}{\partial x_1}(\boldsymbol{x}) & \dots & \dfrac{\partial g_1}{\partial x_n}(\boldsymbol{x}) \\ \vdots & \ddots & \vdots \\ \dfrac{\partial g_n}{\partial x_1}(\boldsymbol{x}) & \dots & \dfrac{\partial g_n}{\partial x_n}(\boldsymbol{x}) \end{pmatrix}, \tag{4.3.13}$$

其中 $g_1, \dots, g_n$ 表示 g 的分量。

定义 4.3.2

如果 g 在 $\boldsymbol{x}$ 处有偏导数，且 *Jacobi* 矩阵 $Dg(\boldsymbol{x})$ 满足

$$g(\boldsymbol{y}) = g(\boldsymbol{x}) + Dg(\boldsymbol{x})(\boldsymbol{y} - \boldsymbol{x}) + \|\boldsymbol{y} - \boldsymbol{x}\|\boldsymbol{\varepsilon}(\boldsymbol{y} - \boldsymbol{x}), \tag{4.3.14}$$

其中 $\boldsymbol{\varepsilon}(\boldsymbol{y} - \boldsymbol{x})$ 是 $\mathbb{R}^n$ 中的向量，当 $\boldsymbol{y}$ 趋于 $\boldsymbol{x}$ 时趋于 $\mathbf{0}$，则函数 g 在 $\boldsymbol{x}$ 处**可微**。

下面的定理（其证明是微妙的）将不动点方法的收敛性与 *Jacobi* 矩阵的谱半径联系起来：

定理 4.3.2

设 g 是从 $\mathbb{R}^n$ 到 $\mathbb{R}^n$ 的映射，它有一个不动点 $\hat{\boldsymbol{x}}$，假设 g 在 $\hat{\boldsymbol{x}}$ 处可微，且 $\rho[Dg(\hat{\boldsymbol{x}})]$（$g$ 的 *Jacobi* 矩阵的谱半径）满足 $\rho[Dg(\hat{\boldsymbol{x}})] < 1$。则存在 η，使得如果 $\boldsymbol{x}^{(0)}$ 满足 $\|\boldsymbol{x}^{(0)} - \hat{\boldsymbol{x}}\| < \eta$，由

$$\boldsymbol{x}^{(k+1)} = g(\boldsymbol{x}^{(k)}) \tag{4.3.15}$$

定义的序列收敛到 $\hat{\boldsymbol{x}}$。

可以证明得到的收敛是线性的，即存在 $C > 0$，使得

$$\|\boldsymbol{x}^{(k+1)} - \hat{\boldsymbol{x}}\| \le C\|\boldsymbol{x}^{(k)} - \hat{\boldsymbol{x}}\|. \tag{4.3.16}$$

当我们有估计

$$\|\boldsymbol{x}^{(k+1)} - \hat{\boldsymbol{x}}\| \le C\|\boldsymbol{x}^{(k)} - \hat{\boldsymbol{x}}\|^n, \tag{4.3.17}$$

我们说收敛是 n **阶的**。

4.3.3　非线性方程组的 *Newton* 方法

我们希望求解非线性方程组 $\boldsymbol{f}(\boldsymbol{x}) = \mathbf{0}$。与 $n = 1$ 的情况一样，*Newton* 方法的思想在于考虑 $\boldsymbol{f}$ 在 $\boldsymbol{x}^{(k)}$ 处的仿射近似，即

$$\boldsymbol{f}(\boldsymbol{x}^{(k)} + \boldsymbol{h}) = \boldsymbol{f}(\boldsymbol{x}^{(k)}) + D\boldsymbol{f}(\boldsymbol{x}^{(k)})\boldsymbol{h} + \|\boldsymbol{h}\|\boldsymbol{\varepsilon}(\boldsymbol{h}), \tag{4.3.18}$$

如果 $\boldsymbol{f}$ 可微，其中我们记 $D\boldsymbol{f}(\boldsymbol{x})$ 为 $\boldsymbol{f}$ 的 *Jacobi* 矩阵。然后我们确定 $\boldsymbol{h}$，使得

$$\boldsymbol{f}(\boldsymbol{x}^{(k)}) + D\boldsymbol{f}(\boldsymbol{x}^{(k)})\boldsymbol{h} = \mathbf{0}, \tag{4.3.19}$$

然后 $\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} + \boldsymbol{h}$。

求解非线性方程组 $\boldsymbol{f}(\boldsymbol{x}) = \boldsymbol{0}$ 的 *Newton* 方法由下式给出：

给定 $\boldsymbol{x}^{(0)} \in \mathbb{R}^n$，然后对 $k \geq 0$：

1. 求解线性方程组 $D\boldsymbol{f}(\boldsymbol{x}^{(k)})\boldsymbol{h} = -\boldsymbol{f}(\boldsymbol{x}^{(k)})$。
2. 设 $\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} + \boldsymbol{h}$。

这就是我们在引用的段落中看到的，该段落处理两个非线性方程的特殊情况。

定理 4.3.3

设 $\boldsymbol{f}$ 是从 $\mathbb{R}^n$ 到 $\mathbb{R}^n$ 的映射。我们希望通过 *Newton* 方法求解 $\boldsymbol{f}(\boldsymbol{x}) = \boldsymbol{0}$。如果存在 $\hat{\boldsymbol{x}}$，使得

- $\boldsymbol{f}(\hat{\boldsymbol{x}}) = \boldsymbol{0}$，
- $\boldsymbol{f}$ 在 $\hat{\boldsymbol{x}}$ 的邻域内可微，且 $\|D\boldsymbol{f}(\boldsymbol{x}) - D\boldsymbol{f}(\hat{\boldsymbol{x}})\| \leq \alpha\|\boldsymbol{x} - \hat{\boldsymbol{x}}\|$，
- $D\boldsymbol{f}(\hat{\boldsymbol{x}})$ 可逆，

则存在严格正实数 η，使得如果 $\boldsymbol{x}^{(0)}$ 满足 $\|\boldsymbol{x}^{(0)} - \hat{\boldsymbol{x}}\| < \eta$，则由 *Newton* 方法构造的序列收敛到 $\hat{\boldsymbol{x}}$。此外，得到的收敛是 **2 阶的**，或**二次的**，即存在常数 $C > 0$，使得

$$\|\boldsymbol{x}^{(k+1)} - \hat{\boldsymbol{x}}\| \leq C\|\boldsymbol{x}^{(k)} - \hat{\boldsymbol{x}}\|^2. \tag{4.3.20}$$

我们不证明这个结果，它是 $n = 1$ 情况下相应假设的" 翻译"。我们还将注意到收敛非常快（二次的）。

4.4 第四章文档

4.4.1 非线性系统的不动点定理

我们知道如何用极限来定义序列的收敛性。如果我们不知道这个极限，可以证明一个序列收敛当且仅当它是 *Cauchy* 序列，其定义如下。

定义 4.4.1

如果满足

$$\forall \varepsilon > 0, \quad \exists N(\varepsilon) \in \mathbb{N} \text{ 使得} \forall k \geq N(\varepsilon), \quad \forall p \geq 0, \quad \|\boldsymbol{x}^{(k+p)} - \boldsymbol{x}^{(k)}\| \leq \varepsilon, \tag{4.4.1}$$

则称序列 $\{\boldsymbol{x}^{(k)}\}$ 是 ***Cauchy* 序列**。

这使我们能够陈述一些关于不动点方法的结果。

定理 4.4.1

设 g 是从 $\mathbb{R}^n$ 到 $\mathbb{R}^n$ 的映射，λ 是实数，$0 \le \lambda < 1$，使得对于 $\mathbb{R}^n$ 中的任意 $\boldsymbol{x}$ 和 $\boldsymbol{y}$，有

$$\|g(\boldsymbol{x}) - g(\boldsymbol{y})\| \le \lambda \|\boldsymbol{x} - \boldsymbol{y}\|. \tag{4.4.2}$$

则存在唯一的 $\hat{\boldsymbol{x}} \in \mathbb{R}^n$，使得 $\hat{\boldsymbol{x}} = g(\hat{\boldsymbol{x}})$，且由

$$\begin{cases} \boldsymbol{x}^{(0)} \text{ 给定}, \\ \boldsymbol{x}^{(k+1)} = g(\boldsymbol{x}^{(k)}) \end{cases} \tag{4.4.3}$$

定义的序列 $\{\boldsymbol{x}^{(k)}\}_{k \ge 0}$ 收敛到 $\hat{\boldsymbol{x}}$。

证明. 我们有

$$\|\boldsymbol{x}^{(k+1)} - \boldsymbol{x}^{(k)}\| \le \lambda \|\boldsymbol{x}^{(k)} - \boldsymbol{x}^{(k-1)}\| \le \cdots \le \lambda^k \|\boldsymbol{x}^{(1)} - \boldsymbol{x}^{(0)}\|. \tag{4.4.4}$$

另一方面

$$\begin{aligned} \boldsymbol{x}^{(k+p)} - \boldsymbol{x}^{(k)} = {} & \boldsymbol{x}^{(k+p)} - \boldsymbol{x}^{(k+p-1)} + \boldsymbol{x}^{(k+p-1)} - \boldsymbol{x}^{(k+p-2)} + \cdots \\ & + \boldsymbol{x}^{(k+2)} - \boldsymbol{x}^{(k+1)} + \boldsymbol{x}^{(k+1)} - \boldsymbol{x}^{(k)}. \end{aligned} \tag{4.4.5}$$

因此可以写成

$$\begin{aligned} \|\boldsymbol{x}^{(k+p)} - \boldsymbol{x}^{(k)}\| &\le \|\boldsymbol{x}^{(k+p)} - \boldsymbol{x}^{(k+p-1)}\| + \cdots + \|\boldsymbol{x}^{(k+2)} - \boldsymbol{x}^{(k+1)}\| + \|\boldsymbol{x}^{(k+1)} - \boldsymbol{x}^{(k)}\| \\ &\le (\lambda^{k+p-1} + \cdots + \lambda^{k+1} + \lambda^k)\|\boldsymbol{x}^{(1)} - \boldsymbol{x}^{(0)}\| \\ &\le \lambda^k (1 + \lambda + \cdots + \lambda^{p-1})\|\boldsymbol{x}^{(1)} - \boldsymbol{x}^{(0)}\| \\ &= \lambda^k \frac{1 - \lambda^p}{1 - \lambda}\|\boldsymbol{x}^{(1)} - \boldsymbol{x}^{(0)}\| \\ &\le \frac{\lambda^k}{1 - \lambda}\|\boldsymbol{x}^{(1)} - \boldsymbol{x}^{(0)}\|. \end{aligned} \tag{4.4.6}$$

量 $\|\boldsymbol{x}^{(k+p)} - \boldsymbol{x}^{(k)}\|$ 因此当 k 趋于无穷时趋于零；因此序列是 *Cauchy* 序列，所以它是收敛的。我们记 $\hat{\boldsymbol{x}}$ 为该序列的极限。有

$$\|g(\boldsymbol{x}^{(k)}) - g(\hat{\boldsymbol{x}})\| \le \lambda \|\boldsymbol{x}^{(k)} - \hat{\boldsymbol{x}}\|, \tag{4.4.7}$$

因此 $g(\boldsymbol{x}^{(k)})$ 的极限是 $g(\hat{\boldsymbol{x}})$。我们有 $g(\hat{\boldsymbol{x}}) = \hat{\boldsymbol{x}}$，因为

$$\hat{\boldsymbol{x}} = \lim_{k \to \infty} \boldsymbol{x}^{(k+1)} = \lim_{k \to \infty} g(\boldsymbol{x}^{(k)}) = g(\hat{\boldsymbol{x}}). \tag{4.4.8}$$

这样构造的序列因此收敛到 $g(\boldsymbol{x}) = \boldsymbol{x}$ 的解。现在证明该方程有唯一解：假设存在两个解 $\boldsymbol{u}$ 和 $\boldsymbol{v}$，因此有 $\boldsymbol{u} = g(\boldsymbol{u})$，$\boldsymbol{v} = g(\boldsymbol{v})$，因此 $g(\boldsymbol{u}) - g(\boldsymbol{v}) = \boldsymbol{u} - \boldsymbol{v}$。而 $\|g(\boldsymbol{u}) - g(\boldsymbol{v})\| \le \lambda \|\boldsymbol{u} - \boldsymbol{v}\|$，因此有

$$\|\boldsymbol{u} - \boldsymbol{v}\| \le \lambda \|\boldsymbol{u} - \boldsymbol{v}\|, \quad \text{即} \quad \|\boldsymbol{u} - \boldsymbol{v}\|(1 - \lambda) \le 0, \tag{4.4.9}$$

其中 $\lambda < 1$。这只有在 $\|\boldsymbol{u} - \boldsymbol{v}\| = 0$ 时才有可能，因此 $\boldsymbol{u} = \boldsymbol{v}$。这完成了定理的证明。 □

下面的定理（其证明是微妙的）将不动点方法的收敛性与 *Jacobi* 矩阵的谱半径联系起来：

定理 4.4.2

设 g 是从 $\mathbb{R}^n$ 到 $\mathbb{R}^n$ 的映射，它有一个不动点 $\hat{\boldsymbol{x}}$，假设 g 在 $\hat{\boldsymbol{x}}$ 处可微，且 $\rho[Dg(\hat{\boldsymbol{x}})]$（$g$ 的 *Jacobi* 矩阵的谱半径）满足 $\rho[Dg(\hat{\boldsymbol{x}})] < 1$。则存在 η，使得如果 $\boldsymbol{x}^{(0)}$ 满足 $\|\boldsymbol{x}^{(0)} - \hat{\boldsymbol{x}}\| < \eta$，由

$$\boldsymbol{x}^{(k+1)} = g(\boldsymbol{x}^{(k)}) \tag{4.4.10}$$

定义的序列收敛到 $\hat{\boldsymbol{x}}$。

证明. 利用关于矩阵范数的结果，可以证明，如果我们记

$$\hat{\varepsilon} = \frac{1 - \rho[Dg(\hat{\boldsymbol{x}})]}{3} > 0, \tag{4.4.11}$$

可以找到一个从属矩阵范数，使得

$$0 \le \|Dg(\hat{\boldsymbol{x}})\| \le \rho[Dg(\hat{\boldsymbol{x}})] + \hat{\varepsilon}, \tag{4.4.12}$$

因此在后续中我们将使用这个矩阵范数和相应的向量范数。

利用可微性的定义，我们得到：

$$\begin{aligned}
\|g(\boldsymbol{x}) - g(\hat{\boldsymbol{x}})\| &= \|Dg(\hat{\boldsymbol{x}})(\boldsymbol{x} - \hat{\boldsymbol{x}}) + \|\boldsymbol{x} - \hat{\boldsymbol{x}}\|\boldsymbol{\varepsilon}(\boldsymbol{x} - \hat{\boldsymbol{x}})\| \\
&\le \|Dg(\hat{\boldsymbol{x}})(\boldsymbol{x} - \hat{\boldsymbol{x}})\| + \|\boldsymbol{x} - \hat{\boldsymbol{x}}\|\|\boldsymbol{\varepsilon}(\boldsymbol{x} - \hat{\boldsymbol{x}})\| \\
&\le \|Dg(\hat{\boldsymbol{x}})\|\|\boldsymbol{x} - \hat{\boldsymbol{x}}\| + \|\boldsymbol{x} - \hat{\boldsymbol{x}}\|\|\boldsymbol{\varepsilon}(\boldsymbol{x} - \hat{\boldsymbol{x}})\| \\
&= \|\boldsymbol{x} - \hat{\boldsymbol{x}}\|(\|Dg(\hat{\boldsymbol{x}})\| + \|\boldsymbol{\varepsilon}(\boldsymbol{x} - \hat{\boldsymbol{x}})\|).
\end{aligned} \tag{4.4.13}$$

而 $\|\boldsymbol{\varepsilon}(\boldsymbol{x} - \hat{\boldsymbol{x}})\|$ 当 $\boldsymbol{x}$ 趋于 $\hat{\boldsymbol{x}}$ 时趋于 0，因此存在 η，使得

$$\|\boldsymbol{x} - \hat{\boldsymbol{x}}\| < \eta \quad \Rightarrow \quad \|\boldsymbol{\varepsilon}(\boldsymbol{x} - \hat{\boldsymbol{x}})\| \le \hat{\varepsilon}. \tag{4.4.14}$$

我们因此得到：

$$(\|Dg(\hat{\boldsymbol{x}})\| + \|\boldsymbol{\varepsilon}(\boldsymbol{x} - \hat{\boldsymbol{x}})\|) \le \rho[Dg(\hat{\boldsymbol{x}})] + \hat{\varepsilon} + \hat{\varepsilon} = \lambda. \tag{4.4.15}$$

而 $\lambda = \rho[Dg(\hat{\boldsymbol{x}})] + 2\hat{\varepsilon} = 1 - \hat{\varepsilon} < 1$，因此我们证明了：

$$\|\boldsymbol{x} - \hat{\boldsymbol{x}}\| < \eta \quad \Rightarrow \quad \|g(\boldsymbol{x}) - g(\hat{\boldsymbol{x}})\| \le \lambda\|\boldsymbol{x} - \hat{\boldsymbol{x}}\|, \tag{4.4.16}$$

其中 $\lambda < 1$。证明的其余部分类似于 $n = 1$ 的情况。 □

Chapter 5

插值

5.1　引言

5.1.1　函数的逼近

在解决某些数值问题时，我们会遇到以下情况：我们希望计算函数 $f(t)$ 在大量 t 值处的值，但我们不知道 f 的" 显式" 表达式。这种情况发生在：

- f 只在某些实验点 $t_0, t_1, \ldots, t_n$ 处已知，
- 或者函数 f 由计算成本高昂的计算代码进行数值计算。

我们希望用一个计算简单的函数来" 表示" f。

换句话说，这是用另一个更容易计算的函数来逼近函数 f。这个近似函数 $\tilde{f}$ 选自一个计算成本不太高的函数类 $\tilde{F}$。例如多项式集合、有理分式集合、三角多项式集合等。

问题在于我们希望以何种意义逼近 f。有很多种可能性。我们列举最常见的几种：

- 我们可以寻找一个函数 $\tilde{f} \in \tilde{F}$，使得：

$$\forall i = 0, 1, \ldots, n, \quad \tilde{f}(t_i) = f(t_i). \tag{5.1.1}$$

  这是**插值**技术。

- 我们可以寻找一个函数 $\tilde{f} \in \tilde{F}$，它最小化两条曲线在横坐标为 t_i（$0 \le i \le n$）的点处的差值：

$$\sum_{i=0}^{n} (\tilde{f}(t_i) - f(t_i))^2 = \min_{g \in \tilde{F}} \sum_{i=0}^{n} (g(t_i) - f(t_i))^2. \tag{5.1.2}$$

  这是**最小二乘**最小化技术，这在另一章中研究。

- 我们可以寻找一个函数 $\tilde{f} \in \tilde{F}$，使得

$$\int_a^b |f(x) - \tilde{f}(x)|^2 \, dx = \min_{g \in \tilde{F}} \int_a^b |f(x) - g(x)|^2 \, dx. \tag{5.1.3}$$

  这是**二次逼近**技术。

- 最后，我们可以寻找一个函数 $\tilde{f} \in \tilde{F}$，使得

$$\max_{x\in[a,b]} |f(x) - \tilde{f}(x)| = \min_{g\in\tilde{F}} \left(\max_{x\in[a,b]} |f(x) - g(x)| \right). \tag{5.1.4}$$

这是**一致逼近**技术。

在本章的后续内容中，我们只处理插值。

5.1.2 插值

在以下所有内容中，我们假设给定两个 $n+1$ 个实数的族：

- **横坐标**：$\{t_0, t_1, \ldots, t_n\}$，假设它们都互不相同，
- **对应的纵坐标**：$\{y_0, y_1, \ldots, y_n\}$。这些值可以是，例如，$\{f(t_i)\}$，其中 f 是我们希望表示的函数。

我们然后寻找一个函数 h，它在每个点 t_i 处取值 y_i，这对 $i = 0, \ldots, n$ 成立。

显然，这个问题有无穷多个解。因此必须明确我们将在其中寻找 h 的函数类 $\tilde{F}$。

在以下内容中，我们将考虑两个特殊的函数类：

- 次数最多为 n 的多项式集合 P_n，
- **三次样条**集合，它们是定义为" 分段多项式" 的函数，每个多项式的次数为 3。

还存在其他插值方法。我们列举那些使用 f 在点 $t_0, t_1, \ldots, t_n$ 处的导数信息的方法。这是 ***Hermite* 插值**，我们在这里不讨论。我们只给出一个非常简单的例子。假设已知 f 及其直到 n 阶的导数在点 t_0 处的值。则满足

$$\forall i = 0, 1, \ldots, n, \quad P_n^{(i)}(t_0) = f^{(i)}(t_0) \tag{5.1.5}$$

的唯一 n 次多项式 P_n 由下式给出：

$$P_n(t) = f(t_0) + (t - t_0)f'(t_0) + \cdots + \frac{(t - t_0)^n}{n!} f^{(n)}(t_0). \tag{5.1.6}$$

这个多项式实际上就是 f 在点 $t = t_0$ 处的 n 阶 *Taylor* 展开的多项式部分。

5.2 多项式插值

5.2.1 *Lagrange* 基中的插值多项式

定理 5.2.1

给定 $n+1$ 个互异的实数 $(t_0, t_1, \ldots, t_n)$ 和 $n+1$ 个实数 $(y_0, y_1, \ldots, y_n)$，存在唯一的多项式 $p_n \in P_n$（次数 $\leq n$ 的多项式集合），使得

$$\forall i = 0, 1, \ldots, n, \quad p_n(t_i) = y_i. \tag{5.2.1}$$

证明. **1. 存在性**：通过直接展示所求的多项式来证明，即

$$p_n(t) = \sum_{i=0}^{n} y_i \mathscr{L}_i(t), \tag{5.2.2}$$

其中多项式 $\mathscr{L}_i$ 是 ***Lagrange* 基多项式**，其形式为

$$\mathscr{L}_i(t) = \prod_{k=0,k\neq i}^{n} \frac{t-t_k}{t_i-t_k}. \tag{5.2.3}$$

这些多项式被称为**基多项式**，因为它们生成次数小于或等于 n 的多项式空间 P_n。此外，我们引入它们而不是使用标准基 $\{1, t, t^2, \ldots, t^n\}$，是因为它们允许我们立即用多项式在点 t_i 处的值来表达任何次数小于或等于 n 的多项式。事实上，通过 $\mathscr{L}_i(t)$ 的构造，我们验证：

$$\mathscr{L}_i(t_j) = \begin{cases} 1, & \text{当} j = i, \\ 0, & \text{当} j \neq i. \end{cases} \tag{5.2.4}$$

2. 唯一性：证明如下：假设存在两个多项式 p_n 和 q_n 属于 $\mathscr{P}_n$，使得 $p_n(t_i) = q_n(t_i) = y_i$。则如果我们设 $d_n = p_n - q_n$，d_n 属于 $\mathscr{P}_n$ 且 $d_n(t_i) = 0$，$i = 0, \ldots, n$。换句话说，多项式 d_n 至少有 $n+1$ 个不同的根。它的次数小于或等于 n。因此它恒等于零，从而有 $p_n = q_n$。 □

5.2.2　插值的计算

设 $f : [a, b] \to \mathbb{R}$ 是一个给定的函数。我们构造多项式 $p_n(t)$，它在点 $t_0, t_1, \ldots, t_n$（$t_i \in [a, b]$）处插值 f 的值，这导致设 $p_n(t_i) = f(t_i)$，$i = 0, \ldots, n$。我们因此用多项式 p_n 逼近了函数 f。问题如下：当我们用 p_n 逼近 f 时，我们犯了什么误差？

假设和记号　在以下内容中，我们假设 f 在 $[a, b]$ 上 $(n+1)$ 次连续可导，我们记 $e_n(t)$ 为插值误差，定义为：

$$e_n(t) = f(t) - p_n(t). \tag{5.2.5}$$

设 $\mathrm{Int}(t, t_0, \ldots, t_n)$ 为包含点 $t, t_0, \ldots, t_n$ 的最小闭区间，$\pi_n(t)$ 为定义的函数：

$$\pi_n(t) = (t-t_0)(t-t_1)(t-t_2)\cdots(t-t_n). \tag{5.2.6}$$

定理 5.2.2

对任意 $t \in [a, b]$，存在 $\xi_t \in \mathrm{Int}(t, t_0, \ldots, t_n)$，依赖于 t，使得

$$e_n(t) = \frac{1}{(n+1)!} f^{(n+1)}(\xi_t)\pi_n(t). \tag{5.2.7}$$

证明. **1.** 如果存在 j 使得 $t = t_j$，则误差为零，公式 (5.2.7) 立即成立。

2. 如果对任意 j，$t \neq t_j$，则 $\pi_n(t) \neq 0$，我们可以定义一个变量 z 的函数 g_n：

$$g_n(z) = f(z) - p_n(z) - \frac{e_n(t)}{\pi_n(t)}\pi_n(z). \tag{5.2.8}$$

显然 $g_n(t) = 0$ 且 $g_n(t_j) = 0$，$j = 0, \ldots, n$。我们看到 $g_n(z)$ 在区间 $\mathrm{Int}(t, t_0, \ldots, t_n)$ 中消失 $n+2$ 次。通过多次应用 *Rolle* 定理[1]，我们看到：

- g_n' 在该区间中至少消失 $n+1$ 次，
- g_n'' 在该区间中至少消失 n 次，等等
- $g_n^{(n+1)}$ 在区间 $\mathrm{Int}(t, t_0, \ldots, t_n)$ 中至少消失 1 次。

记 $\xi_t \in \mathrm{Int}(t, t_0, \ldots, t_n)$ 为使得 $g_n^{(n+1)}(\xi_t) = 0$ 的 z 的值（或其中之一）。由于函数 g_n 依赖于 t，点 ξ_t 也依赖于 t。另一方面，由于 p_n 是 n 次多项式，$p_n^{(n+1)}(z) = 0$。

同样，由于 $\pi_n(t)$ 的最高次项是 t^{n+1}，我们有：

$$\pi_n^{(n+1)}(z) = (n+1)!, \tag{5.2.9}$$

因此

$$g_n^{(n+1)}(\xi_t) = f^{(n+1)}(\xi_t) - e_n(t)\frac{(n+1)!}{\pi_n(t)} = 0, \tag{5.2.10}$$

这证明了定理。 □

首先注意到，这个误差表达式只有在被插值的函数 f 是 $n+1$ 次连续可导时才有意义。如果不是这种情况，前面的误差表达式就不再定义。此外，可以实验验证，在这种情况下，用 n 次多项式插值 f 是没有用的。这是数值分析中的一般规则：当要逼近的函数没有所需的正则性时，使用为正则函数构造的高阶方法是无用的。

还注意到，在上面定理中得到的误差表达式是所谓的**误差估计**。它的价值在于它给出了误差的形式，并显示了当我们增加插值点的数量时，这个误差如何变化（除了 ξ 之外）。相反，它不允许我们计算给定点 t 处的误差 $e(t)$ 的值。事实上，点 ξ 是未知的（我们只知道它存在），更糟糕的是，我们通常不知道如何计算 f 的 $(n+1)$ 阶导数。事实上，如果我们逼近 f，那是因为我们不知道如何计算它，或者至少它的计算成本非常高。这通常排除了以可承受的成本计算 $f^{(n+1)}$ 的任何可能性。

5.2.3 *Newton* 基中的插值多项式

我们引入了次数小于或等于 n 的多项式空间 P_n 的一个新基：*Lagrange* 基。这使我们能够通过给出插值多项式在该基中的分量来证明插值多项式的存在性。然而，*Lagrange* 基在计算插值多项式在一个或多个点处的值时非常不方便。标准基也不更合适，因此我们将引入第三个基。给定 $n+1$ 个点 $t_0, t_1, \ldots, t_n$，***Newton* 基**定义为：

$$\{1, (t-t_0), (t-t_0)(t-t_1), \ldots, (t-t_0)(t-t_1)\cdots(t-t_{n-1})\}. \tag{5.2.11}$$

[1]如果 f 在 $[a,b]$ 上连续可导且 $f(a) = f(b)$，则存在至少一个实数 $c \in (a,b)$，使得 $f'(c) = 0$。

我们将展示如何计算次数小于或等于 n 的多项式 p_n 的系数，该多项式在点 $t_0, t_1, \ldots, t_n$ 处插值函数 f。该多项式写成：

$$p_n(t) = c_0 + c_1(t - t_0) + \cdots + c_n(t - t_0)(t - t_1)\cdots(t - t_{n-1}). \tag{5.2.12}$$

注意到系数 c_n 是 p_n 中 t^n 的系数。这就是所谓的 p_n 的**首项系数**。

用 *Newton* 基表示的多项式 p_n 的一个优点是：如果我们记 p_k 为截断多项式，即：

$$p_k(t) = c_0 + c_1(t - t_0) + \cdots + c_k(t - t_0)(t - t_1)\cdots(t - t_{k-1}), \quad k = 0, \ldots, n, \tag{5.2.13}$$

则 p_k 是在点 $t_0, \ldots, t_k$ 处插值 f 的次数小于或等于 k 的多项式，事实上我们有

$$p_n(t) = p_k(t) + c_{k+1}(t - t_0)(t - t_1)\cdots(t - t_k) + \cdots + c_n(t - t_0)(t - t_1)\cdots(t - t_{n-1}), \tag{5.2.14}$$

因此 $p_k(t_0) = p_n(t_0) = f(t_0)$，$p_k(t_1) = p_n(t_1) = f(t_1)$，…，$p_k(t_k) = p_n(t_k) = f(t_k)$。

我们因此特别有：

$$p_n(t) = p_{n-1}(t) + c_n(t - t_0)(t - t_1)\cdots(t - t_{n-1}), \tag{5.2.15}$$

因此如果我们知道多项式 p_{n-1} 并且添加一个插值点 t_n，系数 $c_0, \ldots, c_{n-1}$ 是相同的，只需计算系数 c_n 并在多项式 p_{n-1} 上添加项 $c_n(t - t_0)(t - t_1)\cdots(t - t_{n-1})$。

5.2.4　差商

定义 5.2.1

设函数 f 在互异点 $t_0, t_1, t_2, \ldots$ 处的值已知。我们称**差商**（或**差分商**）为以下迭代定义的表达式：

$$\begin{aligned} f[t_0] = f(t_0), \quad f[t_1] = f(t_1), \quad f[t_2] = f(t_2), \\ f[t_0, t_1] = \frac{f[t_0] - f[t_1]}{t_0 - t_1}, \quad f[t_1, t_2] = \frac{f[t_1] - f[t_2]}{t_1 - t_2}, \\ f[t_0, t_1, t_2] = \frac{f[t_0, t_1] - f[t_1, t_2]}{t_0 - t_2}. \end{aligned} \tag{5.2.16}$$

一般地，如果 X 是一个互异点的有限集合，如果 $a \notin X$ 且 $b \notin X$，如果 $a \neq b$，则

$$f[a, X, b] = \frac{f[a, X] - f[X, b]}{a - b}. \tag{5.2.17}$$

定理 5.2.3

设函数 f 在 $n+1$ 个互异点 t_i（$0 \leq i \leq n$）处的值已知，设 p_n 为插值多项式：

$$p_n(t) = c_0 + c_1(t - t_0) + c_2(t - t_0)(t - t_1) + \cdots + c_n(t - t_0)(t - t_1)\cdots(t - t_{n-1}). \tag{5.2.18}$$

则

$$\forall k = 0, \ldots, n, \quad f[t_0, t_1, \ldots, t_k] = c_k, \tag{5.2.19}$$

且

$$e_n(t) = f[t_0, t_1, \ldots, t_n, t](t - t_0)(t - t_1)(t - t_2) \cdots (t - t_n). \tag{5.2.20}$$

证明. 证明通过对插值点的数量进行归纳来完成。

基础情况：

- 如果 $n = 0$，p_0 是在 t_0 处插值 f 的常数多项式，因此

$$p_0(t) = f(t_0) = f[t_0]. \tag{5.2.21}$$

- 如果 $n = 1$，p_1 是在 t_0, t_1 处插值 f 的次数小于或等于 1 的多项式，我们写成

$$p_1(t) = c_0 + c_1(t - t_0), \quad p_1(t_0) = f(t_0), \quad p_1(t_1) = f(t_1), \tag{5.2.22}$$

我们得到

$$c_0 = f(t_0) = f[t_0], \quad c_1 = \frac{f(t_0) - f(t_1)}{t_0 - t_1} = f[t_0, t_1]. \tag{5.2.23}$$

归纳步骤：假设公式对在 $k + 1$ 个点处插值的多项式成立，例如 p_k 是在 $t_0, \ldots, t_k$ 处插值 f 的次数小于或等于 k 的多项式，它写成：

$$p_k(t) = f[t_0] + f[t_0, t_1](t - t_0) + \cdots + f[t_0, \ldots, t_k](t - t_0)(t - t_1) \cdots (t - t_{k-1}). \tag{5.2.24}$$

同样，q_k 是在 $t_1, \ldots, t_{k+1}$ 处插值 f 的次数小于或等于 k 的多项式，它写成：

$$q_k(t) = f[t_1] + f[t_1, t_2](t - t_1) + \cdots + f[t_1, \ldots, t_{k+1}](t - t_1)(t - t_2) \cdots (t - t_k). \tag{5.2.25}$$

如果我们定义多项式 p 为：

$$p(t) = \frac{(t - t_{k+1})p_k(t) - (t - t_0)q_k(t)}{t_0 - t_{k+1}}, \tag{5.2.26}$$

则 $p = p_{k+1}$，事实上 p 是次数小于或等于 $k + 1$ 的多项式，此外它在点 $t_0, t_1, \ldots, t_{k+1}$ 处插值 f，事实上：

$$\begin{aligned}
p(t_0) &= p_k(t_0) = f(t_0), \\
p(t_{k+1}) &= q_k(t_{k+1}) = f(t_{k+1}), \\
\text{对} i = 1, \ldots, k, \quad p(t_i) &= \frac{(t_i - t_{k+1})p_k(t_i) - (t_i - t_0)q_k(t_i)}{t_0 - t_{k+1}} \\
&= \frac{(t_i - t_{k+1}) - (t_i - t_0)}{t_0 - t_{k+1}} f(t_i) = f(t_i).
\end{aligned} \tag{5.2.27}$$

p_k 的首项系数，即 t^k 的系数，是 $f[t_0, \ldots, t_k]$；q_k 的首项系数，即 t^k 的系数，是 $f[t_1, \ldots, t_{k+1}]$；因此 p_{k+1} 的首项系数，即 t^{k+1} 的系数，是

$$c_{k+1} = \frac{f[t_0, \ldots, t_k] - f[t_1, \ldots, t_{k+1}]}{t_0 - t_{k+1}} = f[t_0, \ldots, t_{k+1}]. \tag{5.2.28}$$

另一方面，我们知道

$$p_{k+1}(t) = p_k(t) + c_{k+1}(t-t_0)(t-t_1)\cdots(t-t_k). \tag{5.2.29}$$

我们因此有

$$p_{k+1}(t) = f[t_0] + f[t_0,t_1](t-t_0) + \cdots + f[t_0,\ldots,t_{k+1}](t-t_0)(t-t_1)\cdots(t-t_k). \tag{5.2.30}$$

这完成了证明。 □

关于误差的计算，在练习 5.7 中有详细说明。

在文档中可以看到当点等距时差商的计算。

命题 5.2.1

差商 $f[t_0,t_1,\ldots,t_k]$ 是其自变量的对称函数。

证明. 数 $f[t_0,t_1,\ldots,t_k] = c_k$ 是在点 $\{t_0,t_1,\ldots,t_k\}$ 处插值 f 的次数小于或等于 k 的多项式中 t^k 项的系数。而这个多项式是唯一的，不依赖于我们给点编号的顺序，因此：

$$f[t_{\sigma(0)},t_{\sigma(1)},\ldots,t_{\sigma(k)}] = f[t_0,t_1,\ldots,t_k], \tag{5.2.31}$$

对整数 $\{0,1,2,\ldots,k\}$ 的任意置换 σ 成立。 □

5.2.5　差商的实际计算

回顾定义 5.2.4 中给出的差商表达式：

$$f[t_i] = f(t_i), \quad f[t_0,t_1,\ldots,t_k] = \frac{f[t_0,t_1,\ldots,t_{k-1}] - f[t_1,t_2,\ldots,t_k]}{t_0-t_k}. \tag{5.2.32}$$

使用这个公式可以逐步计算 $f[t_0,t_1,\ldots,t_k]$，使用下表（每一列从前一列推导）：

$k=0$	$k=1$	$k=2$	$\ldots$	$k=n$
$f[t_0]$				
$f[t_1]$	$f[t_0,t_1]$			
$f[t_2]$	$f[t_1,t_2]$	$f[t_0,t_1,t_2]$		
$\vdots$	$\vdots$	$\vdots$	$\ddots$	
$f[t_n]$	$f[t_{n-1},t_n]$	$f[t_{n-2},t_{n-1},t_n]$	$\ldots$	$f[t_0,t_1,\ldots,t_n]$

表 5.2.1　差商计算表

- 我们看到，确定系数 c_k 需要 $\dfrac{n(n+1)}{2}$ 次除法。
- 我们还看到，我们在表的对角线上得到系数 $f[t_0]$、$f[t_0,t_1]$、$f[t_0,t_1,t_2]$，最后是 $f[t_0,t_1,\ldots,t_n]$，即 p_n 在 *Newton* 基中的系数 c_0,c_1,c_2，最后是 c_n。

以下是计算差商 d_i（$0 \le i \le n$）的简洁算法：

算法 5 计算差商

输入： 函数值 $f(t_i)$，$i = 0, \ldots, n$ 和插值点 t_i，$i = 0, \ldots, n$

输出： 差商 $d_i = f[t_0, \ldots, t_i]$，$i = 0, \ldots, n$

```
for i = 0 到 n do
    d_i ← f(t_i)
end for
for k = 1 到 n do
    for i = n 到 k 步长 −1 do
        d_i ← (d_i − d_{i−1}) / (t_i − t_{i−k})
    end for
end for
```

注意到，算法结束时的元素 d_i 确实对应于在 *Newton* 基中写出的插值多项式的系数 c_i。

5.2.6 *Horner* 算法

首先要注意，形式

$$p_n(t) = c_0 + c_1(t - t_0) + c_2(t - t_0)(t - t_1) + \cdots + c_n(t - t_0)(t - t_1)\cdots(t - t_{n-1}) \tag{5.2.33}$$

非常适合使用 *Horner* 方案进行数值计算：

算法 6 *Horner* 算法计算 Newton 形式的多项式

输入： 系数 $c_0, \ldots, c_n$，插值点 $t_0, \ldots, t_{n-1}$，以及要计算的点 t

输出： 多项式值 $p_n(t)$

```
数据：c_0, ..., c_n, t_0, ..., t_{n−1}, t
p ← c_n
for k = n − 1 到 0 步长 −1 do
    p ← c_k + (t − t_k) × p
end for
```

例如，对于 $n = 3$，我们从最内层的括号开始依次计算每个括号：

$$p_3(t) = c_0 + (t - t_0)\left[c_1 + (t - t_1)\left[c_2 + (t - t_2)[c_3]\right]\right]. \tag{5.2.34}$$

经典写法会给出

$$p_3(t) = c_0 + c_1(t - t_0) + c_2(t - t_0)(t - t_1) + c_3(t - t_0)(t - t_1)(t - t_2), \tag{5.2.35}$$

这对应于 5 次乘法。

在练习中，我们将证明，一般来说，对于 p_n 的计算，*Horner* 算法包含 n 次乘法，而”经典”计算包含 $2n - 1$ 次乘法。

5.2.7　插值多项式的收敛性

误差表达式：

$$e_n(t) = \frac{1}{(n+1)!}\pi_n(t)f^{(n+1)}(\xi), \tag{5.2.36}$$

之前得到的这个表达式已经允许我们在一些有利的情况下获得有趣的结果。

设 $[a,b]$ 是包含所有插值点 t_i 的区间。我们有：

$$E_n = \sup_{t\in[a,b]} |e_n(t)| \le \frac{1}{(n+1)!} \sup_{t\in[a,b]} |\pi_n(t)| \sup_{t\in[a,b]} |f^{(n+1)}(t)|, \tag{5.2.37}$$

由此得出上界：

$$E_n \le \frac{(b-a)^{n+1}}{(n+1)!} \sup_{t\in[a,b]} |f^{(n+1)}(t)|. \tag{5.2.38}$$

由于

$$\lim_{n\to\infty} \frac{(b-a)^{n+1}}{(n+1)!} = 0, \tag{5.2.39}$$

因此对于所有 $f \in C^\infty([a,b])$ 且其导数在 n 上一致有界的函数，有 $\lim_{n\to\infty} E_n = 0$。这类函数相当有限，但包含像 e^t、$\sin t$、$\cos t$ 这样的函数。

相反，练习 (5.12) 表明，对于像

$$f(t) = \frac{1}{1+t^2} \tag{5.2.40}$$

这样合理的函数，在区间 $[-5,5]$ 上进行插值时，插值多项式不会一致收敛到 f。

5.3　三次样条插值

5.3.1　问题的提出

多项式插值存在几个缺点：

- 它不能很好地处理相当” 陡峭” 的函数，
- 它的收敛性较差，在这个意义上，增加点的数量并不能显著改善超过某个度数的误差。

从定性角度来看，这些困难源于多项式的刚性过大。由于这种刚性，从 0 到 1 的突然跳跃会在整个定义区间上产生振荡。

因此，必须使用刚性较小的近似函数（$\tilde{F}$ 的元素）进行近似。换句话说，我们将要求 $\tilde{F}$ 中的函数具有较少的全局正则性。除了多项式的良好性质外，这将引导我们使用分段多项式。

具体来说，在接下来的内容中，我们考虑区间 $[a,b]$ 的一个分割：

$$\Delta = \{a = t_0 < t_1 < t_2 < \cdots < t_{n-1} < t_n = b\}, \tag{5.3.1}$$

我们称分割点 t_i 为**节点**。假设给定一个实数族 $\{y_0,\ldots,y_n\}$，它们与之前一样对应插值值。一个相当自然的想法是分别考虑每个子区间 $[t_i,t_{i+1}]$ 并构造分段近似：这样我们得到一个满足插值条件 $g(t_i) = y_i$ 的函数 g，它在每个区间 $[t_i,t_{i+1}]$ 内与一个次数或多或少较高的多项式 $g_i(t)$ 重合。

在选择 $g_i(t)$ 为 1 次的情况下，这种技术包括用直线段连接点 (t_i, y_i)：这是使用所谓的**样条函数**的最基本方式。在这种情况下，方程 $y = g(t)$ 的曲线是一条折线，因此有角点，函数 g 在横坐标 t_i 处不可导。

我们清楚地感觉到，如果采用更高次数的多项式，$g_i(t)$ 的选择就不再唯一。这个想法是利用这些额外的自由度来确保 g 在点 t_i 处具有一定的正则性。例如，可以要求 g 一次或多次连续可导。在本课程中，我们将限制在这些多项式为 3 次的情况。

5.3.2 三次样条插值的定义

定义 5.3.1

给定区间 $[a, b]$ 的一个分割：

$$\Delta = \{a = t_0 < t_1 < t_2 < \cdots < t_{n-1} < t_n = b\}, \tag{5.3.2}$$

我们称满足以下性质的函数 g 为**三次样条插值**：

- $g \in C^2[a, b]$（g 是两次连续可导的），
- g 在每个区间 $[t_i, t_{i+1}]$ 上对应一个次数小于或等于 3 的多项式，
- $g(t_i) = y_i$，对于 $i = 0, 1, \ldots, n$。

注意到，上述定义不足以唯一确定样条插值函数，因为还缺少一些条件。正如我们将看到的，确定样条需要求解一个线性方程组，而要确定这个函数还缺少两个方程。这两个方程将来自额外的条件，例如

$$g''(a) = g''(b) = 0. \tag{5.3.3}$$

这两个条件，加上定义 5.3.2 中的条件，定义了所谓的**自然样条**。

我们将在练习中看到如何构造自然三次样条。

5.4 第五章文档

5.4.1 插值多项式和 *Taylor* 多项式的表达式类比

充分可导函数 f 的 *Taylor* 展开的多项式部分的表达式是经典的。它写成：

$$P(t) = P(t_0) + (t - t_0)f'(t_0) + \cdots + \frac{(t - t_0)^n}{n!} f^{(n)}(t_0). \tag{5.4.1}$$

我们已经看到插值多项式具有表达式：

$$P(t) = P(t_0) + (t - t_0)f[t, t_0] + \cdots + (t - t_0)(t - t_1)\cdots(t - t_{n-1})f[t_0, t_1, \ldots, t_n]. \tag{5.4.2}$$

我们将看到，在插值点等距的情况下，可以获得一个与 *Taylor* 多项式表达式更加相似的插值多

项式表达式。实际上，可以证明，设

$$h = t_1 - t_0 = t_2 - t_1 = \cdots = t_n - t_{n-1}, \quad s = \frac{t - t_0}{h}, \tag{5.4.3}$$

$$\Delta^1 f_i = f(t_{i+1}) - f(t_i), \quad \Delta^k f_i = \Delta^{k-1} f(t_{i+k}) - \Delta^{k-1} f(t_i), \tag{5.4.4}$$

则有（待证明）

$$(t - t_0)(t - t_1) \cdots (t - t_{k-1}) f[t_0, t_1, \ldots, t_k] = \frac{s(s-1)\cdots(s-k+1)}{k!} \Delta^k f_0, \tag{5.4.5}$$

由此可以推导出（待证明）插值多项式的表达式：

$$P(t) = f_0 + s\Delta f_0 + \frac{s(s-1)}{2!}\Delta^2 f_0 + \cdots + \frac{s(s-1)\cdots(s-n+1)}{n!}\Delta^n f_0. \tag{5.4.6}$$

如果由于与物理或力学科学的充分接触，人们对在其方程中遇到的各种量的量纲问题敏感，那么在这里会非常注意。

差值 $(t - t_i)$ 具有长度的量纲（例如，或时间的量纲，或其他任何量纲都无关紧要）。因此，在 *Taylor* 公式中，$(t - t_0)^k$ 的量纲由 f 的 k 阶导数中引入的 k 个除以 $t - t_0$ 的商来补偿。

相反，量 $s, s-1, \ldots$ 是无量纲的。这就是为什么出现不涉及任何除法的差分 $\Delta^k f_0$。

Chapter 6

积分

6.1　数值积分方法的动机和原理

有两种情况需要公式来近似函数 f 的积分：

$$I(f) = \int_a^b f(t)\,dt \tag{6.1.1}$$

- 我们只知道 f 在某些点 $t_0, t_1, \ldots, t_n$ 处的值，并且无法获得除这些值之外的其他值（这是当函数 f 被制成表格时的情况）。
- 可以计算任意 t 的 $f(t)$，但 f 的原函数未知，或者 f 的解析表达式过于复杂而无法显式表达（例如，$f(t)$ 是过于复杂的计算代码的结果）。

在这两种情况下，我们必须尝试使用函数 f 在有限个点 $t_0, t_1, \ldots, t_n$ 处的值来近似 $I(f)$，这些点要么是给定的，要么是为了使近似尽可能最佳而最优选择的。更准确地说，我们将使用被积函数在积分区间内某些点处的值的线性组合，即

$$\int_a^b f(t)\,dt \approx \sum_{i=0}^{n} w_i f(t_i). \tag{6.1.2}$$

点 t_i 称为公式的**节点**，w_i 是**权重**（英文为 weights），有时也称为公式的**系数**。映射

$$f \mapsto \sum_{i=0}^{n} w_i f(t_i) \tag{6.1.3}$$

它将函数 f 映射到其在所考虑区间上的积分的" 近似" 值，定义了一个**数值积分公式**（或**方法**）。也称为**求积公式**或**求积方法**。

一些评论在文档中给出。

6.2　使用插值多项式的方法

6.2.1 方法的原理

为了通过函数 f 在点 $t_0, t_1, \ldots, t_n$ 处的值的线性组合来近似积分 $I(f)$，第一种方法是用

$$J(f) = \int_a^b p_f(t)\,dt \tag{6.2.1}$$

来近似 $I(f)$，其中 $p_f(t)$ 是在互异点 $t_0, t_1, \ldots, t_n$ 处插值 f 的多项式。这些点通常选择在区间 $[a, b]$ 内。然而，在关于微分方程的章节中，我们将遇到使用积分区间外节点的求积公式。其理由非常简单：这允许使用在被积函数值已经计算过的点处的函数值。

我们在前一章看到，插值多项式在 *Lagrange* 基中表示为

$$p_f(t) = \sum_{i=0}^{n} f(t_i)\mathscr{L}_i(t). \tag{6.2.2}$$

我们因此直接得到

$$J(f) = \sum_{i=0}^{n} w_i f(t_i), \quad \text{其中} \quad w_i = \int_a^b \mathscr{L}_i(t)\,dt. \tag{6.2.3}$$

公式 (6.2.3) 称为**求积公式**。

等价地，我们也可以通过要求公式对所有次数小于或等于 n 的多项式精确，即等价地对 $\mathscr{P}_n$ 的规范基的每个单项式精确，来获得系数 w_i。这种等价性很容易证明，参见引用的练习。

因此，我们可以通过要求 $I(p) = J(p)$ 对 $p \in \{p_0, p_1, \ldots, p_n\}$ 成立来计算系数 $w_0, \ldots, w_n$，其中 $\{p_0, p_1, \ldots, p_n\}$ 是 $\mathscr{P}_n$ 的规范基。我们得到线性方程组

$$\begin{pmatrix} 1 & 1 & \cdots & 1 \\ t_0 & t_1 & \cdots & t_n \\ t_0^2 & t_1^2 & \cdots & t_n^2 \\ \vdots & \vdots & \ddots & \vdots \\ t_0^n & t_1^n & \cdots & t_n^n \end{pmatrix} \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_n \end{pmatrix} = \begin{pmatrix} v_0 \\ v_1 \\ \vdots \\ v_n \end{pmatrix}, \tag{6.2.4}$$

其中

$$v_k = \int_a^b t^k\,dt. \tag{6.2.5}$$

该系统的矩阵是 ***Vandermonde* 矩阵**。当且仅当点 t_i 两两互异时，其行列式非零。因此，系统 (6.2.4) 确实有且仅有一个解。

引用的示例允许您在一个特定情况下看到计算 w_i 的两种方法。

6.2.2 参考区间

一旦节点 t_i 选定，权重 w_i 不依赖于要积分的函数 f。然而，它们依赖于 a 和 b。我们现在将看到，可以无限制地将任意区间上的积分近似归结为在唯一一个称为**参考区间**的区间上的积分。我们

选择区间 $[-1,1]$，因为它关于 0 的对称性简化了计算。然而，我们也可以选择任何其他区间，例如 $[0,1]$。

因此，我们将使用仿射变量变换，将区间 $[a,b]$ 上的积分计算归结为区间 $[-1,1]$ 上的积分。实际上，如果设

$$t=\frac{a+b+(b-a)u}{2}, \tag{6.2.6}$$

我们可以写成

$$\int_a^b f(t)\,dt=\frac{b-a}{2}\int_{-1}^1 g(u)\,du, \tag{6.2.7}$$

其中

$$g(u)=f\left(\frac{a+b+(b-a)u}{2}\right). \tag{6.2.8}$$

因此，我们可以在 $[-1,1]$ 上定义求积公式，其中节点和权重都不依赖于 a 或 b。这些公式就是我们在数值积分书籍的表格中找到的公式。

当我们必须计算二重或三重积分时，情况就不那么简单了。实际上，不存在简单的坐标变换能够将任意二维或三维域变换到参考域。我们有一系列域形状族（三角形、四边形、四面体等），对于每个族，都有一个参考域。从一维到二维或三维的过渡改变了求积问题的复杂度水平。

6.2.3　求积误差的上界 - 阶数

求积误差由下式给出：

$$E(f)=I(f)-J(f)=\int_a^b (f(t)-p_f(t))\,dt. \tag{6.2.9}$$

如果 f 是 $n+1$ 次连续可导的函数，且 p_f 是其次数为 n 的插值多项式，我们在关于插值的章节中看到：

$$f(t)-p_f(t)=(t-t_0)(t-t_1)\cdots(t-t_n)\frac{f^{(n+1)}(\xi(t))}{(n+1)!}=\pi_n(t)\frac{f^{(n+1)}(\xi(t))}{(n+1)!}, \tag{6.2.10}$$

其中 $\xi(t)\in \mathrm{Int}(t,t_0,\ldots,t_n)$。因此有

$$|E(f)|\le\int_a^b |\pi_n(t)|\frac{|f^{(n+1)}(\xi(t))|}{(n+1)!}\,dt=\frac{|f^{(n+1)}(\eta)|}{(n+1)!}\int_a^b |\pi_n(t)|\,dt, \tag{6.2.11}$$

其中 $\eta\in \mathrm{Int}(a,b,t_0,\ldots,t_n)$（我们应用了第二个中值定理[1]）。我们还可以进一步上界：

$$|E(f)|\le\frac{M}{(n+1)!}\int_a^b |\pi_n(t)|\,dt, \tag{6.2.12}$$

其中 $M>0$ 是 $|f^{(n+1)}|$ 在 $\mathrm{Int}(a,b,t_0,\ldots,t_n)$ 上的一个上界。

我们确实发现，如果 f 是次数小于或等于 n 的多项式，则 $E(f)=0$，即近似是精确的。我们将在后面看到，特别是在上面引用的示例和练习中，可以获得更精细的误差估计。

[1]如果 f 和 g 是 $[a,b]$ 上的两个连续函数，且 g 在 $[a,b]$ 上不变号，则存在 $c\in]a,b[$ 使得 $\int_a^b f(x)g(x)\,dx=f(c)\int_a^b g(x)\,dx$。

定义 6.2.1

对所有次数小于或等于 n（n 为最大值）的多项式精确的求积公式称为**阶数为** n 或**精确度为** n。

6.2.4 *Newton-Cotes* 公式

我们现在将列举一些使用固定等距点 t_i 构造的经典公式。假设 $t_0 = a$，$t_n = b$，且点 t_i 等距：

$$t_{j+1} - t_j = h = \frac{b-a}{n}, \quad \forall j = 0, 1, \ldots, n-1. \tag{6.2.13}$$

因此有 $t_i = a + ih$，对于 $i = 0, \ldots, n$。

我们将梯形方法中使用的思想推广到任意数量的点：用 $J(f) = \displaystyle\int_a^b p_f(t)\,dt = \sum_{i=0}^{n} w_i f(t_i)$ 来近似 $I(f)$，其中 p_f 在点 $t_0, \ldots, t_n$ 处插值 f。

现在给出对于不同 n 值得到的公式。我们同时给出每个公式对应的误差 E 的估计。$n = 1, 2, 3$ 的 *Newton-Cotes* 公式：

- $n = 1$：**梯形公式**（$h = b - a$）：

$$J(f) = \frac{h}{2}(f(t_0) + f(t_1)); \quad \exists \eta \in [a, b], \quad E(f) = -\frac{h^3}{12} f''(\eta). \tag{6.2.14}$$

- $n = 2$：***Simpson* 公式**（$h = (b-a)/2$）：

$$J(f) = \frac{h}{3}(f(t_0) + 4f(t_1) + f(t_2)); \quad \exists \eta \in [a, b], \quad E(f) = -\frac{h^5}{90} f^{(4)}(\eta). \tag{6.2.15}$$

- $n = 3$：***Simpson* 3/8 公式**（$h = (b-a)/3$）：

$$J(f) = \frac{3h}{8}(f(t_0) + 3f(t_1) + 3f(t_2) + f(t_3)); \quad \exists \eta \in [a, b], \quad E(f) = -\frac{3h^5}{80} f^{(4)}(\eta). \tag{6.2.16}$$

我们有以下一般结果：

定理 6.2.1

（带余项的 *Newton-Cotes* 公式）

如果 n 是偶数且 f 是 $n+2$ 次连续可导的，则存在 $\eta \in [a, b]$ 使得

$$\int_a^b f(t)\,dt = \sum_{i=0}^{n} w_i f(t_i) + \frac{h^{n+3} f^{(n+2)}(\eta)}{(n+2)!} \int_0^n t^2(t-1)\cdots(t-n)\,dt. \tag{6.2.17}$$

如果 n 是奇数且 f 是 $n+1$ 次连续可导的，则存在 $\eta \in [a, b]$ 使得

$$\int_a^b f(t)\,dt = \sum_{i=0}^{n} w_i f(t_i) + \frac{h^{n+2} f^{(n+1)}(\eta)}{(n+1)!} \int_0^n t(t-1)\cdots(t-n)\,dt. \tag{6.2.18}$$

系数 w_i 通过求解系统 (6.2.4) 或通过计算 $\int_a^b p_f(t)\,dt$ 获得，其中 p_f 是插值多项式。

可以注意到，对于 n 为偶数（因此是奇数个点），*Newton-Cotes* 公式对次数小于或等于 $n+1$ 的多项式精确，而对于 n 为奇数，这些公式对次数小于或等于 n 的多项式精确。因此，n 为偶数的情况给出了比预期更高阶的公式。这有一个直接后果：当 n 为偶数时，添加单个点不会改善积分的近似，必须添加 2 个点。

6.2.5　复合数值积分

在实践中，我们很少超过 $n=2$，原因与偏好样条而非插值多项式相同，因为当 n 变大时，插值多项式倾向于强烈振荡。为了处理大区间，我们使用局部方法：首先将区间 $[a,b]$ 分割，然后在子区间上应用低阶公式。例如，对于梯形方法：

1. 使用分割点 $t_i = a + ih$（$i = 0, \ldots, N$，其中 $h = (b-a)/N$）将区间 $[a,b]$ 细分为 N 个子区间，
2. 然后在每个子区间 $[t_i, t_{i+1}]$ 上应用梯形方法。

我们因此得到以下复合公式：

$$\begin{aligned} J(f) &= h\left(\frac{f(t_0)+f(t_1)}{2} + \frac{f(t_1)+f(t_2)}{2} + \cdots + \frac{f(t_{N-1})+f(t_N)}{2}\right) \\ &= h\left(\frac{1}{2}f(t_0) + \sum_{i=1}^{N-1} f(t_i) + \frac{1}{2}f(t_N)\right). \end{aligned} \tag{6.2.19}$$

对于误差的计算，我们对每个子区间上的误差求和，即

$$E(f) = \sum_{i=0}^{N-1} E_i(f), \quad \text{其中} \quad E_i(f) = -\frac{h^3}{12} f''(\eta_i), \tag{6.2.20}$$

其中 $\eta_i \in [t_i, t_{i+1}]$。然后我们应用中值定理[2]来引用存在一个数 $\eta \in [a,b]$ 使得

$$f''(\eta) = \frac{1}{N}\sum_{i=0}^{N-1} f''(\eta_i), \tag{6.2.21}$$

全局误差写成

$$E(f) = -\frac{b-a}{12} h^2 f''(\eta). \tag{6.2.22}$$

同样地，对于 *Simpson* 方法：假设 N 是偶数，即 $N = 2M$。得到的公式如下（在练习中证明）：

$$J(f) = \frac{h}{3}\left(f(t_0) + 4\sum_{i=0}^{M-1} f(t_{2i+1}) + 2\sum_{i=1}^{M-1} f(t_{2i}) + f(t_{2M})\right), \tag{6.2.23}$$

其中我们总是设 $h = (b-a)/N$，并且通过与之前相同的技术，我们得到误差估计：

$$E(f) = -\frac{b-a}{180} h^4 f^{(4)}(\eta), \quad \eta \in [a,b]. \tag{6.2.24}$$

在引用的文档中，可以找到误差的后验估计计算以及使用这些估计来构造自适应求积方法的技术。

[2]如果 f 在 $[a,b]$ 上连续，则存在 $c \in (a,b)$ 使得 $f(c) = [f(a)+f(b)]/2$。

6.3 第六章文档

6.3.1 在什么意义下近似？

形式

$$\int_a^b f(t)\,dt \approx \sum_{i=0}^{n} w_i f(t_i) \tag{6.3.1}$$

的选择不应该令人惊讶。实际上，让我们回顾一下可积函数的积分是如何定义的。

给定区间 $[a,b]$ 的一个分割

$$t_0 = a < t_1 < \cdots < t_n = b$$

以及每个子区间 $[t_i, t_{i+1}]$ 中的一个点 $\xi_i \in [t_i, t_{i+1}]$。然后我们引入和式

$$\sum_{i=0}^{n-1} f(\xi_i)(t_{i+1} - t_i),$$

它表示曲线 $y = f(t)$ 在点 a 和 b 之间所围面积的近似值。设 $h = \max_{0\le i<n-1} |t_{i+1} - t_i|$。如果极限

$$\lim_{h\to 0} \sum_{i=0}^{n-1} f(\xi_i)(t_{i+1} - t_i)$$

存在且相同，则称函数 f 在区间 $[a,b]$ 上是 Riemann 可积的，无论：

1. 分割点 t_i 的选择如何（只要这个选择满足条件 $h \to 0$），
2. 以及每个子区间 $[t_i, t_{i+1}]$ 中点 ξ_i 的选择如何。

这个极限的值就是 f 在 $[a,b]$ 上的积分。

因此我们看到，每个和式

$$\sum_{i=0}^{n-1} f(\xi_i)(t_{i+1} - t_i)$$

都给出积分的近似值。我们也看到这些和式确实是形式 (6.3.1)。

理想情况下，我们希望对我们可能感兴趣的所有函数（实际上是对所有 Riemann 可积函数）都有精确值。这是不可能的，但这个想法给出了构造最常用方法的原则，许多其他方法都是基于这些方法构造的。

因此，我们首先要求求积公式对尽可能广泛的函数类精确。由于每个公式只有有限个自由度，我们很快想到多项式。实际上，一方面它们确实允许构造公式，因为我们知道它们的原函数。另一方面，它们在连续函数空间中稠密[3]，这使得我们可以期望这样构造的公式对这个广泛的函数类具有良好的性质。

当我们处理不属于我们有精确公式的函数类的函数 f 时，我们至少希望能够拥有一族公式 $(Q_n)_{n\in\mathbb{N}}$，使得

$$\lim_{n\to\infty} \sum_{i=0}^{n} w_i^n f(t_i^n) = \int_a^b f(t)\,dt.$$

[3]这意味着在实践中，任何连续函数都可以被多项式任意接近地逼近。

我们将在后面构造对任何 Riemann 可积函数都具有此性质的公式族。我们还将看到，存在一些公式族，虽然对多项式精确，但不具有此性质。

6.3.2　求积误差的先验和后验估计

练习 (6.3) 中中点方法得到的误差和段落（*Newton-Cotes* 积分公式）中梯形方法得到的误差是同一类型的。它们表明，例如，在子区间 $[t_i, t_{i+1}]$ 上的误差以 h_i^3 的速度趋于 0，这是有趣的。然而，形式为 $f''(\xi_{M,i})$（或 $f''(\xi_{T,i})$）的项的存在禁止了误差值的任何评估。相反，如果我们同时有两个估计，即

$$E_M^i(f) = \frac{h_i^3}{24} f''(\xi_{M,i}) \quad \text{和} \quad E_T^i(f) = -\frac{h_i^3}{12} f''(\xi_{T,i}),$$

我们注意到，对于足够小的 h_i，我们可以写成

$$E_T^i(f) \approx -2E_M^i(f).$$

设

$$I_{\text{exact}}^i(f) = \int_{t_i}^{t_{i+1}} f(t)\,dt, \tag{6.3.2}$$

$$I_M^i(f) = h_i f\left(\frac{t_i + t_{i+1}}{2}\right), \tag{6.3.3}$$

$$I_T^i(f) = \frac{h_i}{2}(f(t_i) + f(t_{i+1})). \tag{6.3.4}$$

则有

$$I_{\text{exact}}^i(f) - I_T^i(f) \approx -2(I_{\text{exact}}^i(f) - I_M^i(f)).$$

我们因此推导出 $I_{\text{exact}}^i(f)$ 的改进近似值：

$$I_{\text{exact}}^i(f) \approx \frac{I_T^i(f) + 2I_M^i(f)}{3} = \frac{h_i}{6}\left(f(t_i) + 4f\left(\frac{t_i + t_{i+1}}{2}\right) + f(t_{i+1})\right), \tag{6.3.5}$$

尤其是误差估计：

$$E_M^i(f) = I_{\text{exact}}^i(f) - I_M^i(f) \approx \frac{I_T^i(f) + 2I_M^i(f)}{3} - I_M^i(f) = \frac{I_T^i(f) - I_M^i(f)}{3}. \tag{6.3.6}$$

上述估计是**后验估计**：一旦获得了近似值 $I_M^i(f)$ 和 $I_T^i(f)$，它就给出误差的”可计算值”。我们将在下一段看到如何使用这些估计来获得给定精度的近似值。

让我们通过回顾所有获得的估计只对足够正则的被积函数有意义（具体来说，对于中点和梯形公式，需要 C^2 类函数）来结束这一段。此外，先验估计只对足够小的 h_i 有意义，使得当我们将 $\xi_{M,i}$ 和 $\xi_{T,i}$ 等同起来时可以忽略高阶项，但也不能太小，否则机器的截断误差变得占主导地位，并且在不考虑它们的情况下使这些估计失去意义。

给定一个区间 $[a, b]$，一个函数 f，我们希望其在 $[a, b]$ 上的积分误差小于 ε。为此，我们先用中点方法评估近似值，然后用梯形方法评估。我们因此得到误差值。如果它小于 ε，则完成，我们取外推值作为近似值。否则，我们将 $[a, b]$ 细分为两部分，并在每个半区间上以 $\varepsilon/2$ 的容差计算，依此类推。

Chapter 7

微分方程

7.1　一般求解原理

7.1.1　引言

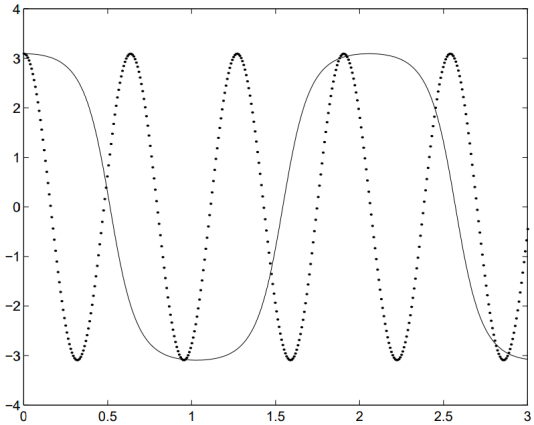

图 7.1.1　线性摆（虚线）和非线性摆（实线）的振荡

考虑一个初始静止的摆，相对于垂直方向有一个初始偏差 θ_0。控制偏差 $\theta(t)$ 的微分方程如下：

$$\begin{cases} \ddot{\theta}(t) = -\frac{g}{L}\sin\theta(t), \\ \theta(0) = \theta_0, \\ \dot{\theta}(0) = 0. \end{cases} \tag{7.1.1}$$

当 θ_0 很小时，我们可以对 $\sin\theta(t)$ 进行一阶近似，这导致设

$$\sin\theta(t) \approx \theta(t),$$

在这种情况下，我们容易证明有

$$\theta(t) = \theta_0 \cos\omega t, \tag{7.1.2}$$

其中 $\omega = \sqrt{g/L}$。相反，如果 θ_0 不小，这个近似就不再有效：图 7.1.1 显示了对于 $\theta_0 = \frac{63}{64}\pi$ 得到的解。很明显，来自线性化问题（虚线）的解给出的想法与实际情况（实线）相去甚远。

因此我们看到，线性化只有在初始角度 θ_0 很小时才能给出可用的结果。

然而，我们不知道如何获得非线性问题的精确解。因此，必须寻找近似解。

本章的目的是介绍实现这一目标的主要数值技术。

还存在其他近似可能性，在计算机广泛使用之前就已经非常发达。例如，可以以级数展开的形式寻找非线性问题的解。然后通过将展开式引入微分方程来确定系数。

7.1.2 微分方程理论要素

设 I 是 $\mathbb{R}$ 的一个区间，$f : I \times \mathbb{R} \to \mathbb{R}$ 是一个连续可微函数，我们记 $f(t, y)$ 为这个函数，$\frac{\partial f}{\partial t}$ 和 $\frac{\partial f}{\partial y}$ 为偏导数。

定义 7.1.1

如果对于所有 $t \in I$ 有

$$\hat{y}'(t) = f(t, \hat{y}(t)),$$

则称连续可导函数 $\hat{y} : I \to \mathbb{R}$ 是微分方程

$$y' = f(t, y) \tag{7.1.3}$$

的解。

单独的微分方程不足以定义唯一解。通常，我们给它添加一个**初始条件**，即形式为：

$$y(t_0) = y_0, \tag{7.1.4}$$

其中 $t_0 \in I$ 和 $y_0 \in \mathbb{R}$ 是给定的。

在引用的文档中，我们介绍了一个经典的充分条件，使得微分方程 (7.1.3) 与初始条件 (7.1.4) 有且仅有一个解，且该解连续依赖于数据。d 我们只关注这类问题。然而，必须记住，我们可能会遇到其他情况。因此，带初始条件 $y(t_0) = y_0$ 的微分方程 $y' = f(t, y)$ 可能有多解。例如，微分方程

$$\begin{cases} y'(t) = \sqrt{y(t)}, & t > 0, \\ y(0) = 0, \end{cases}$$

有两个解：

$$y_1(t) = 0 \quad 和 \quad y_2(t) = \frac{t^2}{4}.$$

它甚至有无穷多个解。实际上，无论实数 $a > 0$ 如何，由

$$y_a(t) = \begin{cases} 0, & 对于 0 \le t \le a, \\ \dfrac{(t-a)^2}{4}, & 对于 a \le t, \end{cases}$$

定义的函数 y_a 也是解。

到目前为止，我们只限于一阶方程。当然，我们会遇到高阶方程。例如，在力学中经常遇到二阶方程：

$$y''(t) = g(t, y(t), y'(t)),$$

其中 $g : I \times \mathbb{R}^2 \to \mathbb{R}$。

二阶方程需要两个额外条件才能有唯一解。

对于**初值问题**,这通常对应于变量 t 表示时间的情况,这些条件的形式为:$y(0) = y_0$ 和 $y'(0) = y_1$，即物理上，初始时刻的位置和速度是给定的。我们这里只关注这类问题。

然而，不要忘记，对于同一个微分方程，存在另一种类型的问题，我们已经遇到过：**边值问题**。两个条件分别在区间的两个端点给出，例如：$y(0) = y_0$ 和 $y(T) = y_T$。这第二种类型的问题对应于完全不同的物理情况，这导致完全不同的数值求解方法。

对于二阶初值问题，存在特定的数值方法。然而，总是可以将它们归结为两个耦合的一阶微分方程组，带初始条件。实际上，设：

$$U(t) = \begin{pmatrix} U_1(t) \\ U_2(t) \end{pmatrix} = \begin{pmatrix} y(t) \\ y'(t) \end{pmatrix}, \quad U_0 = \begin{pmatrix} y_0 \\ y_1 \end{pmatrix}.$$

则有：

$$U'(t) = \begin{pmatrix} U_1'(t) \\ U_2'(t) \end{pmatrix} = \begin{pmatrix} y'(t) \\ y''(t) \end{pmatrix} = \begin{pmatrix} U_2(t) \\ g(t, y(t), y'(t)) \end{pmatrix}.$$

因此，通过引入向量值函数

$$F : I \times \mathbb{R}^2 \to \mathbb{R}^2, \quad (t, U) \mapsto F(t, U) = \begin{pmatrix} U_2 \\ g(t, U_1, U_2) \end{pmatrix}, \tag{7.1.5}$$

我们归结为问题：

$$U'(t) = F(t, U(t)) \quad \text{其中} \quad U(0) = U_0,$$

它与问题 (7.1.3)–(7.1.4) 具有相同的形式。我们将二阶微分方程化为**标准形式**。

这个结果可以推广到 m 阶微分方程

$$y^{(m)}(t) = g(t, y(t), y'(t), \ldots, y^{(m-1)}(t)),$$

它们可以归结为 m 个一阶微分方程组。d

关于微分的回顾：设 n, p, q 是三个 d 正整数 > 0。设 $f : (x, y) \in \mathbb{R}^n \times \mathbb{R}^p \mapsto f(x, y) \in \mathbb{R}^q$，我们记 $\dfrac{\partial f}{\partial x}$ 和 $\dfrac{\partial f}{\partial y}$ 为对第一个和第二个变量的偏导数。

设 $(x_0, y_0) \in \mathbb{R}^n \times \mathbb{R}^p$。偏导数 $\dfrac{\partial f}{\partial x}(x_0, y_0)$ 是一个 $(q \times n)$ 大小的矩阵，$\dfrac{\partial f}{\partial y}(x_0, y_0)$ 是一个 $(q \times p)$ 大小的矩阵。

设 I 是 $\mathbb{R}$ 的一个区间。现在假设 x 是一个函数 $x : t \in I \mapsto x(t) \in \mathbb{R}^n$。同样，$y : t \in \mathbb{R} \mapsto y(t) \in \mathbb{R}^p$。取 $t_0 \in I$。我们有 $x'(t_0) = \dfrac{dx}{dt}(t_0)$ 是 $\mathbb{R}^n$ 中的一个向量，$y'(t_0) = \dfrac{dy}{dt}(t_0) \in \mathbb{R}^p$。

最后，设单变量函数 $h : t \in I \mapsto h(t) \in \mathbb{R}^q$，由 $h(t) = f(x(t), y(t))$ 定义。那么它在点 $t_0 \in I$ 处的导数写成

$$h'(t_0) = \frac{\partial f}{\partial x}(x(t_0), y(t_0))\frac{dx}{dt}(t_0) + \frac{\partial f}{\partial y}(x(t_0), y(t_0))\frac{dy}{dt}(t_0).$$

注意矩阵和向量之间的乘积是兼容的：例如，$\frac{\partial f}{\partial x}(x(t_0), y(t_0)) \in M_{q,n}$ 和 $x'(t_0) \in \mathbb{R}^n$。

7.1.3 数值方法的原理

设 $y(t)$ 是微分方程

$$\begin{cases} y'(t) = f(t, y(t)), \quad t \in [t_0, t_0 + T], \\ y(t_0) = y_0 \end{cases} \tag{7.1.6}$$

的解。

一般原理是将区间 $I = [t_0, t_0 + T]$ 离散化，引入点 $t_0, t_1, \ldots, t_N = t_0 + T$，这些点可以是等距的，但不是必须的。量 $h_n = t_{n+1} - t_n$ 称为**步长**。我们希望对于 $n = 1, \ldots, N$，计算 $y(t_n)$ 的近似值，记作

$$z_n \approx y(t_n),$$

使用迭代过程。

最简单的想法是首先写出 $y(t)$ 在 $t = t_n$ 处的 *Taylor* 展开：由于解至少对 t 可导一次，我们可以写成

$$\begin{aligned} y(t_{n+1}) = y(t_n + h) &= y(t_n) + hy'(t_n) + \frac{h^2}{2}y''(\xi), \quad \xi \in [t_n, t_{n+1}] \\ &= y(t_n) + hf(t_n, y(t_n)) + \mathscr{O}(h^2). \end{aligned} \tag{7.1.7}$$

我们假设 h_n 是常数且等于 $h = \frac{T}{N}$，其中 N 是固定的整数。如果我们假设 h 足够小，那么可以提出以下迭代格式：

$$\begin{cases} z_0 = y_0, \\ z_{n+1} = z_n + hf(t_n, z_n), \quad 0 \le n \le N - 1. \end{cases} \tag{7.1.8}$$

这个迭代过程称为**简单 *Euler* 格式**。但我们将看到其他引入它的方法。

另一种方法是将 *Taylor* 展开推到 2 阶，这在引用的示例中介绍。在那里我们看到，需要计算 $y''(t)$，即

$$\frac{d}{dt}f(t, y(t)) = \frac{\partial f}{\partial t}(t, y(t)) + f(t, y(t))\frac{\partial f}{\partial y}(t, y(t)).$$

在同一个示例中，还介绍了这两种格式应用于一个非常简单的例子。

最后，将 *Taylor* 展开推到 2 阶后，自然想到将其展开到 3 阶、4 阶等。然而，只需计算 $(f(t, y(t)))''$ 就可以看到，在一般情况下，这种方法很快变得不可行。

我们区分两大类用于初值问题的数值求解格式：

- **单步格式**。为了计算所求函数在点 t_{n+1} 处的值的近似值，我们忽略点 t_n 之前发生的一切。主要优点是允许在计算过程中根据与近似值同时获得的误差估计非常容易地改变步长。

- **多步格式**。在这些方法中，相反地，为了计算所求函数在点 t_{n+1} 处的值的近似值，我们使用在 $t_n, t_{n-1}, \ldots$ 处计算的值。这允许较低的计算成本，但使值更加相互依赖，因此在计算过程中局部改变步长更加困难。

7.2　单步格式

7.2.1　从数值积分出发的 *Euler* 格式

为了定义某些微分方程数值求解格式，我们注意到精确解 $y(t)$ 满足 $y'(t) = f(t, y(t))$，这给出

$$y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} f(t, y(t))\, dt.$$

然后可以考虑使用 $f(t, y(t))$ 在区间 $[t_n, t_{n+1}]$ 上的值来近似积分，尽管 $y(t)$ 在这个区间上未知。为了简化书写，我们假设步长 $h_n = t_{n+1} - t_n$ 是常数，$h = \frac{T}{N}$，其中 N 是整数，但推广到非常数步长是显然的。

首先，使用" 左" 矩形方法进行积分的近似计算（这等价于在 $t = t_n$ 处应用于 $y(t)$ 的 *Taylor* 公式，我们在引用的段落中介绍过）。

因此可以提出以下格式：

$$z_{n+1} = z_n + hf(t_n, z_n), \quad 0 \le n \le N-1, \tag{7.2.1}$$

这就是**简单 *Euler* 格式**。也可以使用右矩形方法近似积分。等价的计算来自在 $t = t_{n+1}$ 处应用于 $y(t)$ 的 *Taylor* 公式：

$$y(t_n) = y(t_{n+1}) - hf(t_{n+1}, y(t_{n+1})) + \frac{h^2}{2} y''(\xi), \quad \xi \in [t_n, t_{n+1}].$$

这导致格式

$$z_{n+1} = z_n + hf(t_{n+1}, z_{n+1}), \quad 0 \le n \le N-1, \tag{7.2.2}$$

我们称之为**后向 *Euler* 格式**。我们说这个格式是**隐式的**，因为 z_{n+1} 被隐式定义为方程

$$x = z_n + hf(t_{n+1}, x)$$

的解，这个方程通常是非线性的。然后我们使用不动点或 Newton 类型的方法。然而，由于步长 h 很小，实践中所需的迭代次数很少：有时甚至一次就足够了。然后需要用 z_{n+1} 的第一次估计来初始化过程，可以是 z_n。

7.2.2　单步预测-校正格式

让我们重新考虑前面定义的后向 *Euler* 隐式格式 (7.2.2)：

$$z_{n+1} = z_n + hf(t_{n+1}, z_{n+1}), \quad 0 \le n \le N-1.$$

可以构造一个新的格式，称为**预测-校正格式**：

- 确定 z_{n+1} 的第一次粗略估计，记作 $\tilde{z}_{n+1}$，例如可以使用显式 *Euler* 方法
- 通过借鉴后向 *Euler* 格式来改进这个估计。

我们得到格式：

$$\begin{cases} \hat{z}_{n+1} = z_n + hf(t_n, z_n), \\ z_{n+1} = z_n + hf(t_{n+1}, \hat{z}_{n+1}). \end{cases} \tag{7.2.3}$$

在这些方法的经典术语中，我们说首先使用显式格式进行预测（$\hat{z}_{n+1}$），然后使用隐式格式进行校正。此外，可以对校正进行迭代。

让我们看另一个例子，如果使用梯形方法计算积分

$$y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} f(t, y(t))\, dt,$$

这给出表达式

$$y(t_{n+1}) = y(t_n) + \frac{h}{2}(f(t_n, y(t_n)) + f(t_{n+1}, y(t_{n+1}))) - \frac{h^3}{12} y^{(3)}(\xi), \quad \xi \in [t_n, t_{n+1}].$$

项 $y^{(3)}$ 对应于 $t \mapsto f(t, y(t))$ 对 t 的二阶导数。这导致以下格式：

$$z_{n+1} = z_n + \frac{h}{2}(f(t_n, z_n) + f(t_{n+1}, z_{n+1})), \quad 0 \le n \le N-1, \tag{7.2.4}$$

它是隐式的，就像后向 *Euler* 格式一样。

可以像之前一样，构造一个受此隐式格式启发的新的预测-校正格式，这就是 ***Euler-Cauchy* 预测-校正格式**：

$$\begin{cases} \tilde{z}_{n+1} = z_n + hf(t_n, z_n), \\ z_{n+1} = z_n + \frac{h}{2}(f(t_n, z_n) + f(t_{n+1}, \tilde{z}_{n+1})), \end{cases} \quad 0 \le n \le N-1. \tag{7.2.5}$$

7.2.3 *Euler* 方法的初步研究

让我们重新考虑显式和隐式 *Euler* 格式 (7.2.1), (7.2.2)：

$$z_{n+1} = z_n + hf(t_n, z_n), \quad n \ge 0,$$

$$z_{n+1} = z_n + hf(t_{n+1}, z_{n+1}), \quad n \ge 0.$$

我们现在将突出显示使用此类方法时可能出现的两种不同类型的困难。为此，只需将这些格式应用于以下模型问题：

$$\begin{cases} y' = -\lambda y(t), \quad \text{其中} \lambda > 0, \\ y(0) = y_0. \end{cases}$$

这个问题有唯一精确解：$y(t) = y_0 e^{-\lambda t}$。

显式 *Euler* 格式构造值序列 $z_n = (1-\lambda h)^n y_0$，隐式 *Euler* 格式构造 $z_n = y_0/(1+\lambda h)^n$。

精确解和近似解在 $t \to +\infty$ 时的行为

我们首先注意到 $\lim_{t\to+\infty} y(t) = 0$。

如果我们对大的 n 值使用 *Euler* 格式，为简化书写，假设步长 h 是常数，则必须有 $\lim_{n\to+\infty} y_n = 0$。然而，这个条件只有在 $|1-\lambda h| < 1$ 时才会满足，即对于 $\lambda > 0$，需要 $h < 2/\lambda$。这个条件可能非常严格。

对于隐式 *Euler* 格式，序列 z_n 在 n 趋于无穷时收敛到 0，对 h 没有任何条件。因此，我们可以使用这种方法，而无需先验的严格步长限制条件。是期望的精度决定了步长：步长越小，精度越好。

收敛性研究

这次，我们固定一个点 t。我们选择步长 h，使得总是存在一个整数 n 使得 $nh = t$。然后，我们希望 y_n 是 $y(t)$ 的近似值。更好的是，我们希望当 $n \to +\infty$ 时，在约束 $nh = t$ 下，z_n 收敛到 $y(t)$。很容易看到，对于 *Euler* 方法，这个性质是满足的。实际上，在练习 7.6 中我们证明

$$\lim_{h\to 0, nh=t} (1-\lambda h)^n y_0 = \lim_{h\to 0, nh=t} y_0/(1+\lambda h)^n = y_0 e^{-\lambda t}.$$

我们强调这是两个不同且互补的观点。第一个只在 t 大时才有意义。实际上，t 大可能很快达到。因此，当我们进行天气预报时，$t = 10$ 天是非常大的，正是稳定性问题在实践中限制了这些预测的范围。

相反，如果我们只关注" 小" 的 t，只有收敛性问题重要。

7.2.4　单步格式的阶和一致性

给定 f, t_0, y_0, T，设 $y(t)$ 是

$$\begin{cases} y'(t) = f(t, y(t)), \quad t \in [t_0, t_0 + T], \\ y(t_0) = y_0 \end{cases} \tag{7.2.6}$$

的精确解。

为了简化说明，我们假设使用常数步长 $h = \frac{T}{N}$ 进行离散化，设 $t_n = t_0 + nh$。显式或预测-校正的单步格式可以写成一般形式

$$\begin{cases} z_0 = y_0, \\ z_{n+1} = z_n + h\varphi(t_n, z_n, h), \quad 0 \le n \le N-1. \end{cases} \tag{7.2.7}$$

我们可能想知道如何量化用离散序列 z_n 近似精确解 $y(t)$ 时产生的误差。以下定义给出了这个问题的初步答案。

定义 7.2.1

我们称相对于格式 (7.2.7) 的**局部误差**为量

$$\tau_{n+1}(h) = (y(t_{n+1}) - y(t_n)) - h\varphi(t_n, y(t_n), h), \quad n = 0, \ldots, N-1,$$

其中 $y(t)$ 是微分方程 (7.2.6) 的精确解。

$\tau_{n+1}(h) = y(t_{n+1}) - z_{n+1}$ 如果我们假设 $z_n = y(t_n)$。

定义 7.2.2

当存在 $K > 0$ 使得

$$\max_{1\le n\le N}\left|\frac{\tau_n(h)}{h}\right| \le Kh^p,$$

格式称为**阶数为** p。

以下定义是微分方程求解格式特有的，可以从阶数快速推导出来。

定义 7.2.3

当

$$\lim_{h\to 0}\max_{1\le n\le N}\left|\frac{\tau_n(h)}{h}\right| = 0$$

时，格式称为**一致的**。

因此，严格正阶的格式是一致的。

对于简单 *Euler* 格式，有

$$\tau_{n+1}(h) = (y(t_{n+1}) - y(t_n)) - hf(t_n, y(t_n)) = \frac{h^2}{2}y''(\xi).$$

假设 y'' 在 $[t_n, t_{n+1}]$ 上有界，即 $|y''(t)| \le M$，$\forall t \in [t_0, t_0 + T]$，则有

$$\tau_{n+1}(h) \le \frac{M}{2}h^2,$$

根据前面的定义，简单 *Euler* 格式是 **1 阶**的。可以验证 *Euler-Cauchy* 格式是 **2 阶**的，参见练习 7.7。

7.2.5 单步格式的稳定性和收敛性

格式的一致性或阶数只是误差的局部指示。测量用 z_i 近似 $y(t_i)$ 的误差的更现实的方法是考虑 $i = 1, \ldots, N$ 时的最大误差，并查看当 $h \to 0$ 时该误差是否趋于零。

定义 7.2.4

格式

$$z_{n+1} = z_n + h\varphi(t_n, z_n, h), \quad 0 \le n \le N-1, \quad z_0 = y_0, \quad h = \frac{T}{N}$$

相对于微分方程

$$y'(t) = f(t, y(t)), \quad y(t_0) = y_0, \quad t \in [t_0, t_0 + T]$$

称为**收敛的**，如果

$$\lim_{h\to 0}\max_{1\le i\le N}|y(t_i) - z_i| = 0.$$

格式的一致性并不意味它是收敛的，我们将看到这最多是一个必要条件。一个额外条件涉及稳定性的概念：

定义 7.2.5

格式

$$z_{n+1} = z_n + h\varphi(t_n, z_n, h), \quad 0 \le n \le N-1, \quad z_0 = y_0,$$

称为**稳定的**，如果存在常数 M，使得对于所有 z_0，所有 u_0，所有 $h \le h^*$ 和所有序列 $\{\varepsilon_i\}$，由关系

$$z_{i+1} = z_i + h\varphi(t_i, z_i, h), \tag{7.2.8}$$

$$u_{i+1} = u_i + h\varphi(t_i, u_i, h) + \varepsilon_i \tag{7.2.9}$$

定义的序列 $\{z_i\}$ 和 $\{u_i\}$ 满足条件

$$\forall i = 1, \ldots, N, \quad |z_i - u_i| \le M\left(|z_0 - u_0| + \sum_{k=0}^{i-1} |\varepsilon_k|\right).$$

大致上，这意味着稳定格式既不放大初始条件上的误差，也不放大格式中引入的误差：这是一个连续性的概念。可以注意到，稳定性可能依赖于 h。上述定义表明，可能存在一个极限步长 h^*，超过它，稳定格式会变得不稳定。我们还有一个稳定性的充分条件：

命题 7.2.1

为了使格式稳定，只要存在常数 Λ 使得

$$\forall t \in [t_0, t_0 + T], \quad \forall z, u \in \mathbb{R}, \quad \forall h \in [0, h^*], \quad |\varphi(t, z, h) - \varphi(t, u, h)| \le \Lambda |z - u|.$$

这意味着函数 φ 必须在其第二个参数上满足 *Lipschitz* 条件。通常我们证明 f 满足 *Lipschitz* 条件来获得 φ 的这个性质。

在这种情况下，简单 *Euler* 格式显然是稳定的，因为 $\varphi(t, z, h) = f(t, z)$。

以下定理简单而重要；它通常被称为**一致性加稳定性蕴含收敛性**。

定理 7.2.1

设 φ 是 $t \in [t_0, t_0 + T]$，$z \in \mathbb{R}$ 和 h 的连续函数，定义单步格式

$$z_{n+1} = z_n + h\varphi(t_n, z_n, h), \quad 0 \le n \le N-1, \quad z_0 = y_0, \quad h = \frac{T}{N}.$$

如果这个单步格式是一致的且它是稳定的，那么它相对于微分方程

$$y'(t) = f(t, y(t)), \quad y(t_0) = y_0, \quad t \in [t_0, t_0 + T]$$

是收敛的。

引用的示例处理 *Euler-Cauchy* 格式。

7.2.6 *Runge-Kutta* 格式

这些格式允许恢复 *Taylor* 格式的良好性质（高阶），而不呈现其缺点（计算 f 的连续导数）。

通常有两种构造方法。我们在这里介绍一种。另一种在引用的文档中介绍。

这些是单步格式，因此可以写成形式

$$\begin{cases} z_0 = y_0, \\ z_{n+1} = z_n + h\varphi(t_n, z_n, h), \quad n \geq 0, \end{cases}$$

其中 φ 采用以下特殊形式：

$$\varphi(t, z, h) = \sum_{i=1}^{q} \gamma_i k_i, \tag{7.2.10}$$

k_i 按以下方式递归定义：

$$\begin{cases} k_1 = f(t, z), \\ k_2 = f(t + h\alpha_1, z + h\beta_{11}k_1), \\ k_3 = f(t + h\alpha_2, z + h\beta_{21}k_1 + h\beta_{22}k_2), \\ \vdots \\ k_q = f\left(t + h\alpha_{q-1}, z + h\sum_{p=1}^{q-1} \beta_{q-1,p}k_p\right). \end{cases} \tag{7.2.11}$$

引入这 q 个中间值的目的是近似一个 q 阶 *Taylor* 格式。为此，必须确定未知量：

$$[\gamma_i]_{i=1,\ldots,q}, \quad [\alpha_i]_{i=1,\ldots,q-1}, \quad [\beta_{ij}]_{i=1,\ldots,q-1,j=1,\ldots,i}.$$

很难制定一种方法来确定任意 q 值的这些未知量，这就是为什么我们将只在一个例子上进行推理，这里对于 $q = 2$，然后我们将不加证明地给出 $q = 4$ 时获得的值，这是实践中最常用的值。

一个 2 阶 *Taylor* 格式写成

$$z_{n+1} = z_n + h\psi(t_n, z_n, h),$$

其中

$$\psi(t, z, h) = f(t, z) + \frac{h}{2}\left(\frac{\partial f}{\partial t}(t, z) + f(t, z)\frac{\partial f}{\partial y}(t, z)\right). \tag{7.2.12}$$

对于 $q = 2$，由 (7.2.10)–(7.2.11) 定义的函数 $\varphi(t, z, h)$ 写成

$$\begin{aligned} \varphi(t, z, h) &= \gamma_1 k_1 + \gamma_2 k_2 \\ &= \gamma_1 f(t, z) + \gamma_2 f(t + h\alpha_1, z + h\beta_1 f(t, z)), \end{aligned} \tag{7.2.13}$$

其中设 $\beta_1 = \beta_{11}$。我们将尝试识别未知系数 $\gamma_1, \gamma_2, \alpha_1, \beta_1$，使得 $\varphi(t, z, h)$ 和 $\psi(t, z, h)$ 尽可能接近。为此，我们使用两个变量的 *Taylor* 展开展开

$$f(t + h\alpha_1, z + h\beta_1 f(t, z)),$$

这给出到 2 阶：

$$f(t+u,z+v)=f(t,z)+u\frac{\partial f}{\partial t}(t,z)+v\frac{\partial f}{\partial y}(t,z)+\frac{u^2}{2}\frac{\partial^2 f}{\partial t^2}(\xi,\eta)+uv\frac{\partial^2 f}{\partial t\partial y}(\xi,\eta)+\frac{v^2}{2}\frac{\partial^2 f}{\partial y^2}(\xi,\eta),$$

其中 $(\xi,\eta)\in[t,t+u]\times[z,z+v]$。我们因此得到

$$f(t+h\alpha_1,z+h\beta_1 f(t,z))=f(t,z)+h\alpha_1\frac{\partial f}{\partial t}(t,z)+h\beta_1 f(t,z)\frac{\partial f}{\partial y}(t,z)+\mathscr{O}(h^2),$$

这允许我们写成

$$\varphi(t,z,h)=(\gamma_1+\gamma_2)f(t,z)+\gamma_2\left(h\alpha_1\frac{\partial f}{\partial t}(t,z)+h\beta_1 f(t,z)\frac{\partial f}{\partial y}(t,z)\right)+\mathscr{O}(h^2).$$

如果忽略余项，那么可以将此表达式与由 (7.2.12) 给出的 $\psi(t,z,h)$ 等同；我们因此得到以下方程：

$$\begin{cases}\gamma_1+\gamma_2=1,\\ \gamma_2\alpha_1=\frac{1}{2},\\ \gamma_2\beta_1=\frac{1}{2}.\end{cases}\tag{7.2.14}$$

由于有四个未知量的三个方程，系数选择有无穷多种可能性；我们这里只给出最流行的：

- $\gamma_1=0$，$\gamma_2=1$，$\alpha_1=\beta_1=\frac{1}{2}$，这给出格式

$$z_{n+1}=z_n+hf\left(t_n+\frac{1}{2}h,z_n+\frac{1}{2}hf(t_n,z_n)\right),\tag{7.2.15}$$

  称为**中点格式**。

- $\gamma_1=\gamma_2=\frac{1}{2}$，$\alpha_1=\beta_1=1$，这给出众所周知的格式

$$z_{n+1}=z_n+\frac{h}{2}(f(t_n,z_n)+f(t_{n+1},z_n+hf(t_n,z_n))),$$

  因为它是 *Euler-Cauchy* 格式 (7.2.5)。

这些格式当然是 2 阶的，因为

$$\varphi(t_n,z_n,h)+\mathscr{O}(h^2)=\psi(t_n,z_n,h),$$

这允许保持所用 *Taylor* 格式的局部误差的阶。

最常用的选择是 $q=4$。这给出 **4 阶 *Runge-Kutta* 格式**，或简称为 **RK4**，在工程科学中几乎普遍使用[1]：

$$\begin{cases}k_1=f(t_n,z_n),\\ k_2=f\left(t_n+\frac{h}{2},z_n+\frac{h}{2}k_1\right),\\ k_3=f\left(t_n+\frac{h}{2},z_n+\frac{h}{2}k_2\right),\\ k_4=f(t_{n+1},z_n+hk_3),\\ z_{n+1}=z_n+\frac{h}{6}(k_1+2k_2+2k_3+k_4).\end{cases}\tag{7.2.16}$$

在第二个引用的文档中，您可以阅读如何调整网格的步长以提高算法的效率。我们称之为**自适应网格**。

[1]有时甚至错误地使用！

7.3 多步格式

7.3.1 *Adams-Bashforth* 格式

微分方程的精确解 $y(t)$ 满足

$$y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} f(t, y(t))\, dt.$$

某些格式基于对

$$\int_{t_n}^{t_{n+1}} f(t, y(t))\, dt \tag{7.3.1}$$

使用一两点求积公式的近似。这里我们用数量

$$\int_{t_n}^{t_{n+1}} p(t)\, dt \tag{7.3.2}$$

来近似这个积分，其中 $p(t)$ 是满足

$$p(t_i) = f(t_i, y(t_i)), \quad i = n, n-1, \ldots, n-q$$

的唯一 q 次多项式。

如果在 *Lagrange* 基上写出这个多项式，有

$$p(t) = \sum_{k=0}^{q} L_k(t) f(t_{n-k}, y(t_{n-k})),$$

因此

$$\int_{t_n}^{t_{n+1}} p(t)\, dt = h \sum_{k=0}^{q} b_k f(t_{n-k}, y(t_{n-k})),$$

其中

$$b_k = \frac{1}{h} \int_{t_n}^{t_{n+1}} L_k(t)\, dt. \tag{7.3.3}$$

因此有以下格式，称为 $q+1$ **步 *Adams-Bashforth* 格式**：

$$z_{n+1} = z_n + h \sum_{k=0}^{q} b_k f(t_{n-k}, z_{n-k}), \quad n \geq q. \tag{7.3.4}$$

这个 $q+1$ 步格式涉及 $q+1$ 个点，在这些点上评估函数 f（(t_{n-k}, z_{n-k})，对于 $k = 0, \ldots, q$）。我们说这是一个 $q+1$ **步和** $q+1$ **节点**的格式。

这个格式只在 $n \geq q$ 时有效，这就是为什么在实践中需要用足够高阶的单步格式（例如 *Runge-Kutta*）来近似前 q 个值 $z_1, \ldots, z_q$。

注意到由公式 (7.3.3) 给出的系数 b_k 与 h 无关。实际上有

$$b_k = \frac{1}{h} \int_{t_n}^{t_{n+1}} \prod_{j=0, j\neq k}^{q} \frac{t - t_{n-j}}{t_{n-k} - t_{n-j}}\, dt,$$

如果设 $s=\dfrac{t-t_n}{h}$，

$$b_k=\int_0^1\prod_{j=0,j\neq k}^{q}\frac{j+s}{j-k}\,ds,$$

这个表达式清楚地表明 h 不出现。

我们可以看看对于 $q=1$ 这种方法给出什么：

$$b_0=\int_0^1(s+1)\,ds=\frac{3}{2}\quad 和\quad b_1=-\int_0^1 s\,ds=-\frac{1}{2},$$

因此两步 *Adams-Bashforth* 格式采用以下形式：

$$z_{n+1}=z_n+h\left[\frac{3}{2}f(t_n,z_n)-\frac{1}{2}f(t_{n-1},z_{n-1})\right],\quad n\geq 1.$$

一般来说，*Adams-Bashforth* 格式

$$z_{n+1}=z_n+h\sum_{k=0}^{q}b_kf(t_{n-k},z_{n-k}),\quad n\geq q,$$

其中 b_k 由 (7.3.3) 给出，是 q **阶**的。多步格式的阶、一致性和稳定性的概念与单步格式略有不同。我们不会在本课程中讨论它们，它们在著作[2]中得到了很好的处理。

您可以在引用的课程段落中找到这些格式对于某些 q 值的情况。

7.3.2　*Adams-Bashforth* 格式的一些例子

以下是 *Adams-Bashforth* 格式对应于某些 q 值的情况：

- **两步 *Adams-Bashforth* 格式**（两个节点）

$$z_{n+1}=z_n+h\left[\frac{3}{2}f(t_n,z_n)-\frac{1}{2}f(t_{n-1},z_{n-1})\right],\quad n\geq 1,$$

局部误差 $\tau_{n+1}(h)=\frac{5}{12}y^{(3)}(\eta)h^3$，$\eta\in[t_{n-1},t_{n+1}]$。

- **三步 *Adams-Bashforth* 格式**（三个节点）

$$z_{n+1}=z_n+\frac{h}{12}[23f(t_n,z_n)-16f(t_{n-1},z_{n-1})+5f(t_{n-2},z_{n-2})],\quad n\geq 2,$$

局部误差 $\tau_{n+1}(h)=\frac{3}{8}y^{(4)}(\eta)h^4$，$\eta\in[t_{n-2},t_{n+1}]$。

- **四步 *Adams-Bashforth* 格式**（四个节点）

$$z_{n+1}=z_n+\frac{h}{24}[55f(t_n,z_n)-59f(t_{n-1},z_{n-1})+37f(t_{n-2},z_{n-2})-9f(t_{n-3},z_{n-3})],\quad n\geq 3,$$

局部误差 $\tau_{n+1}(h)=\frac{251}{720}y^{(5)}(\eta)h^5$，$\eta\in[t_{n-3},t_{n+1}]$。

[2]BURDEN, R.L. 和 FAIRES, J.D.：Numerical Analysis - Pws-Kent, Boston, p. 257-268。

7.3.3 *Adams-Moulton* 隐式格式

我们将采用与 *Adams-Bashforth* 格式相同的方法。然而，这次我们将用数量

$$\int_{t_n}^{t_{n+1}} p(t)\,dt$$

来近似积分 (7.3.1)，其中 $p(t)$ 是满足

$$p(t_i) = f(t_i, y(t_i)), \quad i = n+1, n, n-1, \ldots, n-q$$

的唯一 $q+1$ 次多项式，即我们将 $y(t_{n+1})$ 包含在" 已知" 值中，这就是为什么我们因此得到一族称为 $q+1$ **步 *Adams-Moulton* 格式**的多步隐式格式：

$$z_{n+1} = z_n + h\sum_{k=-1}^{q} b_k f(t_{n-k}, z_{n-k}), \quad n \geq q. \tag{7.3.5}$$

这个格式是一个 $q+1$ 步和 $q+2$ 节点的格式（(t_{n-k}, z_{n-k})，对于 $k = -1, \ldots, q$）。

系数 b_k，其计算方式与 *Adams-Bashforth* 格式相同，由公式

$$b_k = \int_0^1 \prod_{j=-1, j\neq k}^{q} \frac{j+s}{j-k}\,ds, \quad k = -1, 0, \ldots, q$$

获得。

对于 $q = 1$，我们得到 *Euler*-Centré 格式 (7.2.4)：

$$z_{n+1} = z_n + \frac{h}{2}[f(t_{n+1}, z_{n+1}) + f(t_n, z_n)], \quad n \geq 0,$$

局部误差 $\tau_{n+1}(h) = -\frac{1}{12}y^{(3)}(\eta)h^3$，$\eta \in [t_{n-1}, t_{n+1}]$。

您可以在引用的段落中找到这些格式对于其他 q 值的情况。

在实践中，*Adams-Moulton* 格式不直接使用，因为它们是隐式的，因此尝试使用不动点或 *Newton* 方法获得 z_{n+1} 会失去通过重用 f 的先前值获得的优势。相反，我们联合使用相同阶的 *Adams-Bashforth* 格式和 *Adams-Moulton* 格式来构造预测-校正格式，在 *Adams-Moulton* 格式中使用 *Adams-Bashforth* 格式预测的值作为 z_{n+1}。最常用的预测-校正格式在 4 阶使用这两种格式：

预测：

$$\tilde{z}_{n+1} = z_n + \frac{h}{24}[55f(t_n, z_n) - 59f(t_{n-1}, z_{n-1}) + 37f(t_{n-2}, z_{n-2}) - 9f(t_{n-3}, z_{n-3})],$$

校正：

$$z_{n+1} = z_n + \frac{h}{24}[9f(t_{n+1}, \tilde{z}_{n+1}) + 19f(t_n, z_n) - 5f(t_{n-1}, z_{n-1}) + f(t_{n-2}, z_{n-2})].$$

可以证明，两个格式中每一个的局部误差的阶（这里是 4）都得到保持。

7.3.4 *Adams-Moulton* 格式的一些例子

以下是 *Adams-Moulton* 格式对应于某些 q 值的情况：

- **两步 *Adams-Moulton* 格式**（三个节点）

$$z_{n+1} = z_n + \frac{h}{12}[5f(t_{n+1}, z_{n+1}) + 8f(t_n, z_n) - f(t_{n-1}, z_{n-1})], \quad n \geq 1,$$

局部误差 $\tau_{n+1}(h) = -\frac{1}{24}y^{(4)}(\eta)h^4$，$\eta \in [t_{n-1}, t_{n+1}]$。

- **三步 *Adams-Moulton* 格式**（四个节点）

$$z_{n+1} = z_n + \frac{h}{24}[9f(t_{n+1}, z_{n+1}) + 19f(t_n, z_n) - 5f(t_{n-1}, z_{n-1}) + f(t_{n-2}, z_{n-2})], \quad n \geq 2,$$

局部误差 $\tau_{n+1}(h) = -\frac{19}{720}y^{(5)}(\eta)h^5$，$\eta \in [t_{n-2}, t_{n+1}]$。

- **四步 *Adams-Moulton* 格式**（五个节点）

$$\begin{aligned} z_{n+1} = z_n + \frac{h}{720}[&251f(t_{n+1}, z_{n+1}) + 646f(t_n, z_n) - 264f(t_{n-1}, z_{n-1}) \\ &+ 106f(t_{n-2}, z_{n-2}) - 19f(t_{n-3}, z_{n-3})], \quad n \geq 3, \end{aligned}$$

局部误差 $\tau_{n+1}(h) = -\frac{3}{160}y^{(6)}(\eta)h^6$，$\eta \in [t_{n-3}, t_{n+1}]$。

7.4 第七章文档

7.4.1 Lipschitz 条件

定义 7.4.1

设 g 是定义在 $D \subset \mathbb{R}^n$ 上取值于 $\mathbb{R}^p$ 的函数，如果存在常数 $L > 0$ 使得

$$\forall x, y \in D, \quad \|g(x) - g(y)\| \leq L\|x - y\|,$$

则称 g 满足 ***Lipschitz* 条件**（或它是 ***Lipschitz* 的**）。

定理 7.4.1

（*Cauchy-Lipschitz*）

假设函数 f 在 y 上是 *Lipschitz* 的，即存在常数 $L > 0$ 使得

$$\forall t \in I, \quad \forall x, y \in \mathbb{R}, \quad |f(t, x) - f(t, y)| \leq L|x - y|,$$

那么问题

$$\begin{cases} y'(t) = f(t, y(t)), & t \in I, \\ y(t_0) = y_0, & t_0 \in I, \end{cases}$$

有唯一解。

考虑问题

$$\begin{cases} y'(t) = \sqrt{y(t)}, \\ y(0) = 0 \end{cases}$$

其解不是唯一的。那么我们看到 f 不满足 *Lipschitz* 条件。实际上，有

$$f(t,y) - f(t,z) = \sqrt{y} - \sqrt{z} = \frac{y-z}{\sqrt{y}+\sqrt{z}},$$

分母在原点处为零。

7.4.2 *Runge-Kutta* 方法的定义

单步方法只使用点 (t_n, y_n) 来计算 (t_{n+1}, y_{n+1})。因此，为了获得足够高阶的方法，必须引入中间点。考虑下面的 *Cauchy* 问题

$$\begin{cases} y' = f(t,y), \quad t \in [t_0, t_0+T], \\ y(t_0) = y_0. \end{cases} \tag{7.4.1}$$

我们试图相对于分割 $t_0 < t_1 < \cdots < t_N = t_0 + T$ 对其进行离散化。因此，想法是使用中间点 $(t_{n,i}, y_{n,i})$ 从点 (t_n, y_n) 计算点 (t_{n+1}, y_{n+1})。

在每个这样的点，我们关联" 斜率"

$$p_{n,i} = f(t_{n,i}, y_{n,i}),$$

这实际上是函数 y 在点 $t_{n,i}$ 处的切线斜率 $y'(t_{n,i})$ 的近似。

这些中间点将是数值积分公式 (Q)（Q 表示求积）的节点：

$$\int_0^1 g(\tau)\,d\tau \approx \sum_{i=1}^{q} b_i g(c_i) \quad (Q)$$

它将用于近似精确表达式

$$y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} f(t, y(t))\,dt,$$

即，在从参考区间 $[0,1]$ 转换到区间 $[t_n, t_{n+1}]$ 之后：

$$t_{n,i} = t_n + c_i h_n, \quad c_i \in [0,1],$$

$$y_{n+1} = y_n + h_n \sum_{i=1}^{q} b_i f(t_{n,i}, y_{n,i}).$$

为了获得数值格式，还需要构造近似 $y_{n,i}$。为此，我们再次使用数值积分，但为了避免无限引入新的中间点，这些新的求积公式将只使用先前的节点 c_i。

然后，对于每个点 $(t_{n,i}, y_{n,i})$，我们给出一个数值积分方法，在每个参考区间上定义，这里是 $[0, c_i]$：

$$\int_0^{c_i} g(\tau)\, d\tau \approx \sum_{j=1}^{q} a_{ij} g(c_j), \quad (Q_i)$$

设 $y(t)$ 是 (7.4.1) 的精确解。有

$$y(t_{n,i}) = y(t_n) + \int_{t_n}^{t_{n,i}} f(t, y(t))\, dt = y(t_n) + h_n \int_0^{c_i} f(t_n + uh_n, y(t_n + uh_n))\, du,$$

其中我们做了变量替换 $t = t_n + uh_n$。同样，

$$y(t_{n+1}) = y(t_n) + h_n \int_0^1 f(t_n + uh_n, y(t_n + uh_n))\, du.$$

当我们将这些方法应用于 $g(u) = f(t_n + uh_n, y(t_n + uh_n))$ 时，有

$$\begin{cases} y(t_{n,i}) \approx y(t_n) + h_n \sum_{j=1}^{q} a_{ij} f(t_{n,j}, y(t_{n,j})), \quad i = 1, \ldots, q, \\ y(t_{n+1}) \approx y(t_n) + h_n \sum_{i=1}^{q} b_i f(t_{n,i}, y(t_{n,i})). \end{cases}$$

因此对应的 *Runge-Kutta* 方法：

$$\begin{cases} t_{n,i} = t_n + \tau_i h_n, \\ y_{n,i} = y_n + h_n \sum_{j=1}^{q} a_{ij} p_{n,j}, \\ p_{n,i} = f(t_{n,i}, y_{n,i}), \\ t_{n+1} = t_n + h_n, \\ y_{n+1} = y_n + h_n \sum_{i=1}^{q} b_i p_{n,i}. \end{cases} \tag{7.4.2}$$

我们看到这确实是单步方法，其中

$$\Phi(t, y, h) = \sum_{i=1}^{q} b_i f(t + c_i h, y_i), \quad \text{其中} \quad y_i = y + h \sum_{j=1}^{q} a_{ij} f(t + c_j h, y_j), \quad 1 \le i \le q.$$

对应的 *Runge-Kutta* 方法是**显式的**：y_{n+1} 的计算从 y_n 的值开始，无需求解方程。如果对 j 的求和从 1 到 i，则方法称为**半隐式的**。如果它超过（最多到 q），则称为**隐式的**。那么，必须在每一步求解一个方程（通常是非线性的）来从 y_n 计算 y_{n+1}。

7.4.3　步长的自动适应

格式的收敛性表示全局误差 $|y(t_n) - w_n|$ 在分割的所有点处趋于零，当这些点的数量趋于无穷时。如下面的定理所示，它直接与局部误差相关，正是这种关系证明了本段后续内容的合理性：

定理 7.4.2

设单步格式

$$\begin{cases} z_0 = y_0, \\ z_{n+1} = z_n + h\varphi(t_n, z_n, h), \quad n \geq 0, \end{cases} \tag{7.4.3}$$

近似微分方程

$$y'(t) = f(t, y), \quad t \in [t_0, t_0 + T], \quad y(t_0) = y_0$$

的解。

如果格式对于 $h < h^*$ 是收敛的，且局部误差 $\tau_{n+1}(h)$ 满足

$$\left| \frac{\tau_{n+1}(h)}{h} \right| \leq \varepsilon(h), \quad \forall n, \quad \forall h < h^*,$$

那么有上界

$$|y(t_n) - z_n| \leq \frac{\varepsilon(h)}{L} e^{L(t_n - t_0)}, \quad \forall n,$$

其中 L 是相对于格式 (7.4.3) 的函数 φ 的 *Lipschitz* 常数。

因此，只要能够使局部误差不超过某个容差阈值，就可以控制全局误差。例如，这将允许使用最少的步长，同时遵守此容差。不幸的是，这并不令人惊讶，如果步长 h 保持常数，在控制全局误差的同时拥有最少的步长是一个不可能实现的目标。

可以按以下方式估计局部误差：假设我们有一个 p 阶的单步格式

$$\begin{cases} z_0 = y_0, \\ z_{n+1} = z_n + h\varphi(t_n, z_n, h), \quad n \geq 0. \end{cases} \tag{7.4.4}$$

与此格式相关的局部误差由量

$$\tau_{n+1}(h) = y(t_{n+1}) - y(t_n) - h\varphi(t_n, y(t_n), h) = \mathscr{O}(h^{p+1})$$

给出，其中 y 表示原始微分方程的解。我们给出第二个格式

$$\begin{cases} \tilde{z}_0 = y_0, \\ \tilde{z}_{n+1} = \tilde{z}_n + h\tilde{\varphi}(t_n, z_n, h), \quad n \geq 0, \end{cases} \tag{7.4.5}$$

它是 $p+1$ 阶的，其局部误差 $\tilde{\tau}_{n+1}(h)$ 因此满足

$$\tilde{\tau}_{n+1}(h) = \mathscr{O}(h^{p+2}).$$

假设我们对于给定的 $n \geq 0$ 有 z_n，并应用两个格式来获得 $y(t_{n+1})$ 的近似：有

$$z_{n+1} = z_n + h\varphi(t_n, z_n, h),$$

$$\tilde{z}_{n+1} = z_n + h\tilde{\varphi}(t_n, z_n, h).$$

如果我们假设 $z_n = y(t_n)$（对于 $n = 0$ 为真！），可以写成

$$\tau_{n+1}(h) = y(t_{n+1}) - z_n - h\varphi(t_n, z_n, h) = y(t_{n+1}) - z_n - (z_{n+1} - z_n) = y(t_{n+1}) - z_{n+1}.$$

如果我们在最后这个量上加上和减去 $\tilde{z}_{n+1}$，得到

$$\tau_{n+1}(h) = y(t_{n+1}) - \tilde{z}_{n+1} + \tilde{z}_{n+1} - z_{n+1} = y(t_{n+1}) - y(t_n) - \tilde{\varphi}(t_n, y(t_n), h) + \tilde{z}_{n+1} - z_{n+1} = \tilde{\tau}_{n+1}(h) + \tilde{z}_{n+1} - z_{n+1}.$$

由于 $\tilde{\tau}_{n+1}(h) = \mathscr{O}(h^{p+2})$ 和 $\tau_{n+1}(h) = \mathscr{O}(h^{p+1})$，我们可以忽略 $\tilde{\tau}_{n+1}(h)$ 相对于 $\tau_{n+1}(h)$，并通过以下方式估计 $\tau_{n+1}(h)$：

$$\hat{\tau}_{n+1}(h) = \tilde{z}_{n+1} - z_{n+1}.$$

我们按以下方式使用此估计器：从初始步长开始，通常是 $h = (T - t_0)/100$，在每次迭代 n 时，我们计算 $\tilde{z}_{n+1} - z_{n+1}$ 并因此计算 $\hat{\tau}_{n+1}(h)$。然后我们考虑以下情况：

- 如果 $\dfrac{|\hat{\tau}_{n+1}(h)|}{h} \in [\varepsilon/10, \varepsilon]$，则我们接受 z_{n+1}，为下一次迭代保持相同的步长。
- 如果 $\dfrac{|\hat{\tau}_{n+1}(h)|}{h} \in [0, \varepsilon/10)$，我们接受 z_{n+1} 并为下一次迭代增加步长（例如 $h \leftarrow 2h$）。
- 如果 $\dfrac{|\hat{\tau}_{n+1}(h)|}{h} > \varepsilon$，我们拒绝 z_{n+1}，减小步长（例如 $h \leftarrow h/2$）并重新计算 z_{n+1}、$\tilde{z}_{n+1}$ 然后 $\hat{\tau}_{n+1}(h)$。

通常，我们对步长施加最大值（通常是其初始值）以及最小值。当达到最小步长时，这意味着要么最小值相对于要求的容差 ε 太大，要么微分方程的解在考虑的瞬时 t_n 处存在奇点。

最常用的方法基于两个 *Runge-Kutta* 格式，分别是 4 阶和 5 阶（这是 Matlab 函数 ode45 中使用的方法）。

Chapter 8

特征值和特征向量的确定

8.1　回顾和记号

我们回顾，给定矩阵 $A \in M_{nn}(\mathbb{R})$，计算特征值的问题在于找到一个标量 λ，使得存在向量 $\boldsymbol{y}$，$\boldsymbol{y} \neq \mathbf{0}$，使得

$$A\boldsymbol{y} = \lambda \boldsymbol{y}.$$

记号在本章中，我们记 $\lambda_1, \lambda_2, \ldots, \lambda_n$ 为 A 的 n 个特征值（可能重复），并假设

$$|\lambda_1| \geq |\lambda_2| \geq \cdots \geq |\lambda_n|,$$

λ_1 称为 A 的**主特征值**。

我们假设矩阵 A 是可对角化的，因此存在一个特征向量基，我们记作 $\boldsymbol{y}^{(1)}, \boldsymbol{y}^{(2)}, \ldots, \boldsymbol{y}^{(n)}$。

确定 A 的特征值的问题等价于找到特征多项式

$$P_A(s) = \det(sI - A)$$

的根。

人们可能认为特征值的数值计算归结为多项式的数值根计算。实际上，相反的情况发生了。实际上，给定一个多项式

$$p(t) = t^n + a_n t^{n-1} + a_{n-1} t^{n-2} + \cdots + a_2 t + a_1,$$

可以证明（参见练习 TD A.8.2）这个多项式是以下矩阵的特征多项式

$$A = \begin{pmatrix} 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & 1 \\ -a_1 & -a_2 & \cdots & -a_{n-1} & -a_n \end{pmatrix}.$$

具有上述形式的矩阵 A 称为**友矩阵**。

8.2 幂迭代方法 - 陈述和假设

幂迭代方法如下：

$$\begin{cases} \boldsymbol{x}^{(0)} \text{ 给定在} \mathbb{R}^n \text{ 中}, \\ \boldsymbol{x}^{(k+1)} = \dfrac{A\boldsymbol{x}^{(k)}}{\|A\boldsymbol{x}^{(k)}\|}, \quad k \geq 0, \end{cases} \tag{8.2.1}$$

其中 $\|\cdot\|$ 表示任意范数。

假设和记号

- 我们假设
$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \cdots \geq |\lambda_n|.$$
因此 λ_1 是一个实单特征值（在练习中证明）。
- 我们假设 $\boldsymbol{x}^{(0)}$ 不属于由特征向量 $\{\boldsymbol{y}^{(2)}, \boldsymbol{y}^{(3)}, \ldots, \boldsymbol{y}^{(n)}\}$ 生成的子空间。
- 设 p 是一个指标，使得 $y_p^{(1)} \neq 0$。

定理 8.2.1

在前面的假设下，由关系 (8.2.1) 生成的序列 $(\boldsymbol{x}^{(k)})_{k\in\mathbb{N}}$ 具有以下性质：

$$\lim_{k\to\infty} \|A\boldsymbol{x}^{(k)}\| = |\lambda_1|,$$

更精确地，有

$$\lim_{k\to\infty} \frac{[A\boldsymbol{x}^{(k)}]_p}{x_p^{(k)}} = \lambda_1.$$

此外，序列 $(\boldsymbol{x}^{(k)})_{k\in\mathbb{N}}$ 以下列方式收敛到与 λ_1 相关的特征向量：

$$\lim_{k\to\infty} [\operatorname{sgn}(\lambda_1)]^k \boldsymbol{x}^{(k)} = \gamma \boldsymbol{y}^{(1)}, \tag{8.2.2}$$

其中 γ 是一个实常数。

8.3 幂迭代方法 - 收敛性和备注

我们现在将证明定理 8.1。

我们立即证明有：

$$\boldsymbol{x}^{(k)} = \frac{A^k \boldsymbol{x}^{(0)}}{\|A^k \boldsymbol{x}^{(0)}\|}. \tag{8.3.1}$$

实际上，这个性质对于 $k = 1$ 由 $\boldsymbol{x}^{(1)}$ 的构造本身为真，如果我们假设该性质对于 k 为真，那么有

$$\boldsymbol{x}^{(k+1)} = \frac{A\boldsymbol{x}^{(k)}}{\|A\boldsymbol{x}^{(k)}\|} = \frac{A\frac{A^k\boldsymbol{x}^{(0)}}{\|A^k\boldsymbol{x}^{(0)}\|}}{\left\|A\frac{A^k\boldsymbol{x}^{(0)}}{\|A^k\boldsymbol{x}^{(0)}\|}\right\|} = \frac{A^{k+1}\boldsymbol{x}^{(0)}}{\|A^{k+1}\boldsymbol{x}^{(0)}\|}.$$

通过在特征向量基上展开 $\boldsymbol{x}^{(0)}$，可以写成

$$\boldsymbol{x}^{(0)} = \sum_{i=1}^{n} \xi_i \boldsymbol{y}^{(i)}, \quad \xi_1 \neq 0.$$

我们因此得到

$$A^k \boldsymbol{x}^{(0)} = \sum_{i=1}^{n} \xi_i A^k \boldsymbol{y}^{(i)} = \sum_{i=1}^{n} \xi_i \lambda_i^k \boldsymbol{y}^{(i)} = \lambda_1^k \left(\xi_1 \boldsymbol{y}^{(1)} + \sum_{i=2}^{n} \xi_i \left[\frac{\lambda_i}{\lambda_1} \right]^k \boldsymbol{y}^{(i)} \right) = \lambda_1^k \boldsymbol{w}^{(k)}, \tag{8.3.2}$$

其中设

$$\boldsymbol{w}^{(k)} = \xi_1 \boldsymbol{y}^{(1)} + \sum_{i=2}^{n} \xi_i \left[\frac{\lambda_i}{\lambda_1} \right]^k \boldsymbol{y}^{(i)},$$

使用 (8.3.1) 和 (8.3.2)，得到

$$\boldsymbol{x}^{(k)} = \frac{\lambda_1^k}{|\lambda_1^k|} \frac{\boldsymbol{w}^{(k)}}{\|\boldsymbol{w}^{(k)}\|} = [\mathrm{sgn}(\lambda_1)]^k \frac{\boldsymbol{w}^{(k)}}{\|\boldsymbol{w}^{(k)}\|}, \tag{8.3.3}$$

由于 $\lim_{k\to\infty} \boldsymbol{w}^{(k)} = \xi_1 \boldsymbol{y}^{(1)}$（因为 $|\lambda_i/\lambda_1| < 1$，$\forall i > 1$），因此

$$\lim_{k\to\infty} [\mathrm{sgn}(\lambda_1)]^k \boldsymbol{x}^{(k)} = \gamma \boldsymbol{y}^{(1)}, \quad \text{其中} \quad \gamma = \frac{\xi_1}{|\xi_1| \|\boldsymbol{y}^{(1)}\|}.$$

同样，根据 (8.3.1) 和 (8.3.2)

$$A\boldsymbol{x}^{(k)} = \frac{A^{k+1}\boldsymbol{x}^{(0)}}{\|A^k \boldsymbol{x}^{(0)}\|} = \frac{\lambda_1^{k+1} \boldsymbol{w}^{(k+1)}}{|\lambda_1^k| \|\boldsymbol{w}^{(k)}\|} = \lambda_1 [\mathrm{sgn}(\lambda_1)]^k \frac{\boldsymbol{w}^{(k+1)}}{\|\boldsymbol{w}^{(k)}\|}, \tag{8.3.4}$$

因此

$$\|A\boldsymbol{x}^{(k)}\| = |\lambda_1| \frac{\|\boldsymbol{w}^{(k+1)}\|}{\|\boldsymbol{w}^{(k)}\|},$$

因此 $\lim\limits_{k\to\infty} \|A\boldsymbol{x}^{(k)}\| = |\lambda_1|$。

此外，使用 (8.3.3) 和 (8.3.4)，有

$$\frac{[A\boldsymbol{x}^{(k)}]_p}{x_p^{(k)}} = \lambda_1 \frac{w_p^{(k+1)}}{w_p^{(k)}}.$$

由于 $\lim_{k\to\infty} w_p^{(k)} = \xi_1 y_p^{(1)}$（由假设非零），因此

$$\lim_{k\to\infty} \frac{[A\boldsymbol{x}^{(k)}]_p}{x_p^{(k)}} = \lambda_1.$$

一些备注：

- 如果我们有例如 $\lambda_1 = \lambda_2$ 且 $|\lambda_1| > |\lambda_3| \geq |\lambda_4| \geq \cdots \geq |\lambda_n|$，即如果主特征值是重根，证明仍然有效，只需写成

  $$\boldsymbol{x}^{(0)} = \xi_1 \boldsymbol{y}^{(1)} + \sum_{i=3}^{n} \xi_i \boldsymbol{y}^{(i)},$$

  其中 $\xi_1 \boldsymbol{y}^{(1)}$ 是 $\boldsymbol{x}^{(0)}$ 在与 λ_1 相关的特征子空间（这里是 2 维）上的分量。如果 λ_1 是多重特征值，这仍然有效。相反，如果我们有 $\lambda_1 \neq \lambda_2$ 且 $|\lambda_1| = |\lambda_2|$，那么证明不成立，这特别发生在复特征值的情况下。

- 在公式 (8.2.2) 中出现 λ_1 的符号，这意味着，如果 λ_1 是负数，那么向量 $\boldsymbol{x}^{(k)}$ 在 $+\gamma\boldsymbol{y}^{(1)}$ 和 $-\gamma\boldsymbol{y}^{(1)}$ 两个向量之间振荡。在 TD 中（练习 A.8.1）将看到幂迭代方法的一个变体，它巧妙地使用无穷范数以避免这些振荡。

8.4 逆幂迭代方法 - 原理

如果 λ 是 A 的特征值且 A 是可逆的，那么等价地，λ^{-1} 是 A^{-1} 的特征值，相关的特征向量是相同的。实际上有

$$A\boldsymbol{y} = \lambda\boldsymbol{y} \Leftrightarrow \boldsymbol{y} = \lambda A^{-1}\boldsymbol{y} \Leftrightarrow A^{-1}\boldsymbol{y} = \lambda^{-1}\boldsymbol{y}.$$

此外，对于给定的标量 q，定义矩阵

$$B = A - qI.$$

这个矩阵的特征值为 $\lambda_i - q$，其中 λ_i 是 A 的特征值，矩阵 B^{-1}（如果它被定义，即如果 q 不是 A 的特征值）的特征值为

$$\mu_i = \frac{1}{\lambda_i - q}.$$

实际上，如果 $\boldsymbol{z}$ 是与 $(\lambda_i - q)^{-1}$ 相关的 B^{-1} 的特征向量，它是 B 的特征向量，因此是 A 的特征向量，显然它与特征值 λ_i 相关。验证：

$$B^{-1}\boldsymbol{z} = (\lambda_i - q)^{-1}\boldsymbol{z} \Leftrightarrow \boldsymbol{z} = (\lambda_i - q)^{-1}B\boldsymbol{z} \Leftrightarrow B\boldsymbol{z} = (\lambda_i - q)\boldsymbol{z} \Leftrightarrow (A - qI)\boldsymbol{z} = (\lambda_i - q)\boldsymbol{z} \Leftrightarrow A\boldsymbol{z} - q\boldsymbol{z} = (\lambda_i - q)\boldsymbol{z} \Leftrightarrow A$$

设 A 是在 $\mathbb{R}$ 上可对角化的矩阵，q 是一个实数，λ_j 是 A 的一个特征值，满足

$$0 < |q - \lambda_j| < |q - \lambda_i|, \quad \forall i \neq j, \tag{8.4.1}$$

即 q 不是 A 的特征值，且 λ_j 是最接近 q 的特征值。由 (8.4.1) 得出，矩阵 B^{-1}

$$B^{-1} = (A - qI)^{-1}$$

以

$$\nu_1 = \frac{1}{\lambda_j - q}$$

作为主特征值。因此，对于给定的 q，可以借鉴应用于 B^{-1} 的幂迭代算法，这允许获得 ν_1，我们通过设

$$\lambda_j = \frac{1}{\nu_1} + q$$

来恢复 λ_j。

该方法称为**逆幂迭代方法**。

8.5 逆幂迭代方法

设 $B = A - qI$。给定 $\boldsymbol{x}^{(0)}$ 任意（或几乎任意！），并通过以下方式定义序列 $\boldsymbol{x}^{(k+1)}$：

$$\begin{cases} B\boldsymbol{u}^{(k+1)} = \boldsymbol{x}^{(k)}, \\ \boldsymbol{x}^{(k+1)} = \dfrac{\boldsymbol{u}^{(k+1)}}{\|\boldsymbol{u}^{(k+1)}\|}, \quad k \geq 0. \end{cases} \tag{8.5.1}$$

可以陈述以下定理：

定理 8.5.1

设给定的 $q \in \mathbb{R}$ 使得 $q \neq \lambda_i$，$\forall i$，且设 $B = A - qI$。如果初始向量 $\boldsymbol{x}^{(0)}$ 不属于由 $\{\boldsymbol{y}^{(i)}\}_{i=1,\ldots,n,i\neq j}$ 生成的子空间，那么由方法 (8.5.1) 生成的序列 $(\boldsymbol{x}^{(k)})_{k\in\mathbb{N}}$ 具有以下性质：

$$\lim_{k\to\infty} \|\boldsymbol{u}^{(k)}\| = \left|\frac{1}{\lambda_j - q}\right|,$$

其中 λ_j 是最接近 q 的 A 的特征值。更精确地，如果 $y_p^{(j)} \neq 0$，有

$$\lim_{k\to\infty} \frac{u_p^{(k+1)}}{x_p^{(k)}} = \frac{1}{\lambda_j - q}.$$

此外，序列 $(\boldsymbol{x}^{(k)})_{k\in\mathbb{N}}$ 以下列方式收敛到与 λ_j 相关的 A 的特征向量 $\boldsymbol{y}^{(j)}$：

$$\lim_{k\to\infty} \left[\operatorname{sgn}\left(\frac{1}{\lambda_j - q}\right)\right]^k \boldsymbol{x}^{(k)} = \gamma \boldsymbol{y}^{(j)}, \tag{8.5.2}$$

其中 γ 是一个实常数。

可以证明，方法收敛得越快，$|q - \lambda_j|$ 相对于 $|q - \lambda_i|$（$\forall i \neq j$）越小。

8.6 收缩方法

前面的方法允许确定一个特征值和相关的特征向量，例如逆幂迭代方法允许计算最小绝对值的特征值（如果它是唯一的）。因此，如果我们通过任何方法确定了一个特征值 λ_1（例如主特征值），可以考虑构造一个矩阵，其中刚刚确定的特征值不再是主特征值，但相反，它仍然具有 (λ_j)，$j \neq 1$ 作为特征值。然后幂方法（例如）允许确定族 (λ_j)，$j \neq 1$ 的新主特征值，依此类推。

这个过程构成了所谓的**收缩方法**。

- **第一种情况：A 对称。**
  假设我们知道与特征值 λ 相关的特征向量 $\boldsymbol{y}$，且 $\|\boldsymbol{y}\|_2 = 1$。
  然后考虑矩阵

$$B = A - \lambda \boldsymbol{y}\boldsymbol{y}^T.$$

显然有

$$B\boldsymbol{y} = A\boldsymbol{y} - \lambda \boldsymbol{y}\boldsymbol{y}^T\boldsymbol{y} = \lambda \boldsymbol{y} - \lambda \boldsymbol{y} = \boldsymbol{0}.$$

此外，如果 $\boldsymbol{z}$ 是与另一个特征值 μ 相关的 A 的另一个特征向量，有

$$B\boldsymbol{z} = A\boldsymbol{z} - \lambda \boldsymbol{y}\boldsymbol{y}^T\boldsymbol{z} = \mu \boldsymbol{z},$$

因为根据特征向量的正交性，$\boldsymbol{y}^T\boldsymbol{z} = 0$。

- **第二种情况：A 任意（*Duncan* 和 *Collar* 方法）**

  设 A 是任意矩阵，假设我们获得了特征对 $(\lambda, \boldsymbol{y})$，并假设为简化起见，$\boldsymbol{y}$ 的第一个分量等于 1。记 A_1 为矩阵 A 的第一行，根据特征对 $(\lambda, \boldsymbol{y})$ 的定义，有

$$A_1\boldsymbol{y} = \lambda y_1 = \lambda. \tag{8.6.1}$$

  然后通过以下方式定义矩阵 B：

$$B = A - \boldsymbol{y}A_1.$$

  那么 B 的第一行是零，实际上

$$B_1 = A_1 - y_1 A_1 = \boldsymbol{0}.$$

  此外，根据 (8.6.1)：

$$B\boldsymbol{y} = A\boldsymbol{y} - \boldsymbol{y}A_1\boldsymbol{y} = \lambda \boldsymbol{y} - \lambda \boldsymbol{y} = \boldsymbol{0}. \tag{8.6.2}$$

  如果我们假设 A 的其他特征向量的第一个分量非零，那么可以将它们归一化，使其等于 1。在这些条件下，如果 $(\mu, \boldsymbol{z})$ 是 A 的另一个特征对（$\mu \neq \lambda$），有 $A\boldsymbol{z} = \mu\boldsymbol{z}$，因此

$$A_1\boldsymbol{z} = \mu$$

  和

$$B(\boldsymbol{z} - \boldsymbol{y}) = B\boldsymbol{z} = A\boldsymbol{z} - \boldsymbol{y}A_1\boldsymbol{z} = \mu\boldsymbol{z} - \mu\boldsymbol{y} = \mu(\boldsymbol{z} - \boldsymbol{y}),$$

  第一个等式是 (8.6.2) 的后果。因此，B 的其他特征值与 A 的特征值相同，相关的特征向量为 $\boldsymbol{z} - \boldsymbol{y}$。

  相反，如果 $(\mu, \boldsymbol{u})$ 是 B 的特征对，如果我们假设 $\mu \neq 0$ 且 $A_1\boldsymbol{u} = \mu - \lambda$（如果 $A_1\boldsymbol{u} \neq 0$，这总是可能的），那么：

$$A(\boldsymbol{u} + \boldsymbol{y}) = B\boldsymbol{u} + \boldsymbol{y}A_1\boldsymbol{u} + A\boldsymbol{y} = \mu\boldsymbol{u} + (\mu - \lambda)\boldsymbol{y} + \lambda\boldsymbol{y} = \mu(\boldsymbol{u} + \boldsymbol{y}).$$

  我们刚刚证明了 $(\boldsymbol{u} + \boldsymbol{y})$ 是与特征值 μ 相关的 A 的特征向量。为了获得除 $(\lambda, \boldsymbol{y})$ 之外的 A 的特征对，我们因此归结为寻找 B 的特征对（非零特征值）。考虑到 B 的特殊结构（其第一行为零），我们归结为在 $\mathbb{R}^{n-1}$ 中计算特征值的问题。